


ИИ / МОДЕЛИ ИИ / БОЛЬШИЕ ЯЗЫКОВЫЕ МОДЕЛИ

# Системная карта Claude Sonnet 5 от Anthropic говорит о будущем ИИ больше, чем его результаты в бенчмарках

Системная карта Claude Sonnet 5 от Anthropic показывает, что надежность ИИ-агентов, а не результаты в бенчмарках, станет следующей серьезной проблемой для инженерных команд.

30 июня 2026 г. в 16:37 от [Аманда Касвелл](#)



Егор Комаров, Unsplash

Во вторник состоялся дебют **Claude Sonnet 5 от Anthropic**, и были опубликованы результаты его тестирования, демонстрирующие улучшения в задачах кодирования, логического вывода и агентного моделирования. Системная карта Sonnet 5 тоже рассказывает свою историю. Этот пример показывает, что происходит, когда агент с искусственным интеллектом начинает действовать автономно.

— **Системной карте** на 145 страницах сравнительно мало места уделено введению с предыдущими версиями. Вместо этого основная часть

сопротивляются внедрению команд и восстанавливаются в случае сбоев. То, как они восстанавливаются, дает некоторое представление о том, в чем, по мнению Anthropic, будет заключаться следующая инженерная задача по обеспечению надежности агентов.

В системной карте Sonnet 5 представлены оценки, которые почти не учитывались в предыдущих поколениях больших языковых моделей. Например, только в разделе 5 рассматриваются случаи злонамеренного использования агентов кодирования, агентов использования компьютера и браузерных агентов; автономные операции по оказанию влияния; а также устойчивость к промпт-инъекциям при множественных атаках, включая программу Bug Bounty, в рамках которой адаптивные злоумышленники тестировали среды кодирования, использования компьютера и браузера.

Anthropic также сообщает о результатах тестов SHADE-Arena и LinuxArena, которые позволяют оценить, пытаются ли агенты действовать скрытно — преследуя скрытые цели, но при этом делая вид, что выполняют инструкции. Показатели скрытности Sonnet 5 в этих тестах были близки к нулю, но сам факт того, что Anthropic проводит такие тесты, говорит о том, насколько серьезно они относятся к разнице между моделью, которая хорошо работает в окне чата, и моделью, которая ведет себя стабильно при длительной автономной работе.

Что касается внедрения подсказок, в системной карточке описывается тестирование устойчивости в трех различных средах: средах программирования, использования компьютера и навигации в браузере. Результаты показывают улучшение по сравнению с Sonnet 4.6, но показателен сам подход к оценке. Anthropic тщательно проверяет, можно ли перехватить управление агентом, просматривающим веб-страницы, с помощью инструкций, встроенных в посещаемую страницу.

## Why this matters for engineering teams

Organizations want agents that can investigate incidents, review pull requests, update documentation, navigate internal systems, and orchestrate workflows with minimal supervision. Those workloads place new demands on the surrounding infrastructure that go well beyond the model itself.

## TRENDING STORIES

1. [Base44 bets a narrow model beats frontier AI for vibe coding](#)
2. [Anthropic's Claude Sonnet 5 system card says more about the future of AI than its benchmarks do](#)
3. [Cursor, GitLab and Zed agree GitHub is breaking. They disagree on how to rebuild it.](#)
4. [What comes after attention? This startup says it already knows](#)
5. [Will it Mythos? One coder's verdict on Anthropic's blend of debugging](#)

A long-running task can be interrupted in countless ways, such as a tool call timing out halfway through execution or a browser session losing context after a redirect. Each interruption forces the agent to understand what changed, preserve its progress, and decide how to continue — or recognize that it can't.

## Infrastructure patterns for agents

Anthropic's own evaluation infrastructure offers a glimpse of what those systems look like. The system card describes features such as tool result clearing, which removes stale tool outputs as an agent accumulates context, and memory tools that allow information to persist outside the active context window.

Those capabilities solve practical problems that arise as agents work over longer periods. State has to persist across multiple steps, external tools have to stay synchronized, and failures have to be detected before an agent continues with outdated or incomplete information.

## Where agent deployments break

The system card offers a few hints about where Anthropic thinks the AI race is headed. For one, benchmarks appear to be converging, as the gap between top models on standard evals continues to shrink. What *hasn't* converged is whether an agent can grind through a two-hour coding task without losing context, browse the

For engineering teams evaluating agent platforms, the system card doubles as a checklist of the questions that matter in production. Benchmark scores are only part of the picture. It's equally important to understand how a platform handles failed tool calls, preserves state across long-running tasks, and recovers when an agent loses context midway through a workflow. Those are the situations that determine whether an autonomous system can continue to operate reliably once it's deployed.

TNS



Amanda Caswell is an AI journalist, certified prompt engineer, and technology commentator whose work and expertise have been featured on Fox News and CBS News. She covers artificial intelligence, developer tools, foundation models, and emerging technologies, with a particular focus...

[Read more from Amanda Caswell →](#)

TNS owner Insight Partners is an investor in: Anthropic.

#### SHARE THIS STORY



#### TRENDING STORIES

1. Base44 bets a narrow model beats frontier AI for vibe coding
2. Anthropic's Claude Sonnet 5 system card says more about the future of AI than its benchmarks do
3. Cursor, GitLab and Zed agree GitHub is breaking. They disagree on how to rebuild it.
4. What comes after attention? This startup says it already knows
5. Will it Mythos? One coder's verdict on Anthropic's blend of debugging

## Redpanda

### Kafka's log compaction corrupts data. Here's how we fixed it

25 June 2026

### Bridge Queries in Redpanda SQL

23 June 2026

### Adaptive write request scheduling in Redpanda's Cloud Topics

18 June 2026

## dynatrace

### Your business applications are at risk: Introducing in-context security findings for Kubernetes

30 June 2026

### Multicloud HIPAA compliance for healthcare: Dynatrace now supports AWS, Azure, and GCP

26 June 2026

### Beyond LLM-as-a-judge: Establishing LLM evaluations as a foundation for trustworthy agentic AI systems

26 June 2026

---

## How ScyllaDB's Trie Based Index Delivers Up to 5X More Throughput

30 June 2026

## ScyllaDB 2026.2: DynamoDB Streams and Vector Search, Trie Indexes, and Strongly Consistent Tables

29 June 2026

## Using Salting to Lower Latency for Large Blobs in ScyllaDB

25 June 2026

---

### TNS DAILY NEWSLETTER

Receive a free roundup of the most recent TNS articles in your inbox each day.

svo1975pvn1982@gmail.com

SUBSCRIBE

The New Stack does not sell your information or share it with unaffiliated third parties. By continuing, you agree to our [Terms of Use](#) and [Privacy Policy](#).

## Databases

Edge Computing  
Infrastructure as Code  
Linux  
Microservices  
Open Source  
Networking  
Storage

## API Management

Backend development  
Data  
Frontend Development  
Large Language Models  
Security  
Software Development  
WebAssembly

## OPERATIONS

AI Operations  
CI/CD  
Cloud Services  
DevOps  
Kubernetes  
Observability  
Operations  
Platform Engineering

## CHANNELS

Podcasts  
Ebooks  
Events  
Webinars  
Newsletter  
TNS RSS Feeds

## THE NEW STACK

About / Contact  
Sponsors  
Advertise With Us  
Contributions



Community created roadmaps, articles, resources and journeys for developers to help you choose your path and grow in your career.

Frontend Developer Roadmap  
Backend Developer Roadmap  
Devops Roadmap

## FOLLOW TNS



---

[Privacy Policy](#)

[Cookie Policy](#)