



← Опубликовать пост



@brian_armstrong

Как сохранить неизменным объем расходов на ИИ, в то время как использование токенов растет в геометрической прогрессии: без лишних сложностей и предупреждений о расходах. С улучшенными настройками по умолчанию, маршрутизацией и кэшированием. Улучшенные настройки по умолчанию (а не ограничения по использованию). Инженеры могут выбирать любую модель, но настройки по умолчанию имеют значение. Мы экспериментируем с настройками по умолчанию для моделей с открытым исходным кодом, таких как GLM 5.2 и Kimi 2.7, через наш шлюз больших языковых моделей, но при этом поощряем инженеров выбирать модель, подходящую для конкретной задачи. 91 % наших сотрудников никогда не превышали лимиты использования, поэтому вместо того, чтобы снижать лимиты и увеличивать количество оповещений, мы переходим на более дешевые настройки по умолчанию. Обратите внимание, что при проверке кода используются разные модели, чтобы они могли проверять работу друг друга. Улучшенная маршрутизация. В наших пользовательских наборах инструментов мы предварительно обрабатываем запросы и направляем их в модель, которая лучше всего подходит для выполнения задачи, с учетом попаданий в кэш и стоимости модели. Например, для планирования вам может понадобиться модель фронтенд-разработки, но не для выполнения задач, где она может оказаться избыточной. В конечном счете люди не должны выбирать модели — эту задачу может автоматизировать искусственный интеллект. Улучшенное кэширование. Пропуски в кэше — самый простой способ увеличить затраты. Все наши запросы учитывают кэширование, поэтому мы по возможности повторно используем «теплый» кэш. Например, после правильной реализации в LibreChat доля попаданий в кэш выросла с 5 % до 60 %. Не перегружайте контекст. Запускайте новые сеансы при переключении между задачами. Ограничивайте контекст файлов. Отключайте неиспользуемые инструменты. Не просто сжимайте данные. Цель не в том, чтобы использовать меньше токенов, а в том, чтобы меньше токенов расходовалось впустую. Лучшая видимость. Наши инженеры могут использовать столько токенов, сколько захотят, из любой модели, но мы сделали использование токенов видимым — и чем больше вы тратите на ИИ, тем большего эффекта мы ожидаем. Цель не в том, чтобы ограничить использование. Цель в том, чтобы создать инфраструктуру, которая сделает экспоненциальный рост устойчивым. Благодаря этому мы сократили расходы на ИИ почти вдвое, при этом использование токенов продолжает расти.

Подробнее в




Скачайте приложение и всегда будьте в курсе последних событий.

Получить приложение

AI Spend at Coinbase (Bars) -vs- Token Usage (Line)

Left axis = USD spend (stacked by org). Right axis = total company tokens.



0:48 · 27 июня 2026 г. · 3,4 млн Просмотров

445

691

6 тыс.

6 тыс.



Читать 445 ответов

Подробнее в

Скачайте приложение и всегда будьте в курсе последних событий.

Получить приложение