



Национальная студия дизайна

← Все сообщения


22 июня 2026 года

Представляем Rampart



Тай Грут и Эдвард Користин

3 мин чтения





TL;DR

Rampart, созданный National Design Studio, полностью работает в браузере, выявляя и удаляя персональные данные перед отправкой сообщения. Он сочетает в себе детерминированные правила и машинное обучение, обеспечивая защиту конфиденциальности за миллисекунды.

Когда вы вводите текст в чат-боте, вы можете раскрыть о себе больше, чем планировали. В запросе на исправление электронного письма фигурируют ваше имя и имя вашего коллеги; в вопросе о счете за медицинские услуги — ваш адрес и номер счета; в выражении недовольства — кто вы и где живете. И все, что вы набираете, не остается у вас — оно отправляется на удаленный сервер, который вы никак не можете проверить.

Наш основной принцип разработки заключается в том, что единственной личной информацией, в конфиденциальности которой вы можете быть уверены, является информация, которая никогда не покидает ваше устройство.

Сегодня мы открываем исходный код Rampart — системы фильтрации персональных данных на устройстве первого поколения, которая является

надежной первой линией защиты, гарантирующей, что ваши персональные данные никогда не покинут ваше устройство. **Rampart** представляет собой комбинацию детерминированного уровня, основанного на регулярных выражениях для поиска номеров социального страхования и идентификационных номеров, и MiniLM для поиска имен и адресов.

Почему мы создали Rampart

Зачастую для удаления персональных данных необходимо либо доверять удаленному серверу, либо загружать двоичные файлы на клиентское устройство, что сопряжено с рядом ключевых проблем:

1. **Гарантии конфиденциальности ИИ практически невозможно проверить.** Исходя из базовых принципов, невозможно проверить заявления поставщиков ИИ о конфиденциальности и безопасности. Новая версия среды выполнения ИИ может случайно начать регистрировать конфиденциальную информацию о пользователях, а сервисы несут в себе неизвестные внутренние риски для безопасности, такие как уязвимости нулевого дня и инсайдерские угрозы.
2. **Большинство моделей для удаления персональных данных огромны, что сужает круг пользователей, которым они могут быть полезны.** Например, размер OpenAI Privacy Filter составляет ~2,8 ГБ, и при относительно слабом соединении (10 Мбит/с) его загрузка в браузер займет примерно 38 минут.

How it works

Everything happens in the browser, in the moment between typing a message and sending it; there is no server in the loop.

Model size, including tokenizer

14.7MB

p50 runtime latency, in the
browser (WebGPU)

3.9ms

Private-term recall, seven
languages

98.4%

Before the message goes anywhere, two readers look at it on your device.

The first is a set of rules. Regular expressions paired with real validations handle the information that has structure: Social Security numbers, credit cards, phone numbers, routing and account numbers, emails, IP addresses, government IDs. It is deterministic and fast.

The second is a small language model. Rules can't anticipate every name or street address, so MiniLM reads the sentence for the personal information with a deeper understanding of the context of the sentence, then redacts information it finds within a specific category.

For example, say you type a sentence full of personal information into chat:

Rampart redacts PII on-device so it doesn't have to leave your device

The browser stores relevant PII temporarily on your device to fill in the blanks


My name is [GIVEN_NAME]
[SURNAME], my Social Security
number is [SSN], and I make \$1,950
a month. Can you help me find
affordable housing?

Hi Maria,
Here are affordable housing options
in New York.



The Eliza

Inwood, Manhattan | Affordable homes




Send

East Har
Affordab

Message

We trained **Rampart** on AI4Privacy's OpenPII 1.5M dataset and a synthetic generator that reinforces all 17 entity types with deliberately messy chat-style input. The headline numbers below come from a 30,000-row held-out OpenPII slice spanning seven Latin-script languages, scored end-to-end by the shipped pipeline.



Private-term recall on a 30,000-row held-out OpenPII test set across seven supported languages. Higher is better. [Benchmark ↗](#)

Limitations

Rampart is an alpha product intended to be the first line of defense in a more thorough effort to manage personally identifiable information for AI chat experiences.

It currently supports English, Spanish, French, German, Italian, Portuguese, and Dutch.

Get started

Download the model on HuggingFace, install the NPM library, or read the whitepaper.

If the work of building elegant and useful tools for Americans speaks to you, consider joining NDS.

chat.ts

```
import { createGuard } from "@nationaldesignstudio/rampart";

const guard = await createGuard();

const safe = await guard.protect(
  "My name is John Wick. I live at 88 Cedar Lane, Brookvale, CT 06482.",
);

console.log(safe.text);
// "My name is [GIVEN_NAME_1]. I live at [BUILDING_NUMBER_1] [STREET_NAME_1], Brookv

const reply = await llm(safe.text);
console.log(guard.reveal(reply));

async function llm(text: string): Promise<string> {
  return "Thanks [GIVEN_NAME_1], Brookvale CT 06482 works for eligibility.";
}
// "Thanks John Wick, Brookvale CT 06482 works for eligibility."
```

[HuggingFace](#)

[NPM library](#)

[Whitepaper](#)

Interested in contributing to this work? Join us

Follow on X

Tai Groot @taigr

Edward Cristine @as400495

ND Studio @ndstudio

ND=IS

National Design Studio
Eisenhower Executive Office Building
1650 17th St NW,
Washington, DC 20006

[Work](#)
[About](#)
[News](#)
[Dev Index](#)
[Follow on X](#)

Get updates from
National Design Studio

Enter email

Subscribe →

DESIGNED & ENGINEERED IN D.C. BY NATIONAL DESIGN STUDIO