

РАЗРАБОТКА ИИ / ИНФРАСТРУКТУРА ИИ / БАЗЫ ДАННЫХ

Почему для поиска и ранжирования с помощью ИИ недостаточно векторного поиска

В кратком обзоре GigaOm CxO объясняется, почему для производственного поиска с помощью ИИ недостаточно векторного поиска, и рассматривается, как тензоры объединяют ранжирование и сигналы машинного обучения.

13 июня 2026 г. в 14:00 **Бонни Чейз**



Ардиан Праномо для Unsplash+

[Vespa.ai](#) спонсировала этот пост.

В недавнем аналитическом обзоре GigaOm CxO Decision Brief рассматривается, как архитектуры поиска на основе искусственного

персонализацию и логический вывод на основе машинного обучения в производственных системах.

Векторный поиск изменил ландшафт инфраструктуры искусственного интеллекта, сделав семантический поиск практичным в больших масштабах. Преобразуя текст, изображения и поведение пользователей в эмбединги, организации смогли выйти за рамки точного соответствия ключевым словам и получать информацию на основе ее смысла. Однако производственные системы искусственного интеллекта редко ограничиваются векторным сходством.

Для выполнения реального запроса часто требуется одновременная оценка нескольких сигналов. Одним из факторов может быть семантическая релевантность, но также важны структурированные атрибуты, бизнес-правила, сигналы персонализации, актуальность, контроль доступа, логика рекомендаций и модели ранжирования, основанные на машинном обучении. По мере того как организации переходят от экспериментов с искусственным интеллектом к промышленным приложениям, задача уже не сводится к простому поиску похожих элементов. Она заключается в объединении всех значимых сигналов при сохранении низкой задержки и простоты эксплуатации. Именно поэтому тензоры привлекают все больше внимания.

В то время как векторы представляют информацию в виде одномерного массива числовых значений, тензоры обеспечивают более общую **структуру для представления и обработки** сложных многомерных структур данных. Они дают больше возможностей для контроля над вычислением релевантности, позволяя оценивать плотные вложения, разреженные признаки, метаданные и выходные данные моделей в рамках единого процесса поиска и ранжирования. Для организаций, создающих крупномасштабные поисковые системы, это поднимает важный архитектурный вопрос: достаточно ли простого векторного хранилища или **приложениям следующего поколения на основе ИИ** требуется что-то более выразительное?

«Тензоры предоставляют более общую основу для представления сложных многомерных структур данных и работы с ними».



Vespa.ai is a platform for building AI-driven applications for search, recommendation, personalization, and RAG. It handles large data volumes and high query rates, offering efficient data, inference, and logic management. Available as both a managed service and open source.

[Learn More →](#)

THE LATEST FROM VESPA.AI

[Re-autoresearching MSMARCO BM25, on Vespa](#)

29 May 2026

[Vespa Newsletter, May 2026](#)

27 May 2026

[Scaling a Vespa Application: Feeding Fast and Furiously](#)

28 April 2026

HEAR MORE FROM OUR SPONSOR

svo1975pvn1982@gmail.com

[Submit](#)

Among the findings:

- Production AI systems increasingly depend on combining semantic, lexical, behavioral, and business signals rather than relying on vector similarity alone.
- Architectural fragmentation between vector databases, search engines, rerankers, and feature stores introduces latency, operational complexity, and synchronization challenges that become more significant as workloads scale.
- Emerging retrieval models, including multi-vector and late-interaction approaches, place new demands on infrastructure that were not anticipated when first-generation vector databases were designed.

The paper also examines the infrastructure, operational, and organizational implications of these architectural choices, including benchmark data, deployment considerations, and the trade-offs engineering leaders should evaluate when planning future AI retrieval systems.


TRENDING STORIES

1. [AWS, Microsoft, and Google agree the session is the new unit of compute. They disagree on how to isolate it.](#)
2. [Palantir and Nvidia want to change who owns government AI](#)
3. [Neoclouds, sovereign AI and Postgres: The new operating model for regulated enterprises](#)
4. [GitLab just surveyed 1,500 developers. Here's why it matters for your codebase.](#)
5. [OpenAI wants to claim more of the AI stack with Jalapeño, its first custom chip](#)

“Retrieval is evolving from a nearest-neighbor problem into a ranking and decision-making problem.”

As AI applications become more sophisticated, **retrieval** is evolving from a nearest-neighbor problem into a ranking and decision-making problem. Understanding the role tensors play in that transition may be one of the most important architectural discussions facing engineering leaders today.

Download the [GigaOm CxO Decision Brief](#) to explore the findings in full.



go-to-market execution, she thrives at the intersection of technology and customer needs.

[Read more from Bonnie Chase →](#)

SHARE THIS STORY



TRENDING STORIES

1. AWS, Microsoft, and Google agree the session is the new unit of compute. They disagree on how to isolate it.
2. Palantir and Nvidia want to change who owns government AI
3. Neoclouds, sovereign AI and Postgres: The new operating model for regulated enterprises
4. GitLab just surveyed 1,500 developers. Here's why it matters for your codebase.
5. OpenAI wants to claim more of the AI stack with Jalapeño, its first custom chip

INSIGHTS FROM OUR SPONSOR



Vespa.ai is a platform for building AI-driven applications for search, recommendation, personalization, and RAG. It handles large data volumes and high query rates, offering efficient data, inference, and logic management. Available as both a managed service and open source.

[Learn More →](#)

[Re-autoresearching MSMARCO BM25, on Vespa](#)

27 May 2026

Scaling a Vespa Application: Feeding Fast and Furiously

28 April 2026

The Vespa Cloud Metrics Dashboard

24 April 2026

Using Large ONNX Models with External Data in Vespa Embedders

27 March 2026

How Metal AI Built an Agent-Driven Intelligence Platform on Vespa Cloud

10 March 2026

TNS DAILY NEWSLETTER

Receive a free roundup of the
most recent TNS articles in
your inbox each day.

svo1975pvn1982@gmail.com

SUBSCRIBE

ARCHITECTURE

Cloud Native Ecosystem
Containers
Databases
Edge Computing
Infrastructure as Code
Linux
Microservices
Open Source
Networking
Storage

OPERATIONS

AI Operations
CI/CD
Cloud Services
DevOps
Kubernetes
Observability
Operations
Platform Engineering

THE NEW STACK

About / Contact
Sponsors
Advertise With Us
Contributions

ENGINEERING

AI
AI Engineering
API Management
Backend development
Data
Frontend Development
Large Language Models
Security
Software Development
WebAssembly

CHANNELS

Podcasts
Ebooks
Events
Webinars
Newsletter
TNS RSS Feeds



roadmap.sh

Community created roadmaps, articles, resources and journeys for developers to help you choose your path and grow in your career.

Frontend Developer Roadmap
Backend Developer Roadmap
Devops Roadmap

FOLLOW TNS



© The New Stack 2026

[Disclosures](#)

[Terms of Use](#)

[Advertising Terms & Conditions](#)

[Privacy Policy](#)

[Cookie Policy](#)