



АДАПТИВНОЕ СЕМАНТИКО-ОРИЕНТИРОВАННОЕ КВАНТОВАНИЕ ГЛУБОКИХ НЕЙРОННЫХ СЕТЕЙ

Шапцев Валерий Алексеевич

доктор технических наук,
профессор Школы компьютерных наук,
Тюменский государственный университет,
Тюмень, Россия
E-mail: v.a.shapcev@utmn.ru

Хрупин Данила Станиславович

аспирант Школы компьютерных наук,
Тюменский государственный университет,
Тюмень, Россия
E-mail: Khrupin24@mail.ru

Предмет исследования: алгоритм адаптивного семантико-ориентированного квантования глубоких нейросетей, обеспечивающий разделимость объектов, имеющих высокую степень визуального сходства.

Цель исследования: разработка алгоритма адаптивного семантико-ориентированного квантования с минимальной потерей точности распознавания объектов трудноразличимых классов и высокой степенью компрессии цифровой реализации.

Методы исследования: численный анализ нормализованной матрицы ошибок идентификации объектов пересекающихся классов. Оценка вклада тензоров весов в разделимость классов в пространстве признаков для определения семантической значимости слоёв нейросети. Гетерогенное распределение разрядности весовых коэффициентов и промежуточных активаций по оценкам параметров кривой кумулятивной чувствительности. Процедура обучения Quantization-Aware Training с селективной фиксацией слоёв детекции.

Объекты исследования: способы компрессии глубоких нейронных сетей компьютерного зрения.

Основные результаты исследования: гетерогенное распределение разрядности с сохранением формата FP32 (Floating Point 32 бита с плавающей запятой) лишь для 29 % семантически значимых слоёв позволяет удерживать точность распознавания (mean Average Precision, mAP@0,5) на уровне 98,6 % от точности базовой, неквантованной модели. Предложенный в работе метод, апробированный на архитектуре YOLOv8n, обеспечивает сжатие модели FP32 в 2,78 раза. При этом на трудноразличимых объектах имеет место превосходство над стандартным подходом PTQ (Post-Training Quantization) и гомогенным QAT (Quantization-Aware Training, обучение с квантованием) по полноте (Recall – доля верно обнаруженных объектов данного класса) и F1-мере (среднее гармоническое точности и полноты в интервале [0,1]).

Ключевые слова: квантование нейронных сетей, смешанная точность, YOLOv8, QAT, PTQ, семантическая значимость, математическая формализация, трудноразличимые объекты.

ADAPTIVE SEMANTICALLY-ORIENTED QUANTIZATION OF DEEP NEURAL NETWORKS

Valeriy A. Shapcev

Doctor of Engineering Science,
Professor of the School of Computer Science,
Tyumen State University,
Tyumen, Russia
E-mail: v.a.shapcev@utmn.ru

Danila S. Khrupin

Postgraduate student of the School
of Computer Science,
Tyumen State University,
Tyumen, Russia
E-mail: Khrupin24@mail.ru

Subject of research: an algorithm for adaptive semantics-oriented quantization of deep neural networks that ensures the separability of objects with a high degree of visual similarity.

Purpose of research: to develop an adaptive semantics-oriented quantization algorithm with minimal loss of recognition accuracy for objects in hard-to-distinguish classes and a high degree of compression in the digital implementation.

Research methods: numerical analysis of the normalized matrix of identification errors for objects of overlapping classes. Evaluation of the contribution of weight tensors to class separability in feature space to determine the semantic significance of neural network layers. Heterogeneous distribution of the bit depth of weight coefficients and intermediate activations based on estimates of the cumulative sensitivity curve parameters. Quantization-Aware Training procedure with selective freezing of detection layers.

Objects of research: methods for compressing deep neural networks in computer vision.

Research findings: a heterogeneous bit-depth distribution, preserving the FP32 (32-bit floating-point) format only for 29 % of semantically significant layers, allows maintaining recognition accuracy (Mean Average Precision, mAP@0.5) at 98.6 % of the accuracy of the baseline, unquantized model. The method proposed in this work, tested on the YOLOv8n architecture, achieves a 2.78-fold compression of the FP32 model. Furthermore, for hard-to-distinguish objects, it outperforms the standard PTQ (Post-Training Quantization) and the homogeneous approach QAT (Quantization-Aware Training) in terms of recall (the proportion of correctly detected objects of a given class) and the F1 score (the harmonic mean of precision and recall, in the range [0, 1]).

Keywords: neural network quantization, mixed precision, YOLOv8, QAT, PTQ, semantic significance, mathematical formalization, hard-to-distinguish objects.

ВВЕДЕНИЕ

Использование глубоких нейронных сетей в системах реального времени на граничных устройствах сопряжено с жёсткими ограничениями по объёму памяти и вычислительной мощности. Квантование – снижение разрядности весов и активаций – является стандартом де-факто для компрессии цифровых моделей [2].

Однако существующие методы (PTQ, QAT), ориентированные на минимизацию средне-квадратичной ошибки тензоров или функции потерь, часто игнорируют семантику целевого множества объектов [1]. За семантику объекта нами принята совокупность пиксельных данных цифрового отображения, отражающая характерные для соответствующего класса визуальные признаки.



В задачах детектирования транспортных средств это приводит к падению точности (до 20 %) распознавания объектов визуально схожих классов. При этом значение метрики mAP (mean Average Precision) по датасету может оставаться приемлемым [8].

Ниже представлен результат исследования оригинального способа квантования, названного нами Semantically-oriented Mixed Precision Quantization (SMPQ). В отличие от эвристических подходов, основанных на чувствительности к шуму квантования [5], SMPQ использует семантическую метрику (см. ниже), определяющую вклад каждого слоя нейросети в разделимость «конфликтующих» классов.

Сравниваемые в работе методы относятся к трём базовым схемам цифрового представления параметров:

- FP32 – базовое 32-битное представление весов и активаций с плавающей запятой, используется как эталон точности;
- INT8 PTQ – пост-тренировочное квантование обученной FP32-модели в 8-битное целочисленное представление по калибровочной выборке;
- INT8 QAT – обучение с имитацией ошибок квантования. В граф вводятся модули FakeQuantize, которые в прямом проходе округляют значения до целевой разрядности, в обратном пропускают градиент, что позволяет адаптировать веса к шуму квантования.

Для адаптивного выбора разрядности развит ряд подходов на основе анализа локальной чувствительности параметров:

- HAWQ [11] и HAWQ-V2 [12] используют верхнее собственное число и след гессиа на функции потерь по весам слоя как меру чувствительности;
- BRECQ [4] минимизирует блочную ошибку реконструкции, аппроксимируя гессиа диагональю информации Фишера;
- ZeroQ [19] генерирует калибровочные данные без доступа к обучающей выборке;
- Fisher-aware квантование [8] адаптирует разрядность по диагонали матрицы Фишера с акцентом на критические категории.

Перечисленные методы оперируют локальными характеристиками тензора весов или функции потерь и не используют структуру межклассовых ошибок выходного пространства модели. Предлагаемый метод SMPQ опирается на нормализованную матрицу ошибок и идентификацию критических пар классов, тем самым переводя оценку значимости слоя из пространства параметров в пространство решений классификатора.

РЕЗУЛЬТАТЫ И ОБСУЖДЕНИЕ

1. Описание метода SMPQ

1.1. Идентификация критических классов

Мы вводим понятие «критическая пара классов», смешение (сходство объектов) которых выше заданного порога.

Проводится количественная оценка ошибочной классификации всех транспортных средств в виде матрицы ошибок $CM \in \mathbb{R}^{K \times K}$, где $\mathbb{R}$ – множество вещественных чисел, K – число классов, на валидационном наборе данных $D_{val} = \{(x_n, y_n)_{n=1}^{N_{val}}\}$, посредством исходной FP32-модели детектирования. Здесь x_n – входное изображение, y_n – метка класса, N_{val} – число пар «изображение – метка».

Пусть $y \in \{0, \dots, K-1\}$ – метка класса, $\hat{y}(x)$ – метка, предсказанная моделью по изображению x . Элемент CM_{ij} матрицы ошибок равен числу объектов класса i , отнесённых моделью к классу j при условии пространственно корректной детекции:

$$CM_{ij} = |\{(x, y) \in D_{val} : (y = i) \wedge (\hat{y}(x) = j) \wedge (IoU(B_{pred}, B_{gt}) \geq T_{IoU})\}|, \quad (1)$$

$$i, j = 0, 1, \dots, K-1,$$

где $|\{\dots\}|$ – мощность множества, $\wedge$ – конъюнкция, $IoU(B_{pred}, B_{gt})$ – метрика Intersection over Union, отображающая степень перекрытия предсказанного B_{pred} и истинного B_{gt} образов объектов (bounding box). В простейшем случае – прямоугольных областей (в 2-мерный вариант образов), задаваемых координатами противоположных вершин $(x_{min}, y_{min}, x_{max}, y_{max})$, включая локализацию обнаруженного объекта:

$$IoU(B_{pred}, B_{gt}) = \frac{|B_{pred} \cap B_{gt}|}{|B_{pred} \cup B_{gt}|} \in [0, 1].$$

Здесь $|B_{pred} \cap B_{gt}|$ – площадь пересечения рамок (образов), $|B_{pred} \cup B_{gt}|$ – площадь их объединения. $IoU = 1$ – полное совпадение рамок, $IoU = 0$ – отсутствие пересечения. $T_{IoU} = 0,5$ – нижний порог для решения о корректной детекции [8].

Таким образом, элемент CM_{ij} – количество примеров из D_{val} , удовлетворяющих трём условиям:

- 1) $y = i$ – истинный класс объекта равен i ;
- 2) $\hat{y}(x) = j$ – модель распознала класс j ;
- 3) $IoU(B_{pred}, B_{gt}) \geq T_{IoU}$ – предсказанная рамка достаточно полно перекрывает истинную.

Объекты, для которых условие IoU не выполняется, исключаются из матрицы ошибок, поскольку анализу подлежат только ошибки классификации, а не локализации. При $i = j$ элемент CM_{ij} отражает верные результаты классификации, при $i \neq j$ – ошибочные.

Для перевода абсолютных частот в вероятностную шкалу выполняется построчная нормализация:

$$\overline{CM}_{ij} = \frac{CM_{ij}}{\sum_{j'=0}^{K-1} CM_{ij'}}, \text{ при условии } \sum_{j'=0}^{K-1} CM_{ij'} > 0,$$

где j' – индекс суммирования по всем классам от 0 до $K-1$, в отличие от фиксированного j в числителе. Элемент $\overline{CM}_{ij}$ представляет собой эмпирическую вероятность ошибочного отнесения объекта класса i к классу j . Условие $\sum_{j'=0}^{K-1} CM_{ij'} > 0$ исключает из анализа классы, не представленные в валидационном наборе.

Сумма элементов каждой строки равна единице:

$$\sum_{j=0}^{K-1} \overline{CM}_{ij} = 1 \forall i \in [0, \dots, K-1].$$

Пара классов (i, j) , $i \neq j$ называется критической, если модель допускает систематические ошибки классификации между ними, обусловленные высоким сходством визуальных признаков. Формальный критерий отнесения пары к критическим задаём условием:

$$(i, j) \in P_{crit} \Leftrightarrow (i \neq j) \wedge (\overline{CM}_{ij} > T), \quad (2)$$

где $P_{crit} \subseteq \{0, \dots, K-1\}^2$ – множество критических пар, T – порог, отделяющий статистически значимое межклассовое смешение от фонового уровня случайных ошибок. Он определяется эмпирически как компромисс между чувствительностью метода к семантическим связям и вычислительной эффективностью. В нашем эксперименте (см. ниже) $T = 0,05$. Снижение порога до 0,01 приведёт к ложному срабатыванию детектора критических пар на случайных флуктуациях измерений. Это необоснованно увеличивает количество слов с FP32, т. е. снизит степень сжатия модели без значимого прироста производительности (mAP). Повышение порога до $T = 0,10$ исключит из анализа пары с частотой ошибочной классификации 5–10 %. Это приведёт к потере пар.

Множество критических классов C_{crit} формируется путём извлечения всех классов, участвующих хотя бы в одной критической паре как в роли истинного класса объекта, так и в роли класса, к которому объект ошибочно отнесён:

$$C_{crit} = \{i: \exists j, (i, j) \in P_{crit}\} \cup \{j: \exists i, (i, j) \in P_{crit}\}. \quad (3)$$

Иными словами, если класс фигурирует в P_{crit} на любой позиции пары – левой или правой, он включается в C_{crit} .

Множество C_{crit} необходимо на следующем этапе для формирования подмножества данных D_{crit} на котором оценивается семантическая значимость компонентов нейросети.

1.2. Оценка семантической значимости компонентов нейросети

Выполним количественную оценку вклада компонента нейросети в корректную классификацию объектов критических классов.

Под компонентом нейросети понимается тензор весов $w_c \in \mathbb{R}_c^d$ свёрточного слоя, где d_c – размерность тензора, $c \in C = \{c_1, c_2, \dots, c_N\}$ – индекс компонента, N – число компонентов. Оценка заключается в измерении чувствительности модели к локальному возмущению компонента посредством их пробного, агрессивного квантования.

Пусть M – исходная модель с полной точностью (FP32), воспринимающая изображение x и возвращающая вектор распознавания $M(x) \in \mathbb{R}^K$. Пусть M'_c – модифицированная модель, в которой веса компонента с подвергнуты агрессивному квантованию до формата INT8 (8-битное целочисленное представление, Integer 8-bit), остальные – сохраняют точность FP32.

Семантическую значимость S_c компонента c зададим как прирост среднего значения функции потерь на критическом подмножестве данных после возмущения:

$$S_c = \mathbb{E}_{(x,y) \in D_{crit}} [L(M'_c(x), y)] - \mathbb{E}_{(x,y) \in D_{crit}} [L(M(x), y)]. \quad (4)$$

• $D_{crit} = \{(x, y) \in D_{val} : y \in C_{crit}\}$ – подмножество валидационных примеров, содержащее изображения, на которых присутствует хотя бы один объект критического класса из множества C_{crit} определённого на этапе 1;

• $L: \mathbb{R}^K \times \{0, \dots, K-1\} \rightarrow \mathbb{R}_{\geq 0}$ – функция потерь задачи детекции. В архитектуре YOLOv8 функция потерь является составной и включает три компонента:

$$L = \lambda_{cls} \cdot L_{cls} + \lambda_{box} \cdot L_{box} + \lambda_{dfl} \cdot L_{dfl}, \quad (5)$$

где L_{cls} – бинарная кросс-энтропия (Binary Cross-Entropy, BCE), применяемая независимо к каждому классу для оценки ошибки классификации [14], L_{box} – потеря на основе полного пересечения по объединению (Complete Intersection over Union, CIoU) [19], количественно оценивающая отклонение предсказанной ограничивающей рамки от истинной с учётом трёх геометрических факторов: площади перекрытия, расстояния между центрами рамок и соотношения сторон, L_{dfl} – Distribution Focal Loss [10] для уточнения распределения координат, а $\lambda_{cls} = 0,5$, $\lambda_{box} = 7,5$, $\lambda_{dfl} = 1,5$ – веса в стандартной конфигурации YOLOv8. При вычислении S_c используется составная функция потерь (5), поскольку квантование компонента влияет и на классификацию, и на точность локализации [5].

• $\mathbb{E}[\cdot]$ – эмпирическое среднее значение функции потерь на подмножестве D_{crit}

Вычисление S_c выполняется итеративно для каждого $c \in C$.

На каждой итерации выполняется следующее:

1. Сохраняются исходные значения весов компонента c .

2. Они квантуются до формата INT8. Квантование значения v при разрядности b и масштабном коэффициенте Δ определяется как:

$$Q(v, \Delta, b) = \text{clip}\left(\text{round}\left(\frac{v}{\Delta}\right), -(2^{b-1} - 1), 2^{b-1} - 1\right) \cdot \Delta, \quad (6)$$

где $\text{round}(\cdot)$ – округление до ближайшего целого, $\text{clip}(z, a, b) = \max(a, \min(z, b))$ – ограничение диапазона, гарантирующее попадание результата в интервал целочисленного представления.

Квантованные значения весов компонента c вычисляются как:

$$w'_c = Q(w_c, \Delta_c, b), \text{ где } \Delta_c = \frac{\max(|w_c|)}{2^{b-1}-1}, \quad (7)$$

где $b = 8$ – целевая разрядность, Δ_c – масштабный коэффициент, определяемый как максимальное значение тензора весов компонента c .

3. Вычисляется значение функции потерь L на D_{crit} для модифицированной модели M'_c , полученной квантованием весов по (7).

4. Исходные значения восстанавливаются (для изоляции эффекта пробного квантования компонента c).

Значение метрики ограничивается снизу нулём: $S_c = \max(0, S_c)$: квантование не должно уменьшать значение функции потерь малыми отрицательными значениями числового шума.

Значения S_c интерпретируются следующим образом:

- $S_c \gg 0$ – высокая семантическая значимость компонента: его «повреждение» существенно увеличивает ошибки на близких классах. Такие компоненты сохраняются при финальном квантовании;

- $S_c \approx 0$ – низкая значимость компонента для различения объектов критических классов. Это допускает в нём агрессивное квантование практически без деградации качества.

Результатом этапа 2 является «карта» (вектор) семантической значимости $S = \{(c, S_c), c \in C\}$ с убывающими компонентами.

1.3. Адаптивное распределение разрядности

Теперь осуществим гетерогенное назначение разрядности компонентам сети на основе значений компонентов S . Основная идея состоит в сохранении высокой точности представления для компонентов нейронной сети, важных для различения семантически близких классов, при одновременном

агрессивном квантовании компонентов с низкой семантической значимостью.

Пусть $C = \{c_1, c_2, \dots, c_N\}$ – множество анализируемых компонентов, упорядоченное по убыванию семантической значимости:

$$S_{c_1} \geq S_{c_2} \geq \dots \geq S_{c_N}.$$

Общая семантическая значимость модели определяется как сумма значимостей всех компонентов:

$$S_{total} = \sum_{i=1}^N S_{c_i}. \quad (8)$$

Кумулятивная семантическая значимость первых k компонентов:

$$S_{cum}(k) = \sum_{i=1}^k S_{c_i}. \quad (9)$$

Точка отсечения k^* определяется как минимальный индекс, для которого кумулятивная значимость превышает заданную долю $\alpha \in (0, 1]$ от общей значимости (8):

$$k^* = \min \{k \in \{1, \dots, N\} : S_{cum}(k) \geq \alpha \cdot S_{total}\}. \quad (10)$$

Гиперпараметр α задаёт долю общей чувствительности модели, которую необходимо сохранить в высокоточном формате FP32 для минимизации деградации на критических классах.

Разрядность $b(c_i)$ для компонента c_i назначается по правилу:

$$b(c_i) = \begin{cases} 32, & \text{если } i \leq k^* \text{ (FP32 — критические компоненты)} \\ 8, & \text{если } i > k^* \text{ (INT8 — избыточные компоненты)} \end{cases}. \quad (11)$$

Этот подход реализует принцип Парето в распределении вычислительных ресурсов: небольшая доля компонентов сохраняется в FP32 для защиты качества на трудноразличимых классах, а основная масса параметров подвергается сжатию до INT8 без существенной потери точности.

На основании (11) получена гетерогенная конфигурация квантования – основы следующей, финальной стадии имитационного квантования с дообучением.

1.4. Финальная стадия

Здесь реализуется адаптация значений весов модели к ошибкам квантования процедурой обучения с учётом квантования (Quantization-Aware Training [16]) – минимизацией модифицированной функции потерь:

$$\min_{\theta} \mathbb{E}_{(x,y) \sim D_{train}} [L(Q_{\Omega}(f_{\theta}(x)), y)], \quad (12)$$

где:

- f_{θ} – параметризованная нейросеть с вектором обучаемых весов θ ;

- $Q_{\Omega}(\cdot)$ – оператор имитационного квантования из формулы (6), применяемый к весам в соответствии с конфигурацией Ω . Масштабный коэффициент Δ_c определяется

автоматически модулями-наблюдателями в ходе обучения;

- D_{train} – обучающий набор данных.

Важное замечание. Выходной слой детекции H_{detect} исключается из этого процесса квантования:

$$\forall c \in H_{detect}: B(c) = 32.$$

Это обусловлено тем, что квантование весов в слоях, отвечающих за предсказание смещений ограничивающих рамок (границ объектов), приводит к систематическому смещению из-за нелинейной зависимости метрики IoU от ошибок координат [17].

2. Результаты экспериментов

В данном разделе представлена валидация предложенного метода SMPQ. Эксперименты позволили проверить гипотезу: сохранение точности FP32 для подмножества семантически значимых слоёв нивелирует падение метрик на критических классах.

2.1. Экспериментальная установка

Архитектура. В качестве базовой модели использована YOLOv8n [7] – наименьшая модель семейства YOLOv8. Число анализируемых свёрточных слоёв (без учёта головы детекции) – 45.

Набор данных. Обучение и тестирование выполнялись на специализированном наборе данных детекции транспортных средств – «MIO-TCD Localization» [13], содержащем 11 классов: Articulated truck, Bicycle, Bus, Car, Motorcycle, Motorized vehicle, Non-motorized vehicle, Pedestrian, Pickup truck, Single unit truck, Work van.

Набор содержит семантически близкие классы (Motorized vehicle / Car, Work van / Car,

Single unit truck / Articulated truck), что обеспечивает наличие межклассовых смещений и делает датасет диагностическим для методов, претендующих на улучшение разделимости трудноразличимых классов.

Сравниваемые методы

1. FP32: исходная модель с 32-битной точностью весов и активаций.

2. INT8 PTQ: стандартное пост-тренировочное квантование с калибровкой на репрезентативной выборке.

3. INT8 QAT: обучение с квантованием, где все обучаемые слои, кроме головы детекции, переведены в INT8.

Гиперпараметры (для INT8 QAT и SMPQ).

Число эпох дообучения – 10. Оптимизатор – SGD (стохастический градиентный спуск, Stochastic Gradient Descent) с моментом 0,937 и weight decay 10^{-4} . Начальная скорость обучения – 10^{-3} . Градиентное ограничение – максимальная норма 10. Предварительный прогрев наблюдателей – 100 батчей. Статистики батч-нормализации заморожены с начала дообучения, диапазоны наблюдателей зафиксированы на двух последних эпохах для стабилизации. Аугментация Mosaic отключена для стабильности QAT [3].

2.2. Протокол эксперимента

1. Инициализация. Обучение модели в формате FP32 на тренировочном наборе данных на 100 эпохах.

2. Идентификация критических классов. Анализ матрицы ошибок (1) для базовой модели выявил наличие устойчивых кластеров ошибочной классификации. В таблице 1 приведены пары, удовлетворяющие критерию (2) при $T = 0,05$.

Таблица 1. Ошибки классификации на валидационном наборе

Истинный класс	Предсказанный	Error, %
Motorized vehicle	Car	33,04
Work van	Car	27,48
Non-motorized vehicle	Motorized vehicle	12,65
Single unit truck	Motorized vehicle	11,09
Bicycle	Pedestrian	9,88
Single unit truck	Articulated truck	9,58
Pickup truck	Car	9,55
Non-motorized vehicle	Articulated truck	6,56

Наибольшая степень смещения наблюдается между «Motorized vehicle» и «Car» (33,04 %), «Work van» и «Car» (27,48 %). Выявлено 8 критических пар, формирующих множество P_{crit} .

Множество C_{crit} определённое по формуле (3), включает 9 из 11 классов. Отсутствуют классы Bus и Motorcycle.

3. Оценка семантической значимости компонентов.

Для каждого слоя рассчитывалась метрика по формуле (4). Оценки чувствительности варьировались от 0 до 0,059. Наибольшую значимость демонстрирует слой $h_{c2f3.cv2.conv}$ – свёрточный слой в модуле C2f третьего уровня головы сети. Из 45

слоёв 18 имеют ненулевую семантическую значимость, 27 слоёв – нулевую. Они избыточны для различения объектов критических классов.

4. Адаптивное распределение разрядности. Значение порога α определено эмпирически по кривой кумулятивной семантической значимости (9) (рисунок 1).




Рисунок 1. Кривая кумулятивной семантической значимости

По (10) – $k^* = 13$ слоёв. Из 45 они аккумулируют 90 % чувствительности модели к искажениям на критических классах. Увеличение α сверх 0,9 приводит к росту числа слоёв, требующих сохранения (в FP32), при незначительном приросте метрик качества. Принято $\alpha = 0,9$. 13 слоёв сохранены в формате FP32, остальные 32 квантованы до INT8.

5. Финальная стадия. Дообучение в соответствии с (12) включило 10 эпох

стохастического градиентного спуска. Начальная скорость обучения – 10^{-3} (5 % от стандартного LR для предотвращения осцилляций квантованных весов). Для стабилизации батч-норм-статистики были заморожены, а диапазоны наблюдателей зафиксированы на 9-й эпохе.

2.3. Сравнительный анализ точности

Сравнительные данные по точности представлены в таблице 2.

Таблица 2. Сравнительная эффективность методов квантования

Метод	Конфигурация точности	mAP@0,5 (все классы)	Δ mAP (vs FP32)	Размер модели (МВ)	Степень сжатия
FP32	W32 / A32	0,7535	-	17,5	1,0x
INT8 PTQ	W8 / A8	0,7344	-2,5 %	5,2	3,36x
INT8 QAT	W8 / A8	0,7359	-2,3 %	5,2	3,36x
SMPQ	Mixed W8/32	0,7428	-1,4 %	6,3	2,78x

*W – weights, A – activation

Из таблицы 2 следует: метод SMPQ обеспечивает лучшее сохранение точности, достигая 98,6 % от mAP@0,5 базовой модели FP32. При этом размер модели (6,3 МБ) превышает полностью 8-битные аналоги только на 21 %, что обусловлено сохранением 13 наиболее чувствительных слоёв в формате FP32.

Время дообучения SMPQ сопоставимо с INT8 QAT при идентичных гиперпараметрах, поскольку процедура QAT применяется к подмножеству слоёв с разрядностью INT8.

Добавочные затраты на этап оценки семантической значимости (этап 2) составляют один проход по D_{crit} для каждого из N компонентов и являются однократными.

2.4. Анализ метрик по классам

Для верификации гипотезы о семантической избирательности метода SMPQ был проведён детальный анализ метрик полноты и F1-меры в разрезе отдельных классов.

В таблице 3 представлены показатели для наиболее сложных классов, выявленных на этапе анализа матрицы ошибок.

Таблица 3. Полнота и F1-мера критических классов

Class	Метрика	FP32	INT8 PTQ	INT8 QAT	SMPQ
motorized_vehicle	Полнота	0,4173	0,3840	0,3650	0,4298
	F1-мера	0,4801	0,4554	0,4518	0,4776
pedestrian	Полнота	0,5593	0,5415	0,5119	0,5366
	F1-мера	0,6278	0,6119	0,6048	0,6195
non-motorized_vehicle	Полнота	0,5606	0,5408	0,5887	0,5549
	F1-мера	0,6067	0,5774	0,5904	0,6080

Абсолютные значения полноты на классах *motorized_vehicle* и *pedestrian* ограничены сложностью самого набора данных и наблюдаются у всех четырёх методов, включая базовую FP32-модель. Целью эксперимента является не демонстрация максимально достижимой точности на этих классах, а проверка сохранения разделимости при сжатии.

Для *motorized_vehicle* метод SMPQ достиг показателей, сопоставимых с базовой моделью, и даже продемонстрировал незначительный прирост, что может быть связано с эффектом регуляризации, вносимым шумом квантования в некритических слоях при сохранении выразительной способности в критических [15].

Метод SMPQ, сохраняя 13 критических слоёв в FP32, обеспечивает достаточное разрешение в пространстве признаков для корректной классификации этих объектов. При этом на классах с высокой репрезентативностью в выборке SMPQ показывает результаты, идентичные FP32, подтверждая, что агрессивное сжатие остальных 32 слоёв не разрушает общие паттерны детекции.

2.5. Анализ кривых

Визуальный анализ кривых «точность – полнота» (рисунок 2) подтверждает выводы, сделанные на основе табличных данных. Кривая предложенного метода (красная пунктирная линия) практически равна кривой FP32.




Рисунок 2. Усредненные PR-кривые

2.6. Ограничения эксперимента

В исследовании не проводились прямые измерения времени инференса. Фокус внимания – теоретическое обоснование семантического распределения весов. Оценка аппаратной задержки планируется в следующих исследованиях. Текущая реализация

основана на модулях FakeQuantize библиотеки PyTorch, для моделирования ошибки округления в процессе QAT, но не для ускорения вычислений на стандартных GPU [14].

Операции квантования и деквантования вводятся в вычислительный граф, однако базовые вычисления выполняются в формате

FP32 [16]. Это приводит к накладным расходам, из-за которых квантованная модель работает медленнее, чем её исходный FP32-аналог. Вследствие этого замеры времени на данной реализации не отражают истинной производительности целочисленной модели и исключены.

ЗАКЛЮЧЕНИЕ И ВЫВОДЫ

Результаты экспериментального исследования подтверждают, что деградация точности распознавания при квантовании детекторов носит структурный характер и локализована в специфических подмножествах весов. Гомогенное сжатие демонстрирует неэффективность в условиях высокого семантического сходства между классами объектов, так как «размывает» признаки классов шумом квантования.

Уступкой метода SMPQ является увеличение объёма модели на 21 % (6,3 МВ против 5,2 МВ у INT8). В контексте архитектуры граничных вычислений оно оправданно.

Итак, метод адаптивного семантико-ориентированного квантования (SMPQ) признаётся эффективным и решает проблему деградации точности классификации нейронных сетей на объектах визуально схожих классов.

СПИСОК ЛИТЕРАТУРЫ

- Хрупин, Д. С. Метод квантования нейронных сетей обнаружения на встраиваемых системах / Д. С. Хрупин, В. А. Шапцев // Научный результат. Информационные технологии. – 2025. – Т. 10, № 4. – С. 72–78.
- A survey of quantization methods for efficient neural network inference / A. Gholami, S. Kim, Z. Dong [et al.] // Low-power computer vision. – London : Chapman and Hall/CRC, 2022. – P. 291–326.
- Bochkovskiy, A. YOLOv4: Optimal Speed and Accuracy of Object Detection / A. Bochkovskiy, C. Y. Wang, H. Y. M. Liao // arXiv. – URL: <https://arxiv.org/abs/2004.10934> (date of access: 20.03.2026).
- BRECQ: Pushing the limit of post-training quantization by block reconstruction / Y. Li, R. Gong, X. Tan [et al.] // arXiv. – URL: <https://arxiv.org/abs/2102.05426> (date of access: 20.03.2026).
- Data-free quantization through weight equalization and bias correction / M. Nagel, M. van Baalen, T. Blankevoort, M. Welling // Proceedings of the IEEE/CVF international conference on computer vision. – Seoul, Korea (South), 2019. – P. 1325–1334.
- Distance-IoU loss: Faster and better learning for bounding box regression / Z. Zheng, P. Wang, W. Liu [et al.] // Proceedings of the AAAI conference on artificial intelligence. – 2020. – Vol. 34, № 7. – P. 12993–13000.
- Explore Ultralytics YOLOv8 – Ultralytics YOLO Docs // ultralytics. – URL: <https://docs.ultralytics.com/models/yolov8/> (date of access: 24.02.2026).
- Fisher-aware Quantization for DETR Detectors with Critical-category Objectives / H. Yang, Y. Huang, Z. Dong [et al.] // arXiv. – URL: <https://arxiv.org/abs/2407.03442> (date of access: 20.03.2026).
- Focal loss for dense object detection / T. Y. Lin, P. Goyal, R. Girshik [et al.] // Proceedings of the IEEE international conference on computer vision. – Venice, Italy, 2017. – P. 2980–2988.
- Generalized focal loss: Learning qualified and distributed bounding boxes for dense object detection / X. Li, W. Wang, L. Wu [et al.] // Advances in neural information processing systems. – 2020. – Vol. 33. – P. 21002–21012.
- HAWQ: Hessian aware quantization of neural networks with mixed-precision / Z. Dong, Z. Yao, A. Gholami [et al.] // Proceedings of the IEEE/CVF international conference on computer vision. – Seoul, Korea (South), 2019. – P. 293–302.
- HAWQ-V2: Hessian aware trace-weighted quantization of neural networks / Z. Dong, Z. Yao, Y. Cai [et al.] // Advances in neural information processing systems. – 2020. – Vol. 33. – P. 18518–18529.
- MIO-TCO: A new benchmark dataset for vehicle classification and localization / Z. Luo, C. Lemarie, S. Li [et al.] // IEEE Transactions on Image Processing. – 2018. – Vol. 27, № 10. – P. 5129–5141.
- PyTorch: An imperative style, high-performance deep learning library / A. Paszke, S. Gross, F. Massa [et al.] // Advances in neural information processing systems. – 2019. – Vol. 32. – P. 1–12.
- QReg: On Regularization Effects of Quantization / M. H. AskariHemmat, R. A. Hemmat, A. Hoffman [et al.] // arXiv. – URL: <https://arxiv.org/abs/2206.12372> (date of access: 20.03.2026).
- Quantization and training of neural networks for efficient integer-arithmetic-only inference / B. Jacob, S. Kligys, B. Chen [et al.] // Proceedings of the IEEE conference on computer vision and pattern recognition. – Salt Lake City, 2018. – P. 2704–2713.
- Reg-ptq: Regression-specialized post-training quantization for fully quantized object detector / Ding Y. et al. // Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. – Seattle, 2024. – P. 16174–16184.
- The pascal visual object classes (voc) challenge / M. Everingham, L. Van Gool, Ch. K. I. Williams [et al.] // International journal of computer vision. – 2010. – Vol. 88, № 2. – P. 303–338.
- ZeroQ: A novel zero shot quantization framework / Y. Cai, Z. Yao, Z. Dong [et al.] // Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. – Seattle, 2020. – P. 13169–13178.

Поступила в редакцию: 31.03.2026

Опубликована: 30.06.2026