

Короткая заметка об интерпретируемости и сознании

2026-04-05

Недавно я опубликовал [пост в блоге](#), в котором размышляю о своей докторской диссертации и ее связи с некоторыми смежными работами по интерпретируемости и законам нейронного масштабирования. На написание этого поста (с перерывами) у меня ушло около полутора лет, и в нем около 15 000 слов. В посте ниже я попытался вкратце изложить суть этого длинного поста. Речь идет о допущениях, которые делают исследователи в области механистической интерпретируемости, и о том, как эти допущения указывают на более глубокую науку — путь, по которому машинное обучение может научить нас чему-то новому и важному о самих себе. Это немного притянута за уши, но, тем не менее, я чувствую, что это указывает на нечто важное и истинное.

Глубокое обучение — это в значительной степени бихевиористский подход. Мы обучаем более крупные нейросети с помощью более совершенных алгоритмов на большем объеме данных и наблюдаем, что *поведение* получаемых сетей меняется, о чем свидетельствует снижение потерь при предварительном обучении и улучшение результатов тестирования. У нас есть надежная эмпирическая наука о том, как поведение сети зависит от различных макроскопических факторов, примером чего могут служить законы нейронного масштабирования¹, исследование временного горизонта METR² и т. д. Все это хорошо и правильно.

Однако, как и некоторые другие специалисты в этой области, я хочу большего. Я хочу, чтобы мы могли что-то сказать о *внутренних* вычислениях, которые нейросети выполняют и которые лежат в основе их поведения. Если языковая модель получает 1,9 ната на кросс-энтропию на корпусе для предварительного обучения, что это говорит о ее внутренних процессах? Как именно она представляет и обрабатывает входные данные? Чем отличаются вычисления в языковой модели, которая получает 1,8 ната на кросс-энтропию? Такой подход предполагает, что мы можем сказать что-то интересное о вычислениях, которые выполняет нейросеть, помимо описания ее архитектуры и распечатки обученных весовых коэффициентов. Он предполагает, что вычисления в нейронных сетях допускают какое-то другое описание, которое является точным и в то же время понятным. Это фундаментальное допущение, лежащее в основе интерпретируемости.

Хотя это предположение может показаться спорным, я считаю, что оно не должно вызывать возражений. По крайней мере, оно не должно вызывать больше споров, чем существование такой области науки, как когнитивистика, которая на протяжении десятилетий пытается описать алгоритмы, эффективно реализуемые биологическими нейронными сетями.³

Так какие же вычисления происходят внутри глубоких нейронных сетей? Для сетей, обученных на реальных данных, ответ может быть очень сложным. Вероятно, существует огромное количество утверждений о том, какие вычисления выполняет большая сеть, которые можно сделать на разных уровнях анализа.

Однако базовое предположение, которое исследователи механистической интерпретируемости выдвигают в своих работах^{4,5,6,7} и которое я подчеркиваю в своих посте, статье⁸ и докторской диссертации, заключается в том, что вычисления, которые выполняют нейросети, какими бы они ни были, состоят из более простых частей. В каком-то смысле большие вычисления, которые выполняют нейросети, состоят из более мелких. Здесь присутствует своего рода *модульность*.

Еще одно ключевое допущение заключается в том, что эти части *разрежены* в данных.² При обработке любых конкретных входных данных для вычислений в сети требуются только некоторые из этих частей, даже если для всего распределения данных нужны все части. Это хорошее предположение, потому что для понимания поведения сети в каждом конкретном случае нам нужно будет изучить только те ее части, которые «активны» в данном примере. Это может быть очень малая часть всей сети, поэтому объем вычислений, которые нам нужно будет выполнить, будет небольшим.

Если принять эти допущения, то вполне естественно изучить, с какой частотой эти различные части сети активируются в зависимости от распределения данных. Обозначим эти частоты f_i . Некоторые вычислительные части могут требоваться сети очень часто, и $f_i \approx 1$, но другие могут быть узкоспециализированными и активироваться крайне редко. Я думаю, это особенно очевидно в случае с языковым моделированием, когда большие языковые модели усваивают огромное количество эзотерических знаний, которые им нужны крайне редко. Можно было бы представить, что мы изучаем распределение частот f_i по всем участкам. Какую форму принимает это распределение? Я думаю, что вполне естественно предположить, особенно для сетей, обученных на языковом материале, где статистика часто подчиняется закону Ципфа, что распределение частот имеет длинный хвост. f_i подчиняются степенному закону.

From this, a model of neural scaling immediately follows. We just need to think about these "parts" not only as things that are instantiated in a specific network but as objects

that live in the data, computations that any network that performs well on that distribution ought to learn. If the frequencies f_i follow a power law, the "importance" of learning each one to the network—the amount by which learning each one reduces the mean loss—will follow the same power law. Networks would optimally learn as many parts as they have capacity for in order of these frequencies. As networks are scaled up and learn a greater number of increasingly niche parts with power-law distributed importance, the mean loss drops as a power law, because integrating under a power law yields another power law.¹⁰ This is where neural scaling laws come from (conjecturally).¹¹

Now what are these parts? Concretely, interpretability has explored several methods now for trying to decompose trained neural networks into sparsely activating parts, like sparse autoencoders. These methods are each very interesting and one could have a detailed discussion about them and the decompositions of networks they provide. But here I'll just say that I wish that the field had some answer to whether there is any notion of a "right" decomposition for a network.^{12,13} Are there "natural units" that we want our interpretability tools to reveal?¹⁴ Again, what are the parts? If we had a satisfying answer to this question, we could measure the empirical frequencies f_i at which these parts are active on the pretraining corpus, watch the parts form over training, and compare the empirical f_i distribution with the slope of the scaling law that we observe on that distribution. But absent a good answer, the model of scaling I've described here isn't really falsifiable. If you gave me some decomposition of a network into parts with frequencies f_i that didn't follow the power law we'd expect, I could just wave my hands and tell you that you didn't correctly decompose the computation of the network. But this is an uncomfortable place to be in.

For the moment though, let's just accept the basic picture that I've described here and that others in the interpretability literature (Chris Olah, Lee Sharkey, etc.) have articulated in varying forms as well, that neural network computation can be decomposed into simpler, sparsely activating parts. What does this say about the world?

Well, if neural networks are learning to reproduce the rules that generated the data they are trained on¹⁵, it may say a great deal. For what generated humanity's corpus of text across history other than the process of human minds thinking? If the computation that language models do when predicting our text can be decomposed into simpler parts, perhaps human minds and human thinking, the process that generated that text, can be similarly decomposed.^{16,17} Our neural scaling laws would then reflect some fundamental fact about the distribution of ideas across minds.

Why then is it a power law? And what does this say about the process by which ideas are created, and are spread?

I get the funny feeling that those who study deep learning and interpretability, and those who study cognitive science and psychology, will turn out, in the end, to have been studying the same object from different sides.

Surely the unification of these fields into a mathematical science of Mind will be the scientific legacy of this century.¹⁸

Thanks to Wes Gurnee, Marmik Chaudhari, Daniel Kunin, Lee Sharkey, Adam Shai, Loren Amdahl-Culleton, and Casper L. Christensen for reading drafts of this post.

Notes and References

1. Kaplan et al. (2020). Scaling laws for neural language models. *arXiv preprint arXiv:2001.08361*. [\[link\]](#) ↵
2. Kwa et al. (2025). Measuring AI ability to complete long tasks. *arXiv preprint arXiv:2503.14499*. [\[link\]](#) ↵
3. Marr, D. (1982). *Vision: A computational investigation into the human representation and processing of visual information*. W.H. Freeman. ↵
4. Olah et al. (2020). Zoom in: An introduction to circuits. *Distill*. [\[link\]](#) ↵
5. Elhage et al. (2022). Toy models of superposition. *arXiv preprint arXiv:2209.10652*. [\[link\]](#) ↵
6. Bricken et al. (2023). Towards monosemanticity: Decomposing language models with dictionary learning. *Transformer Circuits Thread*. [\[link\]](#) ↵
7. Bushnaq et al. (2025). Stochastic parameter decomposition. *arXiv preprint arXiv:2506.20790*. [\[link\]](#) ↵
8. Michaud, E. J., Liu, Z., Girit, U., & Tegmark, M. (2023). The quantization model of neural scaling. *NeurIPS 2023*. [\[link\]](#) ↵
9. Olshausen, B. A. & Field, D. J. (1996). Emergence of simple-cell receptive field properties by learning a sparse code for natural images. *Nature*, 381(6583), 607–609. [\[link\]](#) ↵
10. Marcus Hutter established this idea as a model of where neural scaling laws come from in: Hutter, M. (2021). Learning curve theory. *arXiv preprint arXiv:2102.04074*. [\[link\]](#) ↵
11. Note however that a couple of recent papers challenge the view that neural scaling laws arise from this kind of power law structure in the data. One is [Barkeshli et al. \(2026\)](#), who train transformers on sequence data generated from random walks on a graph where there isn't obvious power law structure, and nevertheless find that their networks exhibit power law scaling. This should make us cautious about inferring too much about the data just from the observation of scaling laws alone. Power law scaling may arise for more generic reasons. In

another work, [Cagnetta et al. \(2026\)](#) give an explanation, with impressive empirical support, of where data scaling law exponents come from. In their model, scaling laws still arise from power laws in the data, but of a different kind than the Zipfian distribution over skills/mechanisms that myself and others have proposed—their theory uses the power-law decay of the n-gram next-token conditional entropy and the power-law decay of the token-token covariances across context. There may be some way of reconciling these theories, but for now I feel that the origin of neural scaling laws is very much an open theoretical question. ↵

12. Sharkey et al. (2025). Open problems in mechanistic interpretability. *Transactions on Machine Learning Research*. [\[link\]](#) ↵
13. Engels et al. (2024). Not all language model features are one-dimensionally linear. *arXiv preprint arXiv:2405.14860*. [\[link\]](#) ↵
14. Hoel, E. P., Albantakis, L., & Tononi, G. (2013). Quantifying causal emergence shows that macro can beat micro. *Proceedings of the National Academy of Sciences*, 110(49), 19790–19795. [\[link\]](#) ↵
15. In order to predict data optimally, networks can learn a computation which is closely related to, but not identical to, the process that generated that data. See [Shai et al. \(2024\)](#) and [Shai et al. \(2026\)](#). ↵
16. Minsky, M. (1986). *The society of mind*. Simon & Schuster. ↵
17. Fodor, J. A. (1983). *The modularity of mind: An essay on faculty psychology*. MIT Press. ↵
18. I like David Bau's framing that our time is a "Copernican Moment" for our understanding of intelligence here:
Bau, D. (2025). In defense of curiosity. *Blog post*. [\[link\]](#) ↵

```
@misc{michaud2026short,  
  author = {Michaud, Eric J.},  
  title = {A short note on interpretability and minds},  
  year = {2026},  
  howpublished = {\url{https://ericjmichaud.com/interp-and-minds/}},  
}
```