


[Вернуться на главную страницу блога](#)

## Исследовательский блог Microsoft

## Архитектура нового поколения устраняет разрыв между нейронными и символическими представлениями с помощью нейронных символов

Опубликовано 12 декабря 2019 г.

Автор [Пол Смоленски](#), партнер-исследовательПоделитесь этой страницей [f](#) [X](#) [in](#) [e](#) [RSS](#)

И в языке, и в математике центральную роль играют символы и их взаимосвязь. Уравнение  $x = 1/y$  утверждает, что символы  $x$  и  $y$ , то есть то, что они обозначают, связаны взаимно обратными отношениями; «*Ким посмотрел фильм*» утверждает, что «*Ким*» и «*фильм*» — это воспринимающий субъект и стимул. Люди в совершенстве владеют языковыми символами и при должном обучении осваивают математические. На протяжении многих десятилетий когнитивная наука объясняла эти способности человека наличием в сознании символов, а исследователи в области искусственного интеллекта имитировали эти способности, создавая сложные машины для обработки символов. Но как дискретные символы и абстрактные связи между ними могут проявляться в нейронных сетях мозга? Стремительный прогресс в области искусственного интеллекта в последнее время стал возможен благодаря замене прежних систем, основанных на символах, принципиально новыми моделями на основе искусственных нейронных сетей, вдохновленными устройством мозга. Есть ли место символам в системах искусственного интеллекта нового поколения?

В [Microsoft Research AI](#) и других лабораториях, занимающихся искусственным интеллектом, были достигнуты значительные успехи в разработке новых типов интеллектуальных систем — нейросимволических моделей ИИ. В нейросимволическом ИИ обработка символов и обучение нейронных сетей взаимодействуют друг с другом. Используя уникальный нейросимволический подход, основанный на математической теории о том, как мозг кодирует и обрабатывает символы, мы в Microsoft Research создаем новые архитектуры ИИ, в которых нейронные сети учатся кодировать и внутренне обрабатывать символы — *нейронные символы*. Нейронные символы, технически известные как [представления тензорных произведений \(Tensor Product Representations, TPR\)](#)®, представляют собой паттерны активации, распределенные по большим группам нейронов. В отличие от стандартных моделей нейронных сетей, эти паттерны имеют особую внутреннюю структуру, которая впервые позволяет нейронным вычислениям обрабатывать их так же, как символы обрабатывались в традиционных системах искусственного интеллекта на основе символов.

Две из этих новых нейронных архитектур — [трансформер с тензорным произведением \(TP-Transformer\)](#) и [тензорное произведение для преобразования естественного языка в формальный \(TP-N2F\)](#) — установили новый стандарт для систем искусственного интеллекта, решающих математические и программные задачи, сформулированные на естественном языке. Поскольку эти модели включают в себя нейронные символы, они не являются полностью непрозрачными, в отличие почти от всех современных систем искусственного интеллекта. Мы можем изучить изученные символы и их взаимосвязи, чтобы понять, как модели достигают таких впечатляющих результатов. Мы представим обе архитектуры на семинарах в рамках [33-й конференции по системам обработки нейронной информации \(NeurIPS\)](#).


## Решение математических задач

Недавно выпущенный [набор математических данных](#) содержит миллионы задач из разных областей, включая алгебру, математический анализ, теорию вероятностей и теорию чисел, вплоть до уровня старшей школы и выше. Каждая задача сформулирована на английском языке и сопровождается решением на английском языке. Чтобы ответ считался правильным, он должен полностью совпадать с ответом из набора данных.

---

### SPOTLIGHT: ИНФОРМАЦИОННЫЙ БЮЛЛЕТЕНЬ MICROSOFT RESEARCH

---



### Информационный бюллетень Microsoft Research

Оставайтесь на связи с исследовательским сообществом Microsoft.

[Подпишитесь сегодня >](#)

---

The TP-Transformer model—the powerful [Transformer](#) architecture enhanced with neural symbols—raised the state-of-the-art overall success level on the dataset from 76 percent to 84 percent. Relative to the previous state of the art, the TP-Transformer outperforms the previous model or performs perfectly in all but one of the 56 mathematical subareas distinguished in the dataset. The following examples of test problems (not seen during learning) from the dataset, along with the (correct) answers generated by our TP-Transformer model, demonstrate the model's capacity to perform multistep inference in number theory, algebra, and calculus:

Suppose  $0 = 2*a + 3*a - 150$ . Let  $p = 106 - 101$ . Suppose  $-3*b + w + 544 = 3*w$ ,  $-p*b - 5*w = -910$ . What is the greatest common factor of  $b$  and  $a$ ?

30

Let  $q(l) = 33*l$ . Let  $a(y) = -y**2 + 2*y - 2$ . Let  $p$  be  $a(1)$ . Let  $d$  be  $q(p)$ . Let  $n = 38 + d$ . Solve  $-5*v - 11 = -3*c - 0*v$ ,  $-4*c = n*v + 32$  for  $c$ .

-3

Let  $r(g)$  be the second derivative of  $2*g**3/3 - 21*g**2/2 + 10*g$ . Let  $z$  be  $r(7)$ . Factor  $-z*s + 6 - 9*s**2 + 0*s + 6*s**2$ .

-(s + 3)\*(3\*s - 2)

The [MathQA dataset](#) also consists of a variety of math word problems, but rather than producing answers in English, here the goal is to produce a simple solution program: a sequence of steps, each a primitive operation, consisting of an operator together with the arguments it applies to. Again, to count as correct, a model's answer must match symbol for symbol the answer provided in the dataset. TP-N2F—a general architecture for taking descriptions in English as inputs and producing outputs in formal languages, such as logic—raised the state-of-the-art success rate from 59 percent to 72 percent.

The following examples of test problems (not seen during learning) and the (correct) answer produced by TP-N2F demonstrate how much English text the model can read and “understand” and how long a program the model can generate:

*this year , mbb consulting fired 6 % of its employees and left remaining employee salaries unchanged . sally , a first – year post – mba consultant , noticed that the average ( arithmetic mean ) of employee salaries at mbb was 10 % more after the employee headcount reduction than before . the total salary pool allocated to employees after headcount reduction is what percent of that before the headcount reduction ?*

(multiply n1 const\_100) (subtract const\_100 n0) (add #0 const\_100) (add #1 const\_4) (multiply #2 #3) (divide #4 #0)

*a high school has 360 students 1 / 2 attend the arithmetic club , 5 / 8 attend the biology club and 3 / 4 attend the chemistry club . 3 / 8 attend all 3 clubs . if every student attends at least one club how many students attend exactly 2 clubs .*

(multiply n0 n1) (multiply n0 n3) (multiply n0 n5) (divide #0 n2) (divide #1 n4) (divide #2 n6) (divide #2 n4) (add #3 #4) (multiply n2 #6) (add #7 #5) (subtract #9 #8) (subtract #10 n0)

TP-N2F was also applied to another problem, generating Lisp programs from English descriptions: the [AlgoLisp dataset](#). Again, the new neurosymbolic model substantially improved the state of the art, from 77 percent to 93 percent. Here is an example of its correct performance, a solution consisting of 55 Lisp commands:

*given numbers a , b , c and e , let d be c , reverse digits in d , let a and the number in the range from 1 to b inclusive that has the maximum value when its digits are reversed be the coordinates of one end and d and e be the coordinates of another end of segment f , find the length of segment f squared*

(digits c) (reverse #0) (\* arg1 10) (+ #2 arg2) (lambda2 #3) (reduce #1 0 #4) (- a #5) (digits c) (reverse #7) (\* arg1 10) (+ #9 arg2) (lambda2 #10) (reduce #8 0 #11) (- a #12) (\* #6 #13) (+ b 1) (range 0 #15) (digits arg1) (reverse #17) (\* arg1 10) (+ #19 arg2) (lambda2 #20) (reduce #18 0 #21) (digits arg2) (reverse #23) (\* arg1 10) (+ #25 arg2) (lambda2 #26) (reduce #24 0 #27) (> #22 #28) (if #29 arg1 arg2) (lambda2 #30) (reduce #16 0 #31) (- #32 e) (+ b 1) (range 0 #34) (digits arg1) (reverse #36) (\* arg1 10) (+ #38 arg2) (lambda2 #39) (reduce #37 0 #40) (digits arg2) (reverse #42) (\* arg1 10) (+ #44 arg2) (lambda2 #45) (reduce #43 0 #46) (> #41 #47) (if #48 arg1 arg2) (lambda2 #49) (reduce #35 0 #50) (- #51 e) (\* #33 #52) (+ #14 #53)

## Under the hood

With neurosymbolic models, we can peer inside and examine the neural symbols learned and the learned relations between them. In the TP-Transformer model, for example, we find that digits in the denominator of a fraction seek to fill one set of relations, while digits in the numerator seek different relations. When processing the input  $2/5 + 3/7$ , we see that to form the ultimate encoding of the symbol 5, a query is issued that looks for a division operator for which 5 is in the denominator; that query matches the first slash.


These observations are just initial steps in the long process of decoding how the TP-Transformer model manages to perform so well on challenging math problems and to explain why it falls short when it does. But these interpretations of the learned relations between neural symbols are immediately evident, so the prospects are good for developing more sophisticated methods to achieve deep understanding of how these models work.

In the TP-N2F model of MathQA solution-program generation, we can examine the vectors that the model learns for encoding, for example, the operators. We find that general-purpose operators like *add*, *negate*, and *log* fall in one region of the vector space, while shape-specific geometric computations such as *square\_area*, *volume\_cylinder*, and *surface\_cube* fall into a different region. At one boundary of the space are *max*, *min*; at another are *factorial*, *choose* (a complex function built from *factorial*). We begin to see how the model has laid out its learned relation space and can start to analyze how that structure supports its success on its task.

## The promise of a fundamental shift

Symbol processing has been a powerful theory of many of the abilities defining human intelligence, and Microsoft Research’s unique approach to neurosymbolic AI promises significant progress in diverse application areas—progress in creating AI systems that not only perform well, but that can also be understood. Such understanding helps us to explain why a model makes the mistakes it does and enables us to go into the bowels of the model and directly alter the activations of neurons to produce a desired change in behavior. This promises a fundamental shift in the way humans interact with AI models.

The TP-Transformer release package, which contains the pretrained models, the source code, and a README document describing step-by-step how to reproduce the results reported in the TP-Transformer paper, is available to the public on [GitHub](#). A similar package for TP-N2F will also be made available on [GitHub](#). We look forward to ongoing dialogue with the research community on the use of neural symbols in AI.



The above figure shows the proportion of unseen problems answered correctly for each type of math problem in the Mathematics Dataset for the previous state-of-the-art model (yellow), for the TP-Transformer trained on the same quantity of data (red; 700K steps), and for the TP-Transformer trained on approximately 2.5 times as much data (blue; 1.7M steps). In all but one subarea, TP-Transformer—a neurosymbolic model—outperforms the previous model or performs perfectly.

Related publications

|                                                                                                      |                                                                                                           |
|------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------|
| <a href="#">TP-N2F: Tensor Product Representation for Natural To Formal Language Generation &gt;</a> | <a href="#">Enhancing the Transformer with Explicit Relational Encoding for Math Problem Solving &gt;</a> |
|------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------|

Meet the authors



**Paul Smolensky**  
Partner Researcher

[Learn more >](#)


Continue reading





September 10, 2025

[RenderFormer: How neural networks are reshaping 3D rendering >](#)



November 27, 2024

[Advances in run-time strategies for next-generation foundation models >](#)



November 25, 2024

[Accelerating drug discovery with TamGen: A generative AI approach to target-aware molecule generation >](#)



July 25, 2024

[Tracing the path to self-adapting AI agents >](#)

[See all blog posts >](#)

#### Research Areas

 Algorithms

 Artificial intelligence

#### Research Groups

Deep Learning Group

#### Related events

Microsoft at NeurIPS 2019

Follow us:      

Share this page:    

#### What's new

Surface Pro

Surface Laptop

Surface Laptop Studio 2

Copilot for organizations

Copilot for personal use

AI in Windows

Explore Microsoft products

Windows 11 apps

#### Microsoft Store

Account profile

Download Center

Microsoft Store support

Returns

Order tracking

Certified Refurbished

Microsoft Store Promise

Flexible Payments

#### Education

Microsoft in education

Devices for education

Microsoft Teams for Education

Microsoft 365 Education

How to buy for your school

Educator training and development

Deals for students and parents

AI for education

## Business

[Microsoft AI](#)

[Microsoft Security](#)

[Dynamics 365](#)

[Microsoft 365](#)

[Microsoft Power Platform](#)

[Microsoft Teams](#)

[Microsoft 365 Copilot](#)

[Small Business](#)

## Developer & IT

[Azure](#)

[Microsoft Developer](#)

[Microsoft Learn](#)

[Support for AI marketplace apps](#)

[Microsoft Tech Community](#)

[Microsoft Marketplace](#)

[Marketplace Rewards](#)

[Visual Studio](#)

## Company

[Careers](#)

[About Microsoft](#)

[Company news](#)

[Privacy at Microsoft](#)

[Investors](#)

[Diversity and inclusion](#)

[Accessibility](#)

[Sustainability](#)

 Your Privacy Choices

[Consumer Health Privacy](#)

[Sitemap](#)

[Contact Microsoft](#)

[Privacy](#)

[Manage cookies](#)

[Terms of use](#)

[Trademarks](#)

[Safety & eco](#)

[Recycling](#)

[About our ads](#)

[© Microsoft 2026](#)