

ПОЗИЦИЯ

28 ИЮЛЯ 2025 ГОДА

Гиганты-универсалы с амнезией — это не будущее языковых моделей

Вам не нужен универсальный гений. Вам нужен специалист, который учится.



Чарльз О'Нил (Базеттен)



Мудит Джаясекара (Басетен)

На днях к нам в Baseten пришел стажер. Он был великолепен. Он знал определения всех компьютерных терминов, которые я когда-либо слышал. Он читал быстрее всех, кого я когда-либо встречал. Он даже выпустил фичу в первый же час (не просто пул-реквест, а полноценный релиз). Он даже поправил мое понимание консенсуса RAFT (вежливо, но все же). Я подумал, что нашел инженера уровня 10x.

Однако примерно через день я понял, что они тоже идиоты. В понедельник утром они идеально справились с заданием, но во второй половине дня мне пришлось объяснять все с самого начала, с теми же подробностями. Они все прекрасно запомнили, но через час болтовни буквально все забыли. В некоторых случаях я мог просто в общих чертах описать, чего я хочу, и они все понимали. Но в других случаях, сколько бы я с ними ни разговаривал и ни объяснял, они отказывались делать так, как я хотел.

Самое главное, что стажер не **учился**.

Конечно, наш стажер — это не человек, а языковая модель от Big Token (вы знаете, о каких компаниях я говорю). Это гигантская модель с полутриллионом параметров, которая, очевидно, обладает самым высоким уровнем интеллекта и сжатия данных, который только можно уместить на одном жестком диске, но, к сожалению, имеет все перечисленные выше недостатки.

OpenAI, Anthropic и Google убедили нас в том, что нужно использовать их большие, дорогие универсальные модели для решения любых задач. Не ищите альтернативы. Не задавайтесь вопросом, зачем вашему врачу-клиницисту та же модель, что пишет стихи. Просто верьте, что обновление в следующем месяце наконец избавит вас от

галлюцинаций, что 320 версий подсказок в Prompteams — это нормальная часть работы, что интеллект в конце концов преодолеет тот факт, что эти модели никогда не обучаются на вашем конкретном примере использования.

На самом деле вы платите 50 тысяч долларов в месяц за модель, которая уверенно сообщает вашим клиентам, что ваша компания была основана в 1742 году (хотя это не так). Вы написали вводное сообщение из 2000 слов с семнадцатью пунктами «ВАЖНО: НИКОГДА НЕ СДЕЛАЙТЕ X», которые перестают работать, как только кто-то задаст немного другой вопрос. Вы беспомощно наблюдаете за тем, как каждое обновление модели (системные подсказки, скрытая тонкая настройка, происходящая за кулисами) приводит к тому, что ваша тщательно настроенная система справляется с вашей конкретной задачей все хуже и хуже. Однажды Anthropic квантует модель, и вся ваша работа оказывается напрасной; OpenAI выходит из строя, и вам остается только беспомощно наблюдать за происходящим.

Вот о чем вам не говорят: GPT-4o может писать на уровне Шекспира, решать дифференциальные уравнения и программировать на 50 языках. Вашему классификатору страховых случаев не нужны ни те, ни другие способности. Миллиарды параметров, предназначенных для генерации хайку, простаивают без дела, пока ваша модель пытается вспомнить, что заявки на сумму более 10 000 долларов требуют одобрения менеджера. По сути, вы нанимаете нобелевского лауреата на должность делопроизводителя.

«Но разве мне не нужна гибкость?» — спросите вы. «Что, если я хочу использовать одну и ту же модель для разных задач?» Давайте начистоту: 80% компаний, использующих большие языковые модели в производственных процессах, применяют их для решения 1–3 основных задач. Вы не создаете искусственный общий интеллект. Вы автоматизируете поддержку клиентов, извлекаете данные из документов или генерируете описания продуктов. Вам нужен специалист, а не универсал, который все забывает в перерывах между разговорами.

Я не думаю, что это аксиома. Я не думаю, что нам нужно жить в таком мире. Я верю в мир, в котором у моделей не будет амнезии, а с каждой попыткой выполнения задач они будут становиться лучше. В мире, где ваша модель узнает, что, когда клиентка Сара из Толедо говорит «как обычно», она имеет в виду товар с артикулом 4829. В мире, где количество ошибок снижается на 73% после трех месяцев непрерывного обучения. Здесь вы можете запустить свою модель даже на одном графическом процессоре (хотя, конечно, при желании можно увеличить их количество). Важно отметить, что здесь вы можете выбрать любую точку на границе Парето, где соотношение стоимости и задержки соответствует производительности, и быть уверенным, что вы действительно находитесь на границе Парето.

Крупные универсальные модели всегда будут востребованы в сфере чат-ботов, с этим не поспоришь. Но сейчас мы видим, как компании решают реальные,

конкретные задачи. Например, клинические стенографисты должны разбираться в медицинской терминологии, а не в древнегреческом языке. Специалисты по выбору страховых полисов должны знать законодательство штата, а не конституционное право. Агенты службы поддержки клиентов должны досконально знать ваш продукт, а не все когда-либо созданные продукты.


Именно это мы и делаем в Baseten. Мы оцениваем вашу задачу, оптимизируем для нее вашу собственную модель и размещаем ее на сервере с функцией непрерывного обучения. Один из наших клиентов сократил ежемесячные расходы на ИИ более чем на 50 %, повысив при этом точность на 64 %. Другой клиент наконец решил проблему «галлюцинаций» после девяти месяцев работы над промтами. Оказывается, если обучать модель исключительно на страховых полисах, она перестанет предлагать несуществующие варианты покрытия.

There's only so much differentiation you can get from your competitors by constructing a better prompt. They can copy your prompt in an afternoon. But a model that's been learning from your specific use case for six months, and that's been optimised on your actual customer interactions, well, that's a real moat.

The future isn't one massive intern that forgets everything between conversations. It's a team of specialists who remember, who learn, who get better at their jobs every single day. While everyone else is still explaining the same task to their amnesiac genius for the thousandth time, your model will have already mastered it, improved on it, and moved on to solving problems you haven't even thought of yet. That's an actual competitive advantage.

Stop paying for Shakespeare when you need spreadsheets. Let's build something that actually learns.

Other research





POSITION

The Michael Scott Paper Company of AI

Open source doesn't need to wait out the frontier labs. It just has to wait out the gap.



POSITION

Continual learning and the post monolith AI era

The cost of continual learning scales with generality.

POSITION

If we can't design neat latent structures, then maybe we can Bitter Lesson it through self-study

They very existence of Claude's Constitution shows that self-study, to a certain extent, just works.



CHARLES O'NEILL

Explore Baseten today

START DEPLOYING

TALK TO AN ENGINEER >

Продукт

Специализированное логическое устройство

API-интерфейсы моделей

Обучение

Frontier Gateway

Baseten Inference Platform

Model Runtimes

Infrastructure

Multi-cloud

Deployment options

Cloud

Self-hosted

Hybrid

Embedded engineering

Forward deployed engineers

Modalities

Transcription

Image Generation

Text-to-speech

Large language models

Compound AI

Embeddings

Industries

Enterprise

Healthcare

Разработчик

Библиотека моделей

Документация

Список изменений

Ресурсы

Research

Customers

Blog

Guides

Events

Partners

Savings calculator

Trust Center

About us

Startups

Careers

Contact us

Popular models

GLM 5.2

Kimi K2.7 Code

DeepSeek V4

GPT OSS 120B

Whisper Large V3

NVIDIA Nemotron 3 Ultra

Explore all

Legal

Terms and Conditions

Privacy Policy

Service Level Agreement

● ALL SYSTEMS NORMAL



© 2026 BASETEN

