

ИССЛЕДОВАНИЕ

11 ФЕВРАЛЯ 2026 ГОДА

Дистилляция без «темного ящика»

Воспроизведение дистилляции на основе политики «черного ящика» в стеке Baseten



Макс Киркби (Baseten)



Чарльз О'Нил (Базеттен)



Мудит Джаясекара (Басетен)

TL;DR

В следующем посте мы воспроизводим результаты Ye et al. (Microsoft Research), которые представили метод дистилляции LLM с помощью генеративной состязательной дистилляции (GAD). GAD - это метод состязательной дистилляции, в котором дискриминатор представляет собой модель вознаграждения в соответствии с политикой, способную совместно развиваться с моделью ученика (обучения), обходя типичные проблемы с помощью контролируемой точной настройки ответов учителя. Здесь мы выделяем Qwen3-4B (обучающуюся модель) из GPT-5.2 с помощью 8xH200s и продукта Baseten Training. Обучение на 20 000 примерах заняло около 10 часов. Мы показываем, что метод работает: дискриминатор учится отличать обучающую модель от обучающейся во время разминки, а обучающаяся модель успешно учится обманывать его во время состязательного обучения без коллапса или «взлома» длины.



Допустим, вы хотите преобразовать модель с закрытым исходным кодом, например GPT-5.2, в модель с открытым исходным кодом, которую можно было бы использовать в собственном стеке. Вы сразу же сталкиваетесь с проблемой: у вас нет необходимых исходных данных для обучения работоспособной модели. Для дистилляции в рамках этой парадигмы требуется процесс, в котором не

используются логиты, скрытые состояния или паттерны внимания. Только текст. Что же делать? *Текущий* подход до смешного прост. Соберите набор пар (запрос, ответ учителя) и дообучите ученическую модель, чтобы она имитировала эти ответы с помощью простого прогнозирования следующего токена. Дистилляция знаний на уровне последовательности (Sequence-level knowledge distillation, SeqKD), как ее называют, просто учит вашу модель копировать ответы учителя. Во время логического вывода ученица должна генерировать текст авторегрессивно, отталкиваясь от собственных префиксов, которые отличаются от префиксов учителя. Это одна из форм сдвига распределения, при которой небольшие ошибки в прогнозировании накапливаются по мере того, как модель все дальше отклоняется от эталонного распределения, на котором она обучалась. Такой режим сбоя хорошо изучен при имитационном обучении. Росс и др., 2011¹

Кроме того, дистилляция «белого ящика» идет еще дальше, вычисляя дивергенцию Кульбака — Лейблера на основе текста, сгенерированного учеником. В этом случае ученик сам генерирует текст, а учитель указывает, что нужно было сделать на каждом этапе. Однако, как всегда, есть одна загвоздка. Если ваш учитель — это модель с закрытым исходным кодом, вы не сможете вычислить $KL(p(\cdot | x) || q\theta(\cdot | x))$ по токенам, потому что у вас нет p (условного распределения учителя по следующим токенам).²

Таким образом, дистилляция сталкивается с проблемой контроля: «вот как выглядит хороший ответ», но при этом очень мало информации о том, почему именно этот ответ является хорошим. Такой подход, возможно, похож на наши предыдущие публикации о iSFT и RGT, в которых мы говорили о том, что разные обучающие сигналы дают разное количество информации. В данном случае существующие методы дистилляции несовершенны.

Учитывая эти проблемы, Йе и соавторы предложили метод генеративно-сопоставительной дистилляции (Generative Adversarial Distillation, GAD). <https://arxiv.org/html/2511.10643v1>³ Авторы переосмыслили эту проблему контроля как задачу моделирования вознаграждения, просто обучив дискриминатор определять, насколько сгенерированный «учеником» контент похож на контент, сгенерированный «учителем». Нужно, чтобы дискриминатор достаточно хорошо различал сгенерированный «учителем» и «учеником» контент, а затем оптимизировать «ученика», чтобы обмануть дискриминатор. Таким образом, дискриминатор становится моделью вознаграждения, которая предоставляет обратную связь по собственным генерациям обучающегося.

Создание модели вознаграждения на основе политики

GAD представляет дистилляцию как минимаксную игру для двух игроков. Учащийся (генератор) вырабатывает ответы на подсказки, а дискриминатор учится отличать результаты работы учащегося от результатов работы учителя. Дискриминатор

инициализируется на основе параметров модели генератора (в нашем примере это (Qwen3-4B)) и дополняется дополнительной головкой прогнозирования, которая проецирует конечное скрытое состояние на скалярную оценку. Оценка последнего токена в последовательности принимается за оценку уровня последовательности. Затем генератор оптимизируется таким образом, чтобы выдавать ответы, которые дискриминатор не может отличить от ответов учителя. Функция ценности для этой игры выглядит так:

$$\max_G \min_D \mathbb{E}_{(x, y_t) \sim \mathcal{T}} \left[-\log \sigma(D(y_t) - D(G(x))) \right]$$

где x — запрос, y_t — ответ преподавателя, $G(x)$ — сгенерированный ответ ученика, $D(\cdot)$ — скалярная оценка дискриминатора, а σ — сигмоидальная функция.

Йе. и соавторы обучают дискриминатор с помощью попарной функции потерь Брэдли-Терри. Получив запрос, ответ учителя и ответ ученика, дискриминатор присваивает каждому из них скалярную оценку и обучается отдавать предпочтение ответу учителя.

$$\min_D \mathbb{E}_{(x, y_t) \sim \mathcal{T}} \left[-\log \sigma(D(y_t) - D(G(x))) \right]$$

This is the same as classical RLHF, but instead of learning human preferences we're detecting likeness to a teacher model. The generator then treats this discriminator score as a reward signal and seeks to maximize it:

$$\max_G \mathbb{E}_{(x, y_t) \sim \mathcal{T}} \left[D(G(x)) \right]$$

The key trick that Ye et al. introduce here is that the discriminator updates during training, thus getting an adaptive reward signal and avoiding reward hacking (on static data a fixed reward model could just find outputs that score highly). Hence, the discriminator and generator co-evolve, yielding a student that gets better at fooling the discriminator and a discriminator that gets better at detecting fakes.

This is analogous to the minimax game in GANs, where the global optimum is reached when the generator matches the data distribution and the discriminator converges to chance-level accuracy (goodfellow citation). This co-evolutionary, on-policy structure also appears in recent self-distillation work: Zhao et al. show that a model can serve as both teacher and student by conditioning on privileged information, replacing the discriminator with a KL-based distillation loss while retaining the insight that adaptive supervision on the student's own generations outperforms just imitation.⁴

The generator and discriminator updates are also not strictly 1:1. The discriminator is updated online after accumulating a batch of rollouts. In our case, we generate 8 student samples per prompt, obtain 8 rewards, and perform 1 discriminator update. This follows the GRPO implementation described by Ye et al.

A note here on warmup (we show our results on this later). If we start the mini-max game from scratch, we get trivial separation of teacher from student. With the student obviously worse than the teacher initially, the generator gets no useful gradient and can't improve. Similarly, if the generator is far stronger than the discriminator, the discriminator struggles to tell apart teacher vs student responses. The fix to this is to therefore warm up both models prior to true adversarial training: SFT the generator on teacher responses (standard seqKD) and then simultaneously train the discriminator to separate teacher from student.

A replication experiment

We replicate GAD on Baseten infrastructure, distilling Qwen3-4B from GPT-5.2 on 8xH200s. Our dataset consists of ~20K (prompt, teacher response) pairs, where teacher responses are sampled from GPT-5.2 with a 1536 token output cap. We matched the core structure of Ye et al., using a discriminator bootstrap (10 steps of discriminator loss with generator frozen), a joint warmup (generator cross-entropy and discriminator for 100 steps) and then the full GAD run. Compared to Ye et al., who distill Qwen2.5-14B on 200K examples across 16xH100s in 30 hours, our smaller-scale setup (Qwen3-4B, 20K examples) fits the full training pipeline on 8 H100s in ~10 hours, with tweaked prompt/response sampling and batch sizing to optimize KV-cache memory and discriminator activations when both models are active simultaneously.

We deviate further from Ye et al. in introducing two further architectural changes. First, during the GAD stage we freeze the discriminator backbone and only update the attached linear head (that scores the last token's hidden state). This keeps discriminator updates cheap enough to stay on-policy. Second, we introduce a warmup sampling cap to the longest teacher response in the batch (plus a small margin) that prevents the student from 'winning' early on by just padding answers. Whilst we haven't validated the explicit utility of these changes, we find that they allow robust and efficient on-policy training on 8xH200s.⁵

In our experiments, we track two things: whether the discriminator stays calibrated during training, and whether the student actually improves beyond the warmup phase.

Warmup dynamics

We first conducted a joint warmup phase over 110 steps (Figure 1 below). The first 10 steps are a discriminator bootstrap, where the generator is frozen and only the discriminator trains to separate teacher from student outputs. The remaining 100 steps are joint warmup,

where the generator trains with cross-entropy on teacher responses while the discriminator continues learning to distinguish between them. This replicates Ye et al.

In doing so, we observe a steady reduction in discriminator loss (a), indicating that the discriminator is learning to separate teacher from student. Similarly, the margin of these 'victories' (b) begins negative (preferring student, guessing wrong) and climbs to reliably prefer the outputs of GPT-5.2. The accuracy of judgments (c) tracks this. By the end of this warmup phase, the discriminator can thereby tell teacher from student well enough to provide a meaningful reward signal for the generator to optimize against in the adversarial phase.




Figure 1: Metrics from joint warmup of generator and discriminator over 110 steps.

RL training

We then run the full adversarial phase for 2400 steps (Figure 2). The discriminator reward (a) increases steadily, indicating the student is successfully learning to fool the discriminator (the outputs are increasingly scored as teacher-like). Indeed, this gradual improvement suggests that the discriminator and generator co-evolve stably. Policy entropy (b) decreases gradually as the student learns what 'teacher-like' looks like, without detectable mode collapse. Similarly, trainer-inference KL (c) is largely within limits and does not exhibit divergence from the reference policy.

Finally, completion length (d) remains stable throughout. This is exciting as it suggests that the student model is not reward hacking by padding outputs. This confirms that the student is producing teacher-like content.



Figure 2: Metrics from Generative Adversarial Distillation (GAD) of Qwen3-4B on 8xH200s over 12 hours.

Evaluations

To measure whether the student actually got better at the task (rather than just fooling our discriminator), we use an LLM-as-a-judge setup similar to Ye et al. For each prompt, we take model outputs and score them with GPT-4o for consistency, accuracy, and relevance. We observe that our GAD-trained model scores higher (a) and consistently (b) beats the warmup-only baseline. The teacher model (GPT-5.2) still scores higher, in line with distilling a 4B model from a much larger one. These results appear comparable to Ye et al.'s findings on Qwen2.5-3B-Instruct distilled from GPT-5-Chat (45.8 baseline, 48.9 trained, 51.7 teacher), evaluated using a normalized ratio from a GPT-4o reference scoring system.




Figure 3: Simple LLM-as-a-judge evaluation of model outputs from warmup and GAD phases vs teacher model

What's next? Our work at Baseten is driven by continuous experimentation in post-training, where probing methods like GAD help surface new infrastructure patterns and training methodologies.

We believe an exciting extension to this replication is self-distillation. That is, can a model teach itself without an external teacher? Recent work from Zhao et al. on On-Policy Self-Distillation suggests that conditioning a model on privileged information and using it to supervise its unprivileged self can eliminate the need for an external teacher model.<https://arxiv.org/abs/2601.18734>⁶ We're exploring whether this can deliver comparable gains to GAD and further enhance the efficiency and accuracy of on-policy distillation.

For attribution in academic contexts, please cite this work as:

Kirkby, Max, Charles O'Neill, and Mudith Jayasekara. "Distillation without the Dark." Baseten Research, February 11, 2026. <https://www.baseten.co/research/distillation-without-the-dark/>

BibTeX citation

```
@misc{kirkby2026distillation,
  author      = {Max Kirkby and Charles O'Neill and Mudith Jayasekara},
  title       = {Distillation without the Dark},
  year        = {2026},
  month       = {February},
  day         = {11},
  institution = {Baseten},
```

```
    howpublished = {\url{https://www.baseten.co/research/distillation-without-  
the-dark/}},  
    note         = {Baseten Research}  
}
```

¹ [Ross et al., 2011](#)

² A workaround to this is training a strong open model to mimic the closed-source teacher from sampled answers (e.g. SeqKD). The open model can then provide token-level supervision on the student's own rollouts (e.g. 235B->32B), which whilst not recovering the true teacher distribution, does provide more information than pure SFT alone.


³ <https://arxiv.org/html/2511.10643v1>


⁴ We note that in both cases stability depends on an implicit trust region: in GAD, GRPO's clipping and KL penalty to a reference policy (Schulman 2017) prevents the generator from outrunning the discriminator, much as asymmetric update rates and gradient penalties keep GAN training convergent?

⁵ You would likely get better results if you trained the full discriminator, but the fact that both discriminator and student improve in tandem is enough empirical evidence that just training the head works.

⁶ <https://arxiv.org/abs/2601.18734>

Other research





RESEARCH

Still: Amortized KV Cache Compaction in a Single Forward Pass

You can shrink a language model's KV cache by 200x, in a single forward pass, and it still answers correctly.



CHARLES O'NEILL • 4 others



Explore Baseten today

START DEPLOYING

TALK TO AN ENGINEER >

Product

- Dedicated Inference
- Model APIs
- Training
- Frontier Gateway

Baseten Inference Platform

- Model Runtimes
- Infrastructure
- Multi-cloud

Deployment options

- Cloud
- Self-hosted
- Hybrid

Embedded engineering

Forward deployed engineers

Modalities

- Transcription
- Image Generation
- Text-to-speech
- Large language models
- Compound AI
- Embeddings

Industries

- Enterprise
- Healthcare

Developer

- Model library
- Documentation
- Changelog

Resources

- Research
- Customers
- Blog
- Guides
- Events
- Partners
- Savings calculator
- Trust Center
- About us
- Startups
- Careers
- Contact us

Popular models

- GLM 5.2
- Kimi K2.7 Code
- DeepSeek V4
- GPT OSS 120B
- Whisper Large V3
- NVIDIA Nemotron 3 Ultra
- Explore all

Legal

- Terms and Conditions
- Privacy Policy
- Service Level Agreement

● ALL SYSTEMS NORMAL

