

ИССЛЕДОВАНИЕ

8 МАЯ 2025 ГОДА

Замечают ли трансформеры собственные ошибки? Обнаружение линейного детектора галлюцинаций в больших языковых моделях

Линейный сигнал в больших языковых моделях выявляет галлюцинации, обнаруживается «замороженным» наблюдателем и корректируется с помощью одного вектора.



Мудит Джаясекара (Басетен)



Чарльз О'Нил (Базеттен)



Макс Киркби (Baseten)



Святослав Чалнев (независимый)



Руне Чи Чжао (Австралийский национальный университет)

ЧИТАТЬ БУМАГУ

Большие языковые модели могут писать красивую прозу, переводить с одного языка на другой и даже генерировать код. Но у них есть любопытная склонность к «галлюцинациям» — они уверенно заявляют о вещах, которые звучат правдоподобно, но не подкреплены контекстом, в котором они были получены, или даже являются неверными с фактической точки зрения. Это серьезное препятствие для их использования в конфиденциальных приложениях. Когда модель незаметно вставляет утверждение, которое не подкреплено контекстом, в котором она была получена, осознает ли она в каком-то смысле, что *вышла за рамки* сценария? А может ли другой ИИ, выступающий в роли внимательного наблюдателя, заметить это?

В нашей новой статье мы исследуем, как отдельная модель «наблюдателя» может выявлять такие контекстуальные «галлюцинации». Этот «наблюдатель» читает весь текст (начальный контекст + продолжение) и за один проход определяет, является

ли продолжение неподтвержденным. Простой линейный сигнал в активациях «наблюдателя» надежно выявляет неподтвержденные утверждения. Мы проанализировали около 1000 примеров из XSum и CNN/Daily Mail и представляем **ContraTales**: 2000 миниатюрных историй, которые заканчиваются намеренным логическим противоречием.

Взгляд наблюдателя: новый способ распознавать галлюцинации

Представьте себе человека, который вычитывает текст: он читает весь документ, а затем спрашивает: «Логично ли окончание?» Наша «парадигма наблюдателя» аналогична этому. Мы берем стандартный трансформер (например, Gemma-2), убеждаемся, что он не участвовал в создании текста, и передаем ему весь документ. Затем мы спрашиваем: исходя из его внутреннего состояния, считает ли он последнюю часть текста галлюцинацией?

Эта настройка не зависит от генератора (нет необходимости в исходных внутренних компонентах модели) и выполняется за один прямой проход, что делает ее эффективной.

Линейная подсказка для галлюцинаций

Мы предположили, что внутреннее представление галлюцинации в модели наблюдателя может быть линейным. Мы проверили эту гипотезу, обучив линейную модель (логистическую регрессию) на остаточных активациях наблюдателя в конце потенциально галлюцинаторного предложения.




Рисунок 1: Развертка по слоям. Однократное линейное исследование (логистическая регрессия) достигает $> 0,95 F_1$ на слоях 12-30 для новостных данных и $> 0,70$ для логических противоречий.

На рисунке 1 видно, что эти линейные пробники показывают хорошие результаты, достигая высоких значений F_1 (до 0,99 при тестировании на новостных источниках). Эта способность присуща не только одному «волшебному» слою, а является

устойчивым представлением в остаточном потоке модели. Производительность резко возрастает на ранних слоях, а затем выходит на плато на средних и поздних слоях, что говорит о том, что представление «контекстуальной поддержки» формируется и стабильно присутствует в модели.

Превосходит эвристические методы, особенно в сложных логических задачах

Чем этот линейный метод поиска отличается от других методов обнаружения? Мы сравнили его с лексическим совпадением, верификацией сущностей, анализом семантической схожести и анализом паттернов внимания (например, [Lookback Lens](#)¹⁾).





Рис. 2. Сравнение базовых показателей. Эвристика остаточного потока превосходит эвристику перекрытия, сущности, сходства и внимания на 5–27 баллов по шкале F_1 .

Наш линейный метод (рис. 2, крайняя правая колонка в каждой группе) превосходит эти базовые методы на 5–27 баллов по шкале F_1 . Особенно заметна разница в тестах ContraTales, где противоречия чисто логические (например, «Джек лысый... Джек пошел стричься»). Здесь поверхностные подсказки не работают, но линейный метод показывает хорошие результаты (0,84 F_1 при использовании нашего самого крупного наблюдателя).

Последовательная и универсальная «ось галлюцинаций»

Это «направление, определяющее галлюцинации», — не причуда.

- **Across Model Sizes:** The layer-sweep pattern (Figure 1) is consistent across Gemma-2 models (2B to 9B parameters).
- **Across Datasets:** A linear probe trained on one news corpus transfers well to another with minimal performance drop.




Cross-domain transfer. Probes trained on one news corpus retain $> 0.90 F_1$ when evaluated on another, while surface heuristics halve in accuracy.

Figure 3 shows this transferability. While lexical cues degrade when styles change (e.g., Train XSum → Test CNN/DM), the linear probe remains robust, suggesting it captures a fundamental representation of contextual consistency.

What Part of the Observer's "Brain" Tracks Hallucinations?

If a linear direction signifies hallucinations, which transformer components represent it? We used gradient-times-activation attribution to trace the probe's decision. The signal isn't diffuse nor primarily in attention heads. Instead, a sparse, consistent cluster of MLP (feed-forward) blocks in late-middle layers appears key.




MLP attributions. Only layers 7–9 make systematic contributions to the hallucination logit (legend range e.g., $-0.3 \dots +0.3$); heads show no consistent pattern.

Figure 4 shows that for a probe on layer 10 of Gemma-2-9B, MLP blocks in layers 7 and 8 consistently push the representation towards "hallucination" (positive attribution), while layer 9 pushes away (negative attribution). This {positive → strong-positive → negative} MLP triplet recurs across all tested datasets, indicating a compact, responsible sub-circuit.

Is This Representation Causal? Can We Steer a Generator?

To test causality, we injected the normalized 'hallucination vector' into a generator's residual stream while it wrote summaries (known as *steering*).




Causal steering. Scaling the hallucination axis modulates hallucination (black) and repetition (green) rates in opposite directions. (Figure ideally shows two y-axes and 95% CI bands)

Figure 5 shows a monotonic trade-off: steering with $\alpha=+60$ increases the hallucination rate to 0.86, while $\alpha=-60$ results in a 0.35 rate (a 51 percentage point swing across this range). This demonstrates that the linearly decodable direction is an actionable control knob.

Sharpening the Signal: Finetuning Helps

Can an observer's detection be improved without new hallucination labels? We lightly finetuned observer models on *only correct* (non-hallucinated) text from the ContraTales domain.² This involved two epochs of SFT (AdamW, LR 1×10^{-5} , context 512, batch 64).



Domain Adaptation. Two-epoch SFT on 1k correct ContraTales examples lifts probe F_1 by 0.10–0.17.]

Figure 6 shows this unsupervised domain adaptation improved the linear probe's F_1 score upon retraining. For Gemma-2-9B on ContraTales, F_1 jumped from 0.75 to 0.89. Exposure to coherent text sharpens the model's internal representation of supported statements. Most experiments fit on a single 48 GB H100 GPU; finetuning used 8xH200 GPUs (wall-clock time typically under an hour), and steering experiments also benefited from multiple GPUs for latency.

Why This Matters

- **Generator-Agnostic Detection:** Our work demonstrates a simple, single-pass method to detect contextual hallucinations without needing access to the generating model's internals.
- **Linearity of Complex Concepts:** It shows that a complex property like "contextual support" can be robustly represented along a single linear direction in activation space.
- **Causal Control:** The identified direction is not just correlational but can be used to causally influence a generator's tendency to hallucinate.

Limitations & Future Work

Our probe handles single-span contradictions; multi-hop reasoning and world-knowledge gaps remain unsolved.

1. **Persistent Challenges:** Some subtle logical contradictions still evade this linear probe.
2. **Scope:** Current work focuses on single-sentence contradictions; multi-span or more distributed hallucinations are an area for future research.
3. **Circuit Detail:** What computations are these specific MLP layers performing?
4. **Non-linear Components:** How do non-linear aspects of the model's representation contribute to understanding consistency?

To help accelerate research, we release the 2,000-example ContraTales benchmark.

For attribution in academic contexts, please cite this work as:

Jayasekara, Mudith. "Do Transformers Notice Their Own Mistakes? Finding a Linear Hallucination Detector Inside LLMs." Baseten Research, May 8, 2025.

<https://www.baseten.co/research/do-transformers-notice-their-own-mistakes/>


BibTeX citation

```
@misc{jayasekara2025hallucination,  
  author      = {Jayasekara, Mudith},  
  title       = {Do Transformers Notice Their Own Mistakes? Finding a Linear  
Hallucination Detector Inside {LLMs}},  
  year        = {2025},  
  month       = may,  
  day         = {8},  
  howpublished = {Baseten Research},  
  url         = {https://www.baseten.co/research/do-transformers-notice-  
their-own-mistakes/},  
}
```

¹ For example, [Lookback Lens](#) (Chuang, 2024). See paper for full citations of baseline methods.

² In the domain adaptation experiments, the observer model itself is finetuned, departing from the "frozen observer" premise of other sections. The linear probe is then retrained on this modified observer.

Other research



RESEARCH

Post-Training Science for Supervised Fine-Tuning

How the optimal learning rate and batch size move with model scale, family, and data, and whether one selection rule transfers across them.



CHARLES O'NEILL • 2 others



RESEARCH

Still: Amortized KV Cache Compaction in a Single Forward Pass



RESEARCH

Post-training frontier legal agents with Baseten Research

Post-training a 27B open-weight model to the frontier on Harvey LAB with Baseten Research



CHARLES O'NEILL • 5 others

Explore Baseten today

START DEPLOYING

TALK TO AN ENGINEER >

Продукт

Специализированное логическое устройство

API-интерфейсы моделей

Обучение

Frontier Gateway

Платформа логического вывода Baseten

Исполняемые среды моделей

Инфраструктура

Мультиоблако

Варианты развертывания

Облачное

Собственное

Гибридное

Встраиваемая инженерия

Инженеры , развернутые на переднем крае

Модальности

- Транскрипция
- Генерация изображений
- Преобразование текста в речь
- Большие языковые модели
- Комплексный ИИ
- Эмbedding

ОТРАСЛИ

- Предприятие
- Здравоохранение

Разработчик

- Библиотека моделей
- Документация
- Список изменений

Ресурсы

- Исследования
- Клиенты
- Блог
- Руководства
- Мероприятия
- Партнеры
- Калькулятор сбережений
- Центр доверия
- О нас
- Стартапы
- Вакансии
- Контакты

Популярные модели

- GLM 5.2
- Kimi K2.7 Code
- DeepSeek V4
- GPT OSS 120B
- Whisper Large V3
- NVIDIA Nemotron 3 Ultra
- Посмотреть все

Юридическая информация

- Правила и условия
- Политика конфиденциальности
- Соглашение об уровне обслуживания

● ВСЕ СИСТЕМЫ В НОРМЕ



