

ДОЛЖНОСТЬ

26 ЯНВАРЯ 2026 ГОДА

Если мы не можем создать аккуратные латентные структуры, то, возможно, мы сможем постичь этот горький урок через самоанализ

Само существование «Конституции Клода» показывает, что самоанализ в определенной степени работает.



Чарльз О'Нил (Базеттен)

Теперь у Антропа есть [Конституция для Клода](#). В описании говорится:

«Устав Клода» — это подробное описание того, какими должны быть ценности и поведение Клода с точки зрения компании Anthropic. Он играет важнейшую роль в процессе обучения, и его содержание напрямую влияет на поведение Клода. Он также является окончательным воплощением нашего видения Клода, и мы стремимся к тому, чтобы все остальные наши рекомендации и программы обучения соответствовали ему.

Это означает, что Claude обучается на основе Конституции США. Но если вы хорошо разбираетесь в языковых моделях, то, вероятно, за этим кроется нечто большее. Когда вы обучаете языковую модель на каком-либо документе, она не просто запоминает его. Ей приходится сжимать вероятность появления этих токенов, одного за другим, в весовые коэффициенты — процесс, сильно отличающийся от кратковременной памяти без потерь в кэше KV. И даже если бы Anthropic включала Конституцию в обучающие данные десятки тысяч раз, даже если бы Claude выучил весь документ наизусть, он не обязательно *стал бы действовать иначе*.

Хорошим примером этого является обнаруженная на раннем этапе особенность предварительного обучения: даже если в обучающих данных встречалось выражение «Сократ был учеником Платона», модель не могла ответить на вопрос «Кто был учителем Сократа?». И это несмотря на то, что модель прекрасно справлялась с воспроизведением определений понятий «учитель» и «ученик». В чем же была проблема? Что ж, минимизация отрицательного логарифмического правдоподобия следующего токена просто не привела к целостному скрытому представлению необходимых понятий. Модель не смогла ответить, что Платон был учителем Сократа, потому что не смогла установить скрытую связь между «X — учитель Y» и «Y — ученик X».

Я думаю, это указывает на фундаментальную особенность языковых моделей. Чтобы научиться аппроксимировать скрытые знания, нужно обработать такой огромный объем данных, чтобы охватить все возможные варианты. В приведенном выше примере нам потребовалось бы много раз услышать фразы «X — учитель Y» и «Y — ученик X», чтобы усвоить закономерность «если A — ученик B, то B — учитель A» и научиться распознавать различные поверхностные формы, которые могут выражать это отношение.

Вероятно, люди мыслят совсем по-другому, используя латентное кодирование этих понятий и правильные латентные связи для их объединения. Мы не ограничены в использовании субслов в качестве единственного средства мышления, хотя некоторые могут возразить, что языковые модели на основе остаточного потока тоже не ограничены. Мы мыслим образами, иерархиями, смутными ощущениями и *латентными понятиями*.

Зачем я все это описываю? Потому что, на мой взгляд, это дает фундаментальное представление о языковых моделях и, следовательно, о будущем формирования моделей. Мы все согласимся с тем, что Claude демонстрирует сильную интернализацию своих ценностей и моделей поведения. А как было сказано выше, сильная интернализация не возникает при многократном чтении данных, если они представлены в исходном виде. Так чего же не хватает?

Полагаю, в Anthropic уже рассказали нам, чего не хватает, и сделали это еще в 2021 году. В Anthropic уже давно занимаются конституционным выравниванием, то есть используют некую «конституцию» для улучшения ответов модели, а затем проводят контролируемую доработку этих улучшенных ответов (наряду с обучением с подкреплением на основе предпочтений). Это говорит о том, что при наличии непрерывного процесса управляемой обратной связи, основанного на «латентном» факторе (в данном случае «латентным» фактором является Конституция), вы можете неявно, посредством сопоставления с образцом и закона больших чисел, в какой-то степени усвоить этот «латентный» фактор. Это и было изначальным конституционным подходом, и «Антроп», вероятно, до сих пор использует его в той или иной форме.

Но я думаю, что есть более наглядный подход к изучению этих скрытых закономерностей. CARTRIDGES предлагает процедуру самообучения, при которой модель не просто анализирует документ, а генерирует синтетические пары вопросов и ответов и диалоги _о_ содержании, по сути, задавая себе вопросы с разных сторон. Затем это используется в качестве обучающего сигнала для систематизации знаний в компактном хранилище.

Связь с конституционной интериоризацией должна быть очевидной: самообучение заставляет модель сталкиваться с одними и теми же базовыми понятиями в различных лингвистических вариациях. Если конституционный ИИ неявно создает эти вариации посредством итеративного совершенствования и обратной связи, то CARTRIDGES делает этот механизм явным. Вы *создаете* разнообразные представления, необходимые для латентного сжатия. Модель не просто считывает информацию «X — ученик Y», а задает вопросы: «Кто учил X?», «Какова была роль Y?», «Перечислите наставников X», — пока реляционная структура не будет полностью закодирована.

So I imagine Anthropic is doing something similar. They have certain behaviors they want Claude to exhibit, explicitly spelled out in the Constitution, and self-study is used to embed these behaviors into the model. It's clear that Anthropic does this remarkably well; there have been many comments about how Claude feels like it has a "soul", thanks in large part to Amanda Askell and her work on personality shaping, in a way that distinguishes it from other LLMs. This also has implications for capability enhancement. I could imagine some form of self-study working for improving humanities-based tasks like essay writing, philosophy, and deep thought.

A final observation: my work at Parsed, and now at Baseten, on finetuning and post-training specialization has, in a funny way, converged toward this same insight. Initially, we developed Iterative SFT (iSFT) as a way to take a Constitution of sorts (i.e. our evals) and teach a model to improve at those evals by fine-tuning it on data refined with the evals as guide, similar to Constitutional Alignment.

We then developed Rationale-Guided Thinking (RGT) as a way to make the "latents" we were trying to learn more explicit, rather than hoping the model would learn them through imitating shadows on Plato's cave of perfect dances. Our next direction is making the model itself generate its own critiques, evaluations, and reformulations, i.e. its own self-study. This will make everything much more on-policy, which we speculate can only be a good thing.

So I think the takeaway isn't in the Constitution Anthropic released, but in the very fact they acknowledged its existence. Because it tells us they are still doing some form of constitutional alignment, which tells us it remains worth doing in Anthropic's highly optimized training setup, which tells us that self-study, to a certain extent, just works.

Other research



POSITION

The Michael Scott Paper Company of AI

Open-source doesn't need to wait out the frontier labs. It just has to wait out the gap.



CHARLES O'NEILL






POSITION

A letter to the C-suite: the shifting role of MLEs

Your MLEs are brilliant, but you're giving them the wrong job.



CHARLES O'NEILL • 1 other

Explore Baseten today

START DEPLOYING

TALK TO AN ENGINEER >

Product

Dedicated Inference

Model APIs

Training

Frontier Gateway

Baseten Inference Platform

Model Runtimes

Infrastructure

Multi-cloud

Deployment options

Cloud

Self-hosted

Hybrid

Embedded engineering

Forward deployed engineers

Modalities

Transcription

Image Generation

Text-to-speech

Large language models

Compound AI

Embeddings

Industries

Enterprise

Healthcare

Developer

Model library

Documentation

Changelog

Resources

Research

Customers

Blog

Guides

Events

Partners

Savings calculator

Trust Center

About us

Startups

Careers

Contact us

Popular models

- GLM 5.2
- Kimi K2.7 Code
- DeepSeek V4
- GPT OSS 120B
- Whisper Large V3
- NVIDIA Nemotron 3 Ultra
- Explore all

Legal

- Terms and Conditions
- Privacy Policy
- Service Level Agreement

● ALL SYSTEMS NORMAL

