


24 июня 2026 года Компания

OpenAI и Broadcom представили чип для логического вывода, оптимизированный для больших языковых моделей

[▶ Прослушать статью](#) 7:07[🔗 Поделиться](#)

- Предварительные испытания показали, что ускоритель первого поколения обеспечит значительно более высокую производительность на ватт по сравнению с современными аналогами
- Создан с нуля для современных и будущих больших языковых моделей в различных отраслях
- Разработан за девять месяцев, от проектирования до производства, с использованием моделей OpenAI
- Расширяет полнофункциональную платформу OpenAI — от продуктов до моделей, а теперь и до чипов
- Будет развернут в центрах обработки данных в гигаваттном масштабе в течение нескольких поколений

Сегодня компании OpenAI и Broadcom (NASDAQ: AVGO) представили Jalapeño — первый интеллектуальный процессор OpenAI: ускоритель, созданный в соответствии с видением OpenAI будущего логического вывода больших языковых моделей, и первый ускоритель искусственного интеллекта на вычислительной платформе нового поколения, которую компании разрабатывают совместно, чтобы



Генеральный директор OpenAI Сэм Альтман и президент компании Грег Брокман получили в подарок от президента и генерального директора Broadcom Хока Тана и президента Чарли Кавваса перчик халапеньо. Это важный шаг в реализации стратегии OpenAI по созданию полного стека технологий для своих моделей и продуктов.

Компания OpenAI разработала чип с нуля, опираясь на глубокое понимание основ больших языковых моделей, а также на дорожную карту развития моделей, ядер, обслуживающих систем и потребностей в продуктах. Партнеры OpenAI, компании Broadcom и Celestica, помогли внедрить платформу в производство, разработав чип, плату, интегрировав их в стоечную систему, обеспечив высокопроизводительную сетевую связь и масштабируемые производственные системы. Чип Jalapeño спроектирован таким образом, чтобы его можно было использовать со всеми большими языковыми моделями, опираясь на знания OpenAI о потребностях в логическом выводе для существующих и будущих моделей искусственного интеллекта в отрасли. Инженерные образцы чипа Jalapeño

OpenAI

Несмотря на то, что OpenAI еще не определилась с окончательной производительностью, предварительные испытания показывают, что Jalapeño будет значительно превосходить современные аналоги по соотношению производительности на ватт. Подробный технический отчет о производительности будет представлен в ближайшие месяцы. Архитектура сокращает объем перемещаемых данных и распределяет вычислительные ресурсы, память и сетевые ресурсы таким образом, чтобы фактическая производительность была максимально приближена к теоретической пиковой производительности. Кремниевая реализация и сетевые технологии Broadcom, в том числе сетевой процессор Tomahawk, помогают вывести платформу на крупносерийное производство.

“The world is moving to a compute-powered economy,” said Greg Brockman, President and Co-Founder of OpenAI. “Jalapeño is part of our long-term full-stack infrastructure strategy to make compute more abundant, resulting in AI which is faster, more reliable, more affordable for people and businesses, and can be used to solve more important problems. By designing more of the stack ourselves, we can serve more intelligence with greater efficiency and keep pushing advanced AI toward broader access.”

“Jalapeño was designed from the ground up for LLM inference using detailed insights from our close collaboration with OpenAI researchers,” said Richard Ho, who leads OpenAI’s hardware program. “We optimized the architecture around the kernels, memory movement, networking, and serving patterns that matter most for frontier AI models. Based on early testing, Jalapeño will efficiently execute our most important workloads close to the hardware’s theoretical limits.”

“Our collaboration with OpenAI represents a fundamental commitment to scaling the physical infrastructure required for the next decade of AI,” said Hock Tan, President and CEO, Broadcom. “This is just the beginning of a multi-generation roadmap. By co-developing our industry-leading silicon directly with OpenAI, we are enabling the deployment of gigawatt scale data centers with Microsoft and other partners beginning in 2026.”

Designed to be the best inference platform for LLMs

Jalapeño is a blank-slate design for modern LLM inference, not a general-purpose accelerator adapted from earlier AI workloads. It is informed by the systems OpenAI runs every day across ChatGPT, Codex, the API, and future agentic products, while also being designed for current and future LLMs across the industry. The goal is to combine the power and throughput of today's leading AI accelerators with latency closer to the fastest specialized inference systems, making Jalapeño well suited for interactive LLM products at scale.

That is the full-stack advantage. OpenAI is not only developing frontier models or building products on top of them; it is designing the infrastructure underneath them: chip architecture, kernels, memory systems, networking, scheduling, deployment systems, and product experience. Because OpenAI operates across the stack, each layer can be optimized around the same goal: making its models faster, more reliable, and more affordable for users.

Jalapeño strengthens the flywheel behind OpenAI's progress. Better infrastructure drives compute efficiency. Greater compute efficiency enables better training and serving, ultimately powering more capable AI models. Better models become better products for people, developers, and businesses. Better products drive more usage, more customers, and more revenue, which lets OpenAI reinvest in the next generation of infrastructure. Over time, that cycle helps make intelligence more capable, more reliable, and less expensive for everyone.

Nine-month tape-out, accelerated by OpenAI models

Jalapeño was co-developed from initial design to manufacturing tape-out in just nine months, and the custom AI accelerator program represents what we believe to be the fastest ASIC development cycle ever achieved in high-performance advanced semiconductors. That speed reflects deep software-hardware co-development with OpenAI's engineering teams, Broadcom's silicon implementation expertise, and the use of OpenAI models to accelerate parts of the design and optimization process.

OpenAI

future models. If AI can help engineers design better chips faster, it can lower the cost of compute across the industry and help democratize access to advanced AI.

Building a multi-generation platform with partners

Jalapeno is the first step in a multi-generation compute platform designed for initial deployment by the end of 2026 and expanding in the years ahead, combining OpenAI-designed accelerators with Broadcom silicon implementation, networking, and connectivity technologies; and Celestica's board, rack, and system expertise.

Making advanced AI more broadly available

The point of this work is simple: inference is where AI reaches people. Every improvement in cost, speed, and reliability can show up as a faster ChatGPT answer, a Codex task that can take more steps with less waiting, an API product that is cheaper to build, or more dependable access when demand is high.

Democratizing AI means making advanced models available, dependable, and affordable enough for more people to use every day. Jalapeno helps OpenAI turn more of its infrastructure into useful intelligence for students, developers, small businesses, researchers, enterprises, and anyone trying to learn, create, or solve hard problems.

2026


Author

OpenAI



How agents are transforming work

Company Jun 25, 2026



Daybreak: Tools for securing every organization in the world

Security Jun 22, 2026



Samsung Electronics brings ChatGPT and Codex to employees

Company Jun 21, 2026

Research	Products	Business	Company	More
Research Index	ChatGPT ↗	Overview	About Us	Stories
Research Overview	ChatGPT Business ↗	Solutions	Our Charter	Academy
Economic Research	ChatGPT Enterprise ↗	Resources	Careers	Livestreams
		Contact Sales	News	Podcast
Latest Advancements	ChatGPT for Education ↗	Developers	Support	RSS
GPT-5.5	Codex	Apps SDK ↗	Help Center ↗	Terms & Policies
GPT-5.4	Release Notes	Open Models		Terms of Use
GPT-5.3 Instant		Docs ↗		Privacy Policy
	API Platform	Resources ↗		Other Policies
Safety	Overview	Developer Forum ↗		
Safety Approach	API Log In ↗			
	Docs ↗			

