



ИССЛЕДОВАНИЕ

27 МАЯ 2026 ГОДА

Последующее обучение пограничных юридических агентов с помощью Baseten Research

Последующее обучение модели 27B с открытым исходным кодом на границе возможностей Harvey LAB с помощью Baseten Research



Чарльз О'Нил (Базеттен)



Мудит Джаясекара (Басетен)



Мэтью Блау (Басетен)



Аарон Эллис-Блур (Басетен)



Нико Группен (Харви)



Гейб Перейра (Харви)

Benchmark Legal Agent (LAB) Харви был разработан с двумя целями: (1) предоставить общественности возможность оценить, насколько эффективно ИИ-агенты справляются с реальной юридической работой, и (2) послужить основой для исследований, направленных на развитие долгосрочных возможностей юридических агентов.

Из основных направлений агентских исследований постпродакшн является одним из самых перспективных для специализированных юридических агентов, поскольку он одновременно решает три ключевые проблемы, с которыми сталкиваются отраслевые компании:

- **Экспертиза в предметной области:** долгосрочная юридическая работа требует широкого спектра навыков в предметной области, в том числе в области исследований (извлечение и поиск информации по ограниченному набору данных), анализа (обоснование и структурирование результатов) и составления документов (хорошо оформленных, пригодных для проверки документов). Наши недавние результаты в области базовых моделей с закрытым исходным кодом показывают, что у агентов по-прежнему есть существенные пробелы в навыках выполнения такой работы: даже самые продвинутые модели справляются менее чем с 10% задач.
- **Стоимость:** использование пограничной аналитики обходится дорого. В LAB для того, чтобы попасть в топ-10 рейтинга с закрытым исходным кодом, нужно потратить примерно \$50 за задачу и более 20 минут на ожидание. Для юридических компаний качество имеет значение только в том случае, если оно вписывается в бюджеты по стоимости и времени ожидания, которые готовы принять клиенты.
- **Управление:** после завершения обучения появляется возможность создать более безопасные и понятные системы агентов, поскольку модели с открытым исходным кодом могут размещаться в собственной защищенной облачной среде компании и обеспечивать более глубокий аудит за счет полного контроля над логикой работы модели, вызовами инструментов и промежуточными решениями.

Однако, несмотря на успехи в таких областях, как программирование, последующая работа в юридической сфере была сопряжена с трудностями, во многом из-за конфиденциального характера юридических данных. Юридическая сфера — одна из самых важных и деликатных областей применения знаний. Благодаря LAB и его обширной таксономии, включающей более 1200 задач в 24 областях юридической практики, появилась возможность эффективно использовать интеллектуальные модели с открытым исходным кодом для решения юридических задач.

В этом посте мы рассказываем о наших первоначальных исследованиях и экспериментах в области легальных агентов с открытым исходным кодом. В сотрудничестве с Baseten Research мы создали конвейер, который принимает сигнал LAB, сопоставляет его с набором инструментов для легальных агентов, разработанным для долгосрочной юридической работы, и дообучает модель с открытым исходным кодом с использованием этого набора инструментов. С помощью этого конвейера мы дообучили модель с открытым исходным кодом 27B, доведя ее до уровня закрытых моделей в LAB.

Полученные результаты позволяют сделать более общий вывод о том, что оптимизацию пост-обучения и нейронных сетей необходимо проводить совместно. Кроме того, они открывают новые направления для дальнейших исследований, в

том числе более эффективные стратегии сжатия с меньшими потерями и использование артефактов сжатия в качестве ориентиров для частичной оценки в долгосрочном обучении с подкреплением.

Подготовка LAB к использованию в качестве обучающей среды

Задания LAB составлены таким образом, чтобы имитировать реальную юридическую работу. Каждое задание начинается с инструкции, составленной в партнерском стиле, и предполагает, что агент работает с документами клиента в рамках закрытой системы. К каждому заданию прилагается составленная экспертами шкала оценки, а результаты оцениваются по нашей стандартной системе.

For our experiments, we leveraged the public LAB tasks and created a hold out test set that has a similar distribution to the training set. As a starting point, we baselined both open weight and closed foundation models on the hold-out. On these baselines, Sonnet 4.6, Opus 4.7, GPT 5.5 lead, with GLM 5.1 and DeepSeek v4 mixed in among them. Below them are the rest of the popular open-weight models.




Figure 1: The mean criterion pass rate per LAB task across popular closed source and open source models. Rubrics were graded by GPT-5.4. Error bars show 95% bootstrap confidence intervals (CIs).

Where frontier performance comes from

Before any training, we started by looking at how the strongest models on LAB research including retrieval and search.

As our initial public results showed, Opus, Sonnet and GPT-5.5 were comprehensive in their research. They opened most documents in the data room and read them in full, often approaching 90% document coverage. The weaker open-weight models did the opposite, they leaned on the grep tool to surface specific passages and rarely read documents end-to-end.

We wanted to see whether the same strategy would emerge when a model was trained end-to-end against the LAB rubrics. We ran a light RL pass on Qwen3.5-9B using GRPO. Reward came exclusively from the LAB rubric, with no retrieval-specific signal.

After 40 steps (Figure 2), the criterion pass rate rose from 42.5% to 63.0% on the hold out test data. Importantly, the model's behavior shifted as the score rose. **grep** calls dropped by 67%, the read tool became dominant, and characters read per rollout rose by over 20%. Trained against the LAB criteria, the small model converged on the same strategy as Opus, Sonnet and GPT-5.5.




Figure 2: Mean reward per step over a 40-step GRPO pass on Qwen3.5-9B, with reward supplied by the LAB rubric and judged by Claude Haiku 4.5. The light line shows per-step values; the bold line is the smoothed trend.

One caveat: when documents follow a fixed form, targeted retrieval can match or exceed read-everything because the model can use the structure to separate signal from a noise for a given client matter. This matters for firm-specific post-training, where the document mix inside a client matter might be narrower and more predictable. We are researching alternative approaches for when this pattern holds.

Compaction lets the agent keep reading everything at scale

If reading everything is an effective strategy, the question is how to scale that strategy to arbitrarily large client matters. Real client matters often contain hundreds or thousands of contracts and supporting materials, much of it peripheral to any given task. A common answer to this is compaction — periodically compressing the trajectory into a summary so the agent can keep reading.

In order to validate this hypothesis, we implemented a naive natural-language compaction strategy and benchmarked. The agent reads one document per turn in full. Every few reads, it writes a natural language memo to its working directory. The memo is a structured note capturing the facts it has surfaced, the open questions, and any provisional judgements it has reached. The memo replaces the prior chat history, and the agent continues reading.




Figure 3: Message-list state across a single compaction event. (1) Pre-compaction, with raw read history; (2) after `rewrite_fn`, where prior reads are replaced by a **BRIDGE** block containing the memo and the list of files already read; (3) one turn later, as the agent resumes reading from the lighter base.

The harness lifted average criterion pass rate by 5–7 points. The all pass rate - the share of matters where every criterion passes - rose more steeply, 2.6x for Sonnet and 3.7x for GPT-5.5. The all-pass rate is the one that maps to real legal review. A deliverable that misses a single issue can be materially incomplete, and partial correctness counts as a failure.



Figure 4: Effect of the natural-language compaction harness on Claude Sonnet 4.6 and GPT-5.5, evaluated on 120 LAB tasks and rubric-graded by GPT-5.4. Left: mean criterion pass rate. Right: all-pass rate, the share of matters where every rubric criterion passes. Error bars show 95% CIs.

The same compaction harness gave Qwen3.5-27B minimal lift. Our hypothesis after looking at the data was the compaction mechanics were not the bottleneck. Qwen3.5-27B struggled with writing a memo that captured the reasoning and facts that matter for the task. Frontier closed models can write a useful memo on their own with the harness just unlocking it. Qwen3.5-27B needed the combination of the harness that captures the right strategy, and post-training that teaches the model to execute it.

Training Qwen3.5-27B model to use the simple natural-language compaction harness

We post-trained Qwen3.5-27B using Iterative SFT (iSFT) to be better in this natural-language compaction harness.



Figure 5: Qwen3.5-27B before and after iterative SFT in the compaction harness, alongside Claude Sonnet 4.6 and GPT-5.5 running the same harness. Evaluated on 120 LAB tasks, rubric-graded by GPT-5.4. Top: criterion pass rate. Bottom: all-pass rate. Error bars show 95% CIs.

Training data for iSFT came from teachers running each task end-to-end inside the harness, with privileged access to the rubric, until they produced a fully-passing deliverable.

Because the training data was filtered to rubric-passing rollouts, post-training lifts the model on both capabilities the intro called out (i) retrieval, where the model learns to use the compaction harness fluently, and (ii) analysis with reasoning, where it learns to produce passing deliverables from the compacted context.

The main challenge was what to do with imperfect first-pass rollouts. Discarding them wastes signal, but two of the obvious recovery paths also have issues. Feeding the teacher more privileged information, like the expected answer or additional hints, pushes the data off-policy. Each unit of extra information the teacher relies on is a unit the student will never have at inference. Surfacing the judge's feedback to the teacher fails for the same kind of reason from the other end. The model learns to respond to a grader that won't be there. We resolved both with what we call a private-mode submit. When a rollout falls short, the teacher gets a chance to notice the gap itself, in its own voice, with no trace of where the correction came from.

The other choice was matching the training shape to inference. A trajectory might span hundreds of thousands of tokens, but at inference the model only ever sees one

compacted window at a time. We trained per-window, with the loss shaped to teach the model to act in the harness, not to predict it.




Figure 6: Conversion of a single rollout with M memento.md writes into $M+1$ per-window training examples. Each window becomes one example: window 0 retains the raw read history, while subsequent windows replace prior content with a BRIDGE block carrying the latest memento and the list of files already read. Loss (★) is applied only to assistant tokens within the current window.

Beyond textual compaction: compaction in KV cache space

The above memo-based compaction harness has a structural ceiling. The natural-language summary is relatively lossy. This worked well enough at the scale of the matters we tested, but it caps what compaction can preserve, and on the hardest long-horizon matters the residual losses compound.

The number of bits stored in a textual summary is very small relative to the rich internal representations in a model’s KV cache. In order to get around this information bottleneck, Baseten has developed a novel technique, STILL, for directly compressing the KV cache. Given a frozen base model with L layers, h KV-heads per layer, and head dimension d , the per-layer cache for a T -token prefix has the form $K^{(\ell,h)}, V^{(\ell,h)} \in \mathbb{R}^{T \times d}$. Baseten trains a per-layer compactor

$$g^{(\ell)} \phi : (K^{(\ell,h)}, V^{(\ell,h)})_{h=1}^H \mapsto (C_k^{(\ell,h)}, C_v^{(\ell,h)})_{h=1}^H$$

with compact keys and values $C_k^{(\ell,h)}, C_v^{(\ell,h)} \in \mathbb{R}^{t \times d}$ and $t \ll T$. Internally, each $g^{(\ell)} \phi$ uses cross attention to a bank of t learned latent queries and projects out to a set of compact keys and values via two linear heads. This compactor is trained without requiring any alterations to the base model itself; we can apply this compaction strategy to any pre-trained open source model.




Figure 7: The STILL per-layer compactor. A bank of t learned latent queries Z cross-attends the full per-layer KV cache (with RoPE stripped from keys), refines through self-attention and feed-forward sub-layers, and projects to compact keys C_k and values C_v in a single forward pass.

Two properties make this the right shape for long-horizon legal work. Text-based summaries work by discarding irrelevant information. Therefore, when a task genuinely requires knowledge of a very large amount of factual details, it is simply impossible to achieve high compression ratios with text based summaries. This kind of task is very common in legal domains where numerous clauses and specific facts many play a pivotal role in the successful completion of the task. By making use of superposition in the latent space of a compressed KV cache, we are able to store exponentially more information. Secondly, by training the KV compression module in this specific domain, we are able to learn to distinguish important information from irrelevant details. Both of these factors can combine to unlock a fundamental discontinuity in capabilities that would not be possible with purely text based summaries.

The climb from here

A 27B open-weight model landing in the closed-source frontier on LAB is base camp. Post-training research and harness optimisations without the high quality LAB data would not have yielded the same performance. The climb ahead includes research directions around less lossy compaction in KV cache space, using compaction artifacts as anchors for partial-credit assignment in long-horizon RL, and closing the reasoning capability gap that retrieval alone doesn't address. It is a much bigger lift than this one post, more to come.

Other research



RESEARCH

Post-Training Science for Supervised Fine-Tuning

How the optimal learning rate and batch size move with model scale, family, and data, and whether one selection rule transfers across them.



CHARLES O'NEILL • 2 others



RESEARCH



RESEARCH

Towards infinite context windows: neural KV cache compaction

Building an intermediate memory layer is a prerequisite for continual learning in LLMs.



CHARLES O'NEILL • 2 others

Explore Baseten today

START DEPLOYING

TALK TO AN ENGINEER >

Продукт

Специализированное логическое устройство

API-интерфейсы моделей

Обучение

Frontier Gateway

Платформа логического вывода Baseten

Исполняемые среды моделей

Инфраструктура

Мультиоблако

Варианты развертывания

Облачное

Собственное

Гибридное

Встраиваемая инженерия

Инженеры , развернутые на переднем крае

Модальности

Транскрипция

Генерация изображений

Преобразование текста в речь

Большие языковые модели

Комплексный ИИ

Эмbedding

ОТРАСЛИ

Предприятие

Здравоохранение

Разработчик

Библиотека моделей

Документация

Список изменений

Ресурсы

Исследования

Клиенты

Блог

Руководства

Мероприятия

Партнеры

Калькулятор сбережений

Центр доверия

О нас

Стартапы

Вакансии

Контакты

Популярные модели

GLM 5.2

Kimi K2.7 Code

DeepSeek V4

GPT OSS 120B

Whisper Large V3

NVIDIA Nemotron 3 Ultra

Посмотреть все

Юридическая информация

Правила и условия

Политика конфиденциальности

Соглашение об уровне обслуживания

● ВСЕ СИСТЕМЫ В НОРМЕ

© 2026 BASETEN

