

ИССЛЕДОВАНИЕ

15 ФЕВРАЛЯ 2025 ГОДА

# Возрождение лосося: более глубокое понимание больших языковых моделей с помощью предметно-ориентированных SAE

Мощная, эффективная и надежная в предметной области стратегия защиты при генерации медицинских текстов.



Чарльз О'Нил (Базеттен)



Мудит Джаясекара (Басетен)



Макс Киркби (Baseten)

ЧИТАТЬ БУМАГУ

Представьте, что вы наблюдаете за тем, как медицинская языковая модель «загорается» в тот момент, когда распознает *моноклеоз*, или когда у нее включается латентная функция при *потере вкуса*. Разреженные автокодировщики обещают стать таким микроскопом. Они пытаются разложить сложную внутреннюю активность языковой модели на краткий список значимых характеристик.

Но есть одна загвоздка. Когда мы обучаем эти системы на обширных общих наборах данных (по сути, на всем интернете), у них часто возникают проблемы. Они могут упустить до 20% важных сигналов, а те признаки, которые они все-таки выявляют, могут быть довольно расплывчатыми. Это похоже на печально известное исследование «фМРТ мертвого лосося». В ходе этого эксперимента стандартные статистические методы, примененные слишком широко без тщательной корректировки, выявили «активность мозга» у мертвой рыбы. Аналогичным образом, крупные SAE общего назначения иногда могут идентифицировать функции, которые на первый взгляд кажутся поддающимися интерпретации (или хорошо оцениваются в автоматизированных тестах), но на самом деле не улавливают нюансов,

действующих причинно-следственных механизмов, или они просто упускают важные сигналы для конкретных задач.

Наше исследование указывает на нелогичное на первый взгляд решение: **вместо того чтобы учить систему искусственного интеллекта понимать все, мы обучаем ее углубленному изучению одного предмета.** Мы ограничиваем ее обучение узким «руслom» данных. Для понимания медицинских процессов мы обучали систему искусственного интеллекта исключительно на основе клинических вопросов и ответов. Результат? Туман рассеивается. Система искусственного интеллекта внезапно «воскрешает лосося»: она начинает находить подлинные, специфические сигналы, которые раньше упускала.

В частности, наша специализированная система автоматического обучения, обученная на 195 000 примерах медицинских вопросов и ответов для Gemma-2, **выявила на 20 % больше вариативности** в активациях большой языковой модели. Она выявила чёткие, клинически значимые признаки, такие как «инфекционный мононуклеоз» и «потеря вкуса», и значительно сократила количество необъяснимых, линейно предсказуемых ошибок.

Ниже мы расскажем, как работают специализированные модели, почему они превосходят свои «базовые» аналоги и как можно углубиться в изучение этих идей.

## Проблема универсальной интерпретируемости

Современные специализированные модели, несмотря на свою эффективность, сталкиваются с несколькими ключевыми препятствиями при обучении на широком спектре данных:

- **Неуловимые сигналы (ошибки при восстановлении):** часто не удается полностью восстановить исходное внутреннее состояние большой языковой модели, то есть часть информации теряется. Это измеряется такими показателями, как «восстановленная потеря» (насколько мы восстанавливаем прогностические возможности большой языковой модели при использовании ее активаций в версии SAE).
- **Неточные подсказки (общие признаки):** изученные признаки могут быть слишком общими (например, «части предложения»), или одно понятие может быть разбито на несколько признаков, что сбивает с толку.
- **«Линейная темная материя»:** значительная часть того, что не объясняет система автоматического проектирования *не* (ее ошибка), часто представляет собой простые линейные закономерности, которые она *должна* была усвоить. Эта неучтенная линейная структура подобна «темной материи», скрывающей от нас истину.

Основная проблема заключается в том, что фиксированный «бюджет» функций в стандарте SAE не позволяет охватить весь спектр возможностей интернета, из-за чего он вынужден учитывать только наиболее распространённые закономерности.

## **Наш подход: обучение специалиста по анализу данных для медицинской экспертизы**

Мы предположили, что если сосредоточить внимание на конкретной области применения, то можно будет гораздо эффективнее использовать бюджет функций. Вот как мы создали и протестировали наш медицинский SAE:

1. **Специализированная диета (набор данных):** мы объединили несколько общедоступных медицинских наборов данных (например, MedQA и PubMedQA) в корпус из ~195 000 примеров ответов на клинические вопросы (~50 миллионов токенов).
2. **Студент (модель и уровень):** мы сосредоточились на активациях 20-го уровня моделей Gemma-2 (2B и 9B) от Google — это общий уровень для извлечения сложных признаков.
3. **Метод (архитектура SAE):** мы использовали JumpReLU — архитектуру, которая, как известно, помогает функциям активироваться более решительно.


Затем мы сравнили эти медицинские системы автоматического распознавания изображений с системой GemmaScope (надёжными базовыми моделями, обученными на общих данных).

## **Более четкие функции, меньше ошибок: что меняется при фокусировке**


Когда система автоматического распознавания изображений специализируется на определенной области, ее понимание становится гораздо более четким.

### **Она фиксирует больше важных деталей (улучшается реконструкция)**

Our medical SAEs consistently explained about 15-20% more variance in the LLM's activations than general SAEs of similar size. They also scored higher on loss recovered (meaning less of the LLM's original performance is lost when its activations are replaced by the SAE's reconstruction).



*Higher is better: Medical SAEs capture more of the LLM's internal signals.*



*Medical SAEs better preserve LLM performance.*

## It Learns Clinically Meaningful Concepts (More Interpretable Features)


This is where the difference becomes striking. Automated interpretability tools (which generate a textual explanation for each feature and then test how well that explanation predicts the feature's activation) gave our medical SAE features higher scores.

More importantly, the features themselves made intuitive clinical sense.

| Feature Explanation (Our Medical SAE) | F1 Score | Representative Example (Activating token in bold)                    |
|---------------------------------------|----------|----------------------------------------------------------------------|
| Infectious Mononucleosis              | 1.00     | "Positive Paul Bunnell test confirmed mononucleosis in the patient." |
| Taste Sensations                      | 0.94     | "Loss of taste sensation in anterior 2/3 of tongue..."               |
| Specificity in Diagnostic Testing     | 0.94     | "High specificity of the test ensured minimal false positives."      |

Table: For full feature lists, see the paper.


General-purpose SAEs, when encountering medical text, tended to activate on more frequent but less clinically insightful terms (e.g., common verbs, articles, or very broad medical terms like "image").



Medical SAE features are more consistently interpretable.

### It Illuminates the "Dark Matter" (Reduced Linear Error)

What about the parts of the LLM's activations that the SAE doesn't capture? We found that our medical SAEs leave behind a smaller amount of "linear dark matter" (error that is simply predictable from the original activation). The error that remains is more likely to be genuinely complex and nonlinear. General SAEs, in contrast, leave more of these learnable linear patterns on the table.



*Medical SAEs capture more linear structure, leaving a smaller, more complex residual error.*

## The Bigger Picture: Why Specificity Unlocks Clarity

Focusing an SAE on a specific domain forces it to use its limited capacity on features that are high-fidelity and relevant to that task. This mitigates issues like feature fragmentation and improves overall reconstruction, leading to more trustworthy interpretations. It's like tuning a radio to a specific station instead of trying to listen to all frequencies at once.

By ensuring our "interpretability microscope" is correctly calibrated for the specific "sample" (the domain of text) we are examining, we avoid the "dead salmon" problem of finding spurious signals. We see the true, active features relevant to the task, allowing us to better understand how the LLM "thinks" about that specific domain.

## What's Next: Charting the Course for Focused Interpretability

This research opens up several exciting avenues:

1. **Deeper Specialization:** Train SAEs on even larger and more diverse domain-specific corpora (e.g., the entirety of bioRxiv, clinical textbooks).
2. **Methodological Refinements:** Explore alternative optimization goals beyond sparsity, or new SAE architectures tailored for domain specificity.
3. **Broader Applications:** Apply this domain-specific approach to other modalities (like vision or code) or to multi-layer "crosscoders."

4. **Real-World Utility:** Use these highly interpretable features to build causal circuit models of LLM behaviour or for targeted model editing.

We believe that embracing domain specificity is a crucial step towards making mechanistic interpretability a truly practical and insightful field.

## Frequently Asked Questions (FAQ)

- **Why did you choose layer 20 of Gemma-2?** Layer 20 is often a mid-to-late layer in models of this size, where many abstract and semantically rich features are thought to be represented, making it a good target for interpretability.
- **What specific datasets were combined for the medical corpus?** We used MedQA, MedMCQA, MMLU (College Medicine, Clinical Knowledge, Professional Medicine), and PubMedQA. The combined dataset, `irisa/medical-qa-combined`, is available on Hugging Face.
- **Why use JumpReLU for the SAE architecture?** JumpReLU includes a learnable threshold for feature activation, which can help create sparser and more "all-or-nothing" features, potentially improving interpretability by making it clearer when a feature is truly active.
- **How does this compare to just fine-tuning an LLM on a specific domain?** Fine-tuning changes the LLM's weights to be better at a task. Our work focuses on understanding the *internal representations* of an existing LLM (which could be a base model or a fine-tuned one) by training a separate SAE "observer" model on its activations within that domain. The goal is insight, not performance improvement on the task itself.

---

**For attribution in academic contexts, please cite this work as:**

*O'Neill, Charles, Mudith Jayasekara, and Max Kirkby. "Resurrecting the Salmon: Seeing Clearer Inside LLMs with Domain-Specific SAEs." Baseten Research, February 15, 2025.*  
<https://www.baseten.co/research/resurrecting-the-salmon/>

### BibTeX citation

```
@misc{oneill12025saes,  
  author      = {O'Neill, Charles and Jayasekara, Mudith and Kirkby, Max},  
  title       = {Resurrecting the Salmon: Seeing Clearer Inside {LLMs} with
```

```
Domain-Specific {SAEs}},  
  year          = {2025},  
  month         = feb,  
  day           = {15},  
  howpublished  = {Baseten Research},  
  url           = {https://www.baseten.co/research/resurrecting-the-salmon/},  
}
```

## Other research



RESEARCH

### Post-Training Science for Supervised Fine-Tuning

How the optimal learning rate and batch size move with model scale, family, and data, and whether one selection rule transfers across them.





RESEARCH

# Still: Amortized KV Cache Compaction in a Single Forward Pass

You can shrink a language model's KV cache by 200×, in a single forward pass, and it still answers correctly.



CHARLES O'NEILL • 4 others



RESEARCH

## Post-training frontier legal agents with Baseten Research

Post-training a 27B open-weight model to the frontier on Harvey LAB with Baseten Research



CHARLES O'NEILL • 5 others

# Explore Baseten today

START DEPLOYING

TALK TO AN ENGINEER >

Продукт

Специализированное логическое устройство

API-интерфейсы моделей

Обучение

Frontier Gateway

Платформа логического вывода Baseten

Исполняемые среды моделей

Инфраструктура

Мультиоблако

Варианты развертывания

Облачное

Собственное

Гибридное

Встраиваемая инженерия

Инженеры , развернутые на переднем  
крае

Модальности

Транскрипция

Генерация изображений

Преобразование текста в речь

Большие языковые модели

Комплексный ИИ

Эмbedding

ОТРАСЛИ

Предприятие

Здравоохранение

Разработчик

Библиотека моделей

Документация

Список изменений

Ресурсы

Исследования

Клиенты

Блог

Руководства

Мероприятия

Партнеры

Калькулятор сбережений

Центр доверия

О нас

Стартапы

Вакансии

Контакты

Популярные модели

GLM 5.2

Kimi K2.7 Code

DeepSeek V4

GPT OSS 120B

Whisper Large V3

NVIDIA Nemotron 3 Ultra

Посмотреть все

Юридическая информация

Правила и условия

Политика конфиденциальности

Соглашение об уровне обслуживания

● ВСЕ СИСТЕМЫ В НОРМЕ



