

ИССЛЕДОВАНИЕ

27 ОКТЯБРЯ 2025 ГОДА

Надежный и эффективный с точки зрения выборки SFT с мутациями в подсказках

Мутации в подсказках с низкой дивергенцией Кульбака — Лейблера: более высокая производительность при меньших затратах.



Гарри Партридж (Бастетен)



Чарльз О'Нил (Базеттен)

TL;DR

Мутации с низкой KL-дивергенцией повышают производительность при минимальных затратах.

В производственных процессах от больших языковых моделей часто требуется многократное выполнение одной и той же задачи. Обычно для этого используется **prompt template** — набор заранее определенных инструкций и требований, которые многократно применяются в сочетании с небольшим набором переменных входных данных. Например, большая языковая модель может использоваться для преобразования документов из одного формата в другой в соответствии с переменными инструкциями, определяющими желаемую структуру, длину и стиль.

В таких повторяющихся сценариях с большим объемом данных можно использовать контролируемую тонкую настройку (Supervised Fine Tuning, SFT) и обучение с подкреплением (Reinforcement Learning, RL) для оптимизации небольшой модели для эффективного выполнения конкретной задачи. Однако часто возникают две взаимосвязанные проблемы:

1. Повышенная чувствительность к изменениям: поскольку во входных данных для каждого примера присутствует один и тот же набор predetermined инструкций, дообученная модель может стать «хрупкой», и при незначительных изменениях в этих инструкциях может наблюдаться значительное снижение производительности.
2. Стоимость:
 1. Для обычного SFT сбор данных, необходимых для достижения желаемого порога производительности, может оказаться непозволительно дорогостоящим.
 2. Для RL создание и оценка роллаутов могут быть очень затратными, особенно если для оценки каждого отдельного роллаута используются дорогостоящие вознаграждения в виде больших языковых моделей.
 3. Дистилляция на основе политики более экономична, чем обучение с подкреплением, поскольку на каждом примере можно получить более плотный сигнал вознаграждения, но выполнение многочисленных роллаутов и оценка с помощью большой модели-учителя все равно требуют больших затрат. Кроме того, модель-учитель должна принадлежать к тому же семейству (или, по крайней мере, использовать тот же токенизатор), что и обучаемая модель.

Предположим, что вы начинаете с набора данных SFT, состоящего из входных данных и эталонных выходных данных (созданных с помощью меток, предоставленных людьми, дистилляции из обучающей модели, дистилляции контекста или итеративного уточнения). Простая, но удивительно эффективная стратегия решения этих проблем заключается в следующем:

1. Выделите статические **prompt template** инструкции, которые используются во всех примерах
2. Выполните точечные изменения, которые затрагивают только формулировку, структуру и синтаксис **prompt template**, но не влияют на смысл или цель запроса.
3. Вновь добавьте в эти измененные инструкции переменные компоненты задачи и сопоставьте их с теми же эталонными результатами.

Этот процесс увеличивает размер набора данных в несколько раз без необходимости повторного сбора эталонных результатов. Кроме того, он гарантирует, что модель не будет заикливаться на особенностях исходного шаблона подсказок. Действительно, многократное использование одного и того же шаблона подсказок

приводит к тому, что в процессе обучения задействуется только часть многообразия весов. Если модель сталкивается с разными вариациями одного и того же скрытого намерения, она вынуждена обобщать и лучше экстраполировать данные на основе ранее не встречавшихся входных данных.

Надежность

На практике, когда кто-то описывает желаемое поведение своей модели в виде `prompt template`, он ищет условный контекст C , в котором модель будет правильно реагировать на переменные входные данные V_i ; конкретные детали запроса важны только в той мере, в какой они обеспечивают желаемое поведение. Однако если оптимальная политика будет встроена в модель с использованием эталонных результатов $Y_i \sim \pi_{\text{opt}}(V_i)$, то зачем вообще нужна предварительная обработка с помощью C ? Почему бы просто не обучить модель на парах (Y_i, V_i) ? Проблема такого подхода в том, что он в корне противоречит политике: базовая модель крайне редко выдает $\mathcal{Y}_i$ на основе $\mathcal{V}_i$ без контекста C .


Было доказано, что дивергенция Кульбака — Лейблера между распределением политики модели и обучающим набором данных является ключевым фактором катастрофического забывания. Поскольку дивергенция Кульбака — Лейблера между базовой моделью и необработанным набором данных (Y_i, V_i) чрезвычайно высока, это приводит к тому, что модель работает очень плохо, если данные хоть немного выходят за рамки распределения. Вот почему необходимо проводить обучение на комбинированном наборе данных $(\mathcal{V}_i, C)$, даже несмотря на то, что желаемое поведение заложено в самих выходных данных.

However, we can do even better than just (V_i, C) . In fact, any C' which induces a low KL divergence between $\pi_{\text{base}}(V_i, C')$ and $\pi_{\text{opt}}(V_i)$ will result in a robust trained model. We can measure this KL divergence on a given candidate prompt mutation, and select only the lowest divergence mutations. This is something we're actively looking into.

Prompt Mutations in Practice

Parsed uses iterative refinement to construct optimal outputs for a given input example. This process leverages a significant amount of computation in running evaluations and refinements, and may therefore cost thousands of dollars for a large dataset. For only a handful of dollars, prompt mutations can be used to double or triple the size of this dataset with no performance reduction, saving thousands of dollars relative to further refinement.

Furthermore, for customers with limited data, prompt mutations provide us an easy method with which to increase the size of the training dataset, resulting in much stronger performance than would have otherwise been possible.



This customer started with a limited sample set of 5000 samples in their dataset. Performing only a single prompt mutation allowed us to double the size of the dataset to 10k datapoints and resulted in above-trend performance virtually for free. All models trained for 2 epochs from a Gemma-3-27B-it baseline. The Likert score represents the sum of scores from an ensemble of binary PASS/FAIL LLM-as-a-Judge evaluators.

On Policy Prompt Mutations

Prompt mutations can also be used in conjunction with on-policy training strategies such as on-policy distillation or RL. In this setting, it is no longer necessary to select low KL-divergence mutations, since the outputs are generated online. Instead, prompt mutations provide a simple way to broaden the training task and ensure that trained models are less fragile to small changes in the input task. Again, this is something we're experimenting with.


Future work

Instead of merely sampling for low KL divergence prompts, it is possible to directly optimise a KV cache C' that minimises the KL divergence of $\pi_{\text{base}}(V_i, C')$ with $\pi_{\text{opt}}(V_i)$. We

hypothesise that training with such a context will result in even more robustly trained models.

We are also interested in exploring the scaling laws of prompt mutations; we would like to have a better characterisation of the marginal benefit of the n th prompt mutation.

Other research



RESEARCH

Post-Training Science for Supervised Fine-Tuning

How the optimal learning rate and batch size move with model scale, family, and data, and whether one selection rule transfers across them.



CHARLES O'NEILL • 2 others



RESEARCH

Still: Amortized KV Cache Compaction in a Single Forward Pass

You can shrink a language model's KV cache by 200x, in a single forward pass, and it still answers correctly.



CHARLES O'NEILL • 4 others



RESEARCH

Post-training frontier legal agents with Baseten Research

Post-training a 27B open-weight model to the frontier on Harvey LAB with Baseten Research



CHARLES O'NEILL • 5 others

Explore Baseten today

START DEPLOYING

TALK TO AN ENGINEER >

Product

Dedicated Inference

Model APIs

Training

Frontier Gateway

Baseten Inference Platform

Model Runtimes

Infrastructure

Multi-cloud

Deployment options

Cloud

Self-hosted

Hybrid

Embedded engineering

Forward deployed engineers

Modalities

- Transcription
- Image Generation
- Text-to-speech
- Large language models
- Compound AI
- Embeddings

Industries

- Enterprise
- Healthcare

Developer

- Model library
- Documentation
- Changelog

Resources

- Research
- Customers
- Blog
- Guides
- Events
- Partners
- Savings calculator
- Trust Center
- About us
- Startups
- Careers
- Contact us

Popular models

- GLM 5.2
- Kimi K2.7 Code
- DeepSeek V4
- GPT OSS 120B
- Whisper Large V3
- NVIDIA Nemotron 3 Ultra
- Explore all

Legal

- Terms and Conditions
- Privacy Policy
- Service Level Agreement

● ALL SYSTEMS NORMAL



