

Потери при обучении позволяют прогнозировать эффективность оценки даже для задач, которые невозможно проверить

Потери: самая дешевая оценка, которую вы когда-либо проводили.




Чарльз О'Нил (Базеттен)



Макс Киркби (Baseten)

TL;DR

Потери при обучении надежно предсказывают результаты оценки с помощью больших языковых моделей, даже для задач, результаты которых невозможно проверить. Это значит, что вы можете оптимизировать производительность модели, не прибегая к дорогостоящим оценочным процедурам, а просто отслеживая потери.



В Baseten мы помогаем компаниям заменить дорогостоящие языковые модели с закрытым исходным кодом на оптимизированные альтернативы с открытым исходным кодом, которые не только дешевле и быстрее, но и лучше справляются с

конкретными задачами. Основная сложность заключается в том, чтобы определить оптимальное соотношение цены и качества. Вы всегда можете пожертвовать вычислительными ресурсами (увеличить размер моделей, увеличить задержку) ради повышения производительности, но для того, чтобы найти золотую середину, нужно знать, как будет работать каждая конфигурация, прежде чем выделять ресурсы.

Интересно, что, хотя сообщество специалистов по машинному обучению тщательно изучало взаимосвязь между потерями и эффективностью при решении верифицируемых задач (математических задач, задач по программированию, вопросов с несколькими вариантами ответов), никто не проводил тщательных исследований на предмет того, применимо ли это к непроверяемым задачам, связанным с конкретными областями знаний, которые оцениваются экспертами в области больших языковых моделей. Это очень важно для реальных приложений: в большинстве корпоративных задач нет эталонных ответов, только экспертная оценка качества. Если мы сможем предсказывать оценочные баллы только на основе потерь при обучении, то значительно ускорим процесс оптимизации, используя потери как надежный сигнал для тонкой настройки, прежде чем переходить к более дорогостоящим сигналам, получаемым от людей.

В этом посте мы демонстрируем именно такую взаимосвязь на примере задачи клинического стенографирования. Мы обучили 15 конфигураций моделей семейства Qwen-3 (от 1,5 до 32 миллиардов параметров) на трех наборах данных разного размера (от 1293 до 4673 примеров), используя тонкую настройку LoRA с одинаковыми гиперпараметрами (ранг 64, альфа = 32, $lr = 2e-4$, постоянная скорость обучения). Для оценки мы разработали ансамбль из 5 подсказок для больших языковых моделей, специально оптимизированных для медицинских описаний (и, что еще важнее, для *этого* конкретного клинического описания), которые измеряют соответствие клиническим шаблонам, правильность медицинских заключений, использование корректной терминологии, полноту информации и отсутствие ошибок. Каждый судья выносит бинарное решение о прохождении/непрохождении с обоснованием, и мы усредняем их, чтобы получить общий процент успешных описаний. Важно отметить, что мы оптимизировали эти подсказки таким образом, чтобы они соответствовали медицинским знаниям команды, работающей с пациентом, и при этом минимизировали разброс (обеспечивая стабильные результаты при одинаковых входных данных).

Хотя, по общему признанию, это исследование в игрушечном масштабе, выявленные здесь закономерности работают на удивление хорошо; мы проверили те же взаимосвязи в производственном масштабе, используя до миллиона обучающих примеров и 235B моделей параметров для решения множества задач заказчика. Результаты показывают, что одни только потери при обучении объясняют 74% разницы в производительности оценки при почти идеальном прогнозировании ($R^2 > 0,90$) при контроле размера набора данных. Этот вывод надежен для всех

масштабов модели, режимов обработки данных и даже для различных моделей оценки.

Потери при обучении сильно влияют на результаты оценки

Наш первый ключевой вывод на удивление прост: **потери при обучении — очень надежный показатель качества оценки**. На рисунке 1 показана эта взаимосвязь для всех 15 конфигураций обучения (5 размеров модели × 3 размера данных).

Корреляция поразительна: потери при обучении сами по себе объясняют **74% дисперсии** показателей успешности оценки ($R^2 = 0,739$, коэффициент корреляции Пирсона = -0,86).

Зависимость носит чисто линейный характер: при снижении итоговых потерь на 0,1 мы наблюдаем увеличение доли успешных прохождений на 18,5 %. Это значит, что вы можете спрогнозировать результаты оценки только на основе показателей обучения, не дожидаясь завершения дорогостоящих прогонов.

Особую ценность этому явлению придает его стабильность. Прогноз остается верным:

- Разброс в 20 раз по размеру модели (от 1,7 до 32 миллиардов параметров)
- Разброс в 3,6 раза по объему обучающих данных (от 1293 до 4673 примеров)
- Разные системы оценки (и Gemini-2.5-Flash, и GPT-5-mini показывают $r \approx -0,86$, несмотря на разницу в 2,8 раза в абсолютных показателях успешности)




Figure 1: linear regression fit of evaluation score against final training loss against all 15 model configurations.

The linear fit improves significantly when we fix the data size and examine each regime separately. When we condition on training data size, the relationship becomes much tighter (Figure 2). Breaking the analysis into three panels (one for each data regime) shows R^2 values of 0.904, 0.930, and 0.978. This suggests that training loss predicts performance most reliably within a fixed data regime. Some scatter in the overall plot comes from the non-linear relationship between data size and performance.



Figure 2: linear fits holding dataset size constant.

Each panel maintains the strong negative correlation, but with notably different slopes and intercepts. The 1,293-sample regime (left) shows steeper improvement with loss reduction but lower absolute performance. The 4,673-sample regime (right) shows the highest pass

rates but also signs of optimisation challenges, with some configurations achieving higher loss than their medium-data counterparts.

This holds across different LLM-as-judges

A natural concern when using LLM-based evaluation is consistency: are different evaluators measuring the same thing? Figure 3 addresses this directly by comparing two independent judge models (Gemini-2.5-Flash and GPT-5-mini) across all 30 experimental configurations.

Despite a 2.8× difference in absolute pass rates (Gemini averages 26.7%, GPT-5-mini averages 9.5%), both evaluators show nearly identical correlations with training loss: $r = -0.86$ for Gemini, $r = -0.87$ for GPT-5-mini. Thus, these evaluators differ in their stringency threshold, but they're measuring the same underlying quality dimension.

This consistency has important implications. First, it validates that training loss captures real model capability, not evaluator-specific quirks. Second, it means you can use training loss to predict evaluation outcomes regardless of which judge you eventually deploy. The absolute pass rate will differ based on calibration, but the relative ranking of models remains stable.




Figure 3: Training loss predicts evaluation performance consistently across different LLM judges. Despite Gemini-2.5-Flash being 2.8× more lenient than GPT-5-mini in absolute pass rates, both show nearly identical correlations with training loss ($r \approx -0.86$).

Figure 4 decomposes performance across our two key scaling dimensions: model size and training data quantity. The chart reveals several patterns.




Figure 4: Pass rates by model size and training data quantity (Gemini-2.5-Flash evaluator). Larger models consistently outperform smaller ones, and data scaling shows monotonicity.

First, model size scaling is substantial but sublinear. Moving from 1.7B to 32B parameters (a 19× increase) yields a 6.3x improvement in pass rate (from 7.0% to 44.0% at their best configurations). The largest gains come early: doubling from 1.7B to 4B more than doubles performance, while the final jump from 14B to 32B adds only 4 percentage points despite a 2.3× parameter increase. This is the familiar pattern of diminishing returns from scaling laws.

Second, data scaling is generally beneficial and monotonic. Four out of five model sizes show consistent improvement as training data increases from 1,293 to 4,673 samples. The 8B model demonstrates this most dramatically, jumping from 18.7% to 34.9% pass rate as data increases. However, the 14B model breaks this pattern: it achieves 39.8% pass rate with 2,586 samples but drops to 39.1% with 4,673 samples, despite having nearly twice the training data. Its training loss also increases (0.238 → 0.265), confirming this isn't just evaluation noise the model is genuinely learning less effectively with more data, so probably just an unfortunate training run.




Figure 5: Model scaling curves for both LLM-as-judge evaluators. Despite GPT-5-mini being significantly more stringent than Gemini-2.5-Flash (2.8× lower pass rates on average), both evaluators show identical scaling behaviour: pass rates increase log-linearly with model size.

Both evaluators reveal the same fundamental scaling law: pass rates increase with model size but with diminishing returns, particularly beyond 14B parameters. The 32B model achieves 44% with Gemini and 15.5% with GPT-5-mini at full data; a 2.8x calibration gap in absolute terms, yet both show nearly identical relative scaling curves.

Conclusion and future work

While this exploration uses relatively modest scale, the patterns hold remarkably well in production. We've validated these same relationships with up to a million training examples and 235B parameter models across multiple customer tasks. The loss-performance correlation remains strong across different domains, from medical scribing to legal document analysis to insurance workflows.

There's one critical caveat: these results depend entirely on having high-quality LLM-as-judge evaluators. Bad judges produce noisy, inconsistent signals that break the clean relationship with training loss. We've invested heavily in solving this problem (see our [thoughts on eval design here](#)), developing an internal system that iteratively refines evaluation prompts to align with each customer's domain experts. Without this calibration ie if you just naively implement LLM judges, you'll get evaluators that are inconsistent, high-variance, and non-transitive, destroying the predictive power of loss.

Looking ahead, we're pursuing several key questions:

- **Where's the ceiling?** Can we saturate a fine-tuned model to match the performance of the data it was trained on? If we train on GPT-5's outputs where GPT-5 scores 85% on our evals, at what data scale (if ever) does our fine-tuned model hit that same 85%?

- **RL vs iterative SFT efficiency:** How do reinforcement learning and our iterative supervised fine-tuning (essentially smart rejection sampling) compare for reaching specific performance thresholds? Which gets to the asymptote faster?
- **Reverse validation:** Can training loss help us evaluate the quality of our LLM judges themselves? If a judge's scores don't correlate with loss, is that judge actually measuring something meaningful?

The beauty of having loss as a reliable proxy is that it transforms how we approach these questions. Instead of running expensive evaluations on every configuration, we can use loss to map the optimisation landscape, then strategically evaluate only the most informative points. This makes evaluation surgical rather than eliminating it completely. We know exactly where to look, when to look, and what we're looking for.

Appendix

We include the loss curves for the sake of completeness.



For attribution in academic contexts, please cite this work as:


O'Neill, Charles, and Max Kirkby. "Training Loss Predicts Evaluation Performance, Even for Non-Verifiable Tasks." *Baseten Research*, October 27, 2025.

<https://www.baseten.co/research/training-loss-predicts-evaluation-performance-even-for-non-verifiable-tasks/>

BibTeX citation

```
@misc{oneill2025trainingloss,  
  author      = {O'Neill, Charles and Kirkby, Max},  
  title       = {Training Loss Predicts Evaluation Performance, Even for Non-  
Verifiable Tasks},  
  year        = {2025},  
  month       = oct,  
  day         = {27},  
  howpublished = {Baseten Research},  
  url         = {https://www.baseten.co/research/training-loss-predicts-  
evaluation-performance-even-for-non-verifiable-tasks/},  
  note        = {Accessed: 2026-03-12}  
}
```


Other research



RESEARCH

Post-Training Science for Supervised Fine-Tuning

How the optimal learning rate and batch size move with model scale, family, and data, and whether one selection rule transfers across them.



CHARLES O'NEILL • 2 others




RESEARCH

Still: Amortized KV Cache Compaction in a Single Forward Pass

You can shrink a language model's KV cache by 200×, in a single forward pass, and it still answers correctly.



CHARLES O'NEILL • 4 others



Explore Baseten today

START DEPLOYING

TALK TO AN ENGINEER >

Product

Dedicated Inference

Model APIs

Training

Frontier Gateway

Baseten Inference Platform

Model Runtimes

Infrastructure

Multi-cloud

Deployment options

Cloud

Self-hosted

Hybrid

Embedded engineering

Forward deployed engineers

Modalities

Transcription

Image Generation

Text-to-speech

Large language models

Compound AI

Embeddings

Industries

Enterprise

Healthcare

Developer

Model library

Documentation

Changelog

Resources

Research

Customers

Blog

Guides

Events

Partners

Savings calculator

Trust Center

About us

Startups

Careers

Contact us

Popular models

GLM 5.2

Kimi K2.7 Code

DeepSeek V4

GPT OSS 120B

Whisper Large V3

NVIDIA Nemotron 3 Ultra

Explore all

Legal

Terms and Conditions

Privacy Policy

Service Level Agreement

● ALL SYSTEMS NORMAL



