

ИССЛЕДОВАНИЕ

13 ЯНВАРЯ 2025 ГОДА

Почему механистическая интерпретируемость требует смены парадигмы

Традиционная парадигма масштабирования самих языковых моделей может в корне противоречить принципу интерпретируемости.



Чарльз О'Нил (Базеттен)



Мудит Джаясекара (Басетен)



Макс Киркби (Baseten)

В Basetten мы провели исследование в области механистической интерпретируемости и пришли к парадоксальному выводу: традиционная парадигма масштабирования самих языковых моделей, которая привела к значительному прогрессу в области возможностей искусственного интеллекта, может в корне противоречить нашей цели — понять, как работают эти модели. Мы считаем, что для механистической интерпретируемости необходима смена парадигмы: от фундаментальных моделей широкого профиля (таких как разреженные автокодировщики, обученные на данных со всего интернета) к инструментам интерпретируемости, ориентированным на конкретную область.

В этом эссе мы приводим технические аргументы в пользу нашей позиции, а также кратко описываем эмпирические данные, подтверждающие ее, и размышляем о том, как нам подходить к пониманию искусственного интеллекта. Хотя наше исследование в основном сосредоточено на применении ИИ в здравоохранении, обсуждаемые нами принципы имеют более широкое значение для механистической интерпретируемости как научной дисциплины. Это не эмпирическая статья, основанная на доказательствах, а скорее попытка поделиться своими мыслями.

Парадигма модели Foundation и ограничения ее интерпретируемости

Доминирующая парадигма интерпретируемости ИИ основана на той же логике масштабирования, которая лежит в основе разработки базовых моделей: обучение на разнообразных и обширных наборах данных для выявления общих закономерностей. Такой подход предполагает, что инструменты интерпретируемости, такие как разреженные автокодировщики (sparse autoencoders, SAE), должны работать одинаково эффективно в разных областях.

Разложение векторов активации модели на разреженные линейные комбинации изученных направлений признаков. Применительно к большим языковым моделям это попытка разделить перекрывающиеся понятия, закодированные в скрытых слоях модели. Согласно общепринятому мнению, обучение таких моделей на разнообразных данных, отражающих распределение обучающих данных в самих моделях, должно привести к наиболее универсальным и полезным интерпретациям.

Однако наше исследование выявило ограничения этого подхода.

Проблема линейных невязок («темная материя»)

Широкодоменные самообучающиеся архитектуры, как правило, не учитывают значительную часть линейной структуры. Следуя подходу [Энгелса и др. \(2024\)](#)¹, мы можем количественно оценить эту проблему, измерив, какая часть остаточной ошибки самообучающейся архитектуры линейно предсказуема на основе входных активаций. Наши эксперименты неизменно показывают, что до 70–80% остаточной ошибки широкодоменных самообучающихся архитектур линейно предсказуемы — это то, что Энгелс назвал «темной материей».

Это говорит о том, что даже крупные системы автоматического перевода, охватывающие широкий спектр областей, не способны уловить значительную часть линейно структурированных закономерностей во внутренних представлениях модели. Несмотря на то, что они могут улавливать высокочастотные общие закономерности, они упускают бесчисленное множество низкочастотных особенностей, характерных для конкретной предметной области, которые необходимы для понимания специализированных внутренних механизмов.

[Темплтон и др. \(2024\)](#)² привели яркий пример такого ограничения: несмотря на то, что они обучили огромную языковую модель (Claude 3 Sonnet) с 34 миллионами признаков, она распознала только 60 % районов Лондона, хотя при подсказке модель демонстрировала знание обо всех районах. Модель даже могла назвать отдельные улицы в этих районах, что указывает на то, что недостающие признаки существуют в

модели, но не распознаются даже очень большими языковыми моделями широкого профиля. При распределении фиксированного скрытого бюджета на обширное концептуальное пространство многие специализированные концепции неизбежно остаются нереализованными.

Разделение и поглощение функций

В моделях с широкой областью применения часто наблюдается расщепление признаков (разделение единого связного понятия на несколько чрезмерно специализированных латентных признаков) и поглощение признаков (когда латентные признаки, связанные с токенами, «поглощают» ожидаемое направление признака, из-за чего в некоторых контекстах предполагаемый латентный признак не активируется).

Например, широко используемая в медицине аббревиатура SAE может разделять общее медицинское понятие, такое как «диабет», на отдельные признаки, отражающие только определенные аспекты, например «повышенный уровень глюкозы в крови» и «инсулинорезистентность», без учета таких важных компонентов, как «назначенные антигипергликемические препараты» или «метаболические осложнения», что приводит к неполному представлению понятия. (Важно отметить, что само понятие «диабет» может не иметь собственного признака.)

С другой стороны, клинически специфические признаки, такие как «плевральная боль в груди» или «ортопноэ», могут быть объединены с более общими, неспецифическими сенсорными признаками, такими как «дискомфорт в груди» или «одышка», что приводит к потере диагностического нюанса, необходимого для того, чтобы отличить такие состояния, как тромбоэмболия лёгочной артерии и застойная сердечная недостаточность, друг от друга. Еще хуже, когда специфические признаки объединяются с поверхностными лингвистическими шаблонами, такими как «начинается на букву п».

These phenomena substantially reduce both the fidelity and interpretability of the resulting features, making it difficult to trace causal reasoning pathways through the model. The tendency toward generic features in broad-domain SAEs stems directly from their optimisation objective. As observed in our previous work ([O'Neill et al.³](#)), SAEs trained on diverse data distributions face pressure to optimise for reconstruction across an enormous variety of inputs. This fundamentally biases them toward learning abstract, high-level features that have broad applicability but lack specificity. Since the SAE must be able to reconstruct any potential input from the broad distribution, it prioritises features that contribute to reconstruction across many contexts, inevitably sacrificing fine-grained, domain-specific features that only appear in specialised contexts⁴. The consequence is a hierarchy of features where the most general, abstract concepts dominate - essentially another form of feature absorption where specific concepts are subsumed into more

general ones. Domain-specific training relieves this pressure, allowing the SAE to develop precise features that are almost certainly more useful for doing things like circuit tracing⁵.

The Fixed Latent Budget Constraint

Perhaps most fundamentally, broad-domain SAEs face an intractable resource allocation problem. With a fixed latent budget (even in the millions of features), SAEs must distribute capacity across an enormous conceptual space. Language models have arguably trillions of concepts internalised, and the SAE can't learn them all. Inevitably, this forces the SAE to prioritise high-frequency, generic patterns at the expense of domain-specific ones.

This is likely a structural limitation of the broad-domain approach. Even as SAEs grow to enormous sizes (with dictionaries of 2^{20} features or more), they continue to miss substantial portions of the model's representational structure.

The Paradigm Inversion: Domain-Confined SAEs

Our central claim is that these limitations reflect a fundamental misalignment between the goal of interpretability and the scaling paradigm of foundation models. We propose a paradigm inversion: rather than train broader SAEs with larger dictionaries, we should train domain-confined SAEs that focus exclusively on specific domains of interest. And SAEs are actually cheap to train, when you don't need to train them on the whole internet. If they can be more useful at this smaller scale of data, then it's a win-win.

Rather than being a pragmatic compromise, our empirical evidence suggests that domain-confined SAEs actually outperform their broad-domain counterparts across all relevant metrics, even when controlling for dictionary size and sparsity levels.

Empirical Evidence

Our JumpReLU SAEs trained on layer-20 activations of Gemma-2 models using 195,000 clinical Q&A examples demonstrate remarkable improvements over comparable broad-domain SAEs:

1. **Higher Variance Explained:** Domain-confined SAEs consistently explain 15-20% more variance than broad-domain counterparts with equivalent capacity.
2. **Superior Loss Recovery:** When substituting SAE reconstructions back into the model, domain-confined SAEs achieve substantially higher loss recovery, indicating more faithful representation of causally important features.

3. **Reduced Linear Residual:** The "dark matter" analysis reveals that domain-confined SAEs leave behind significantly less linearly predictable error, suggesting they better capture the linear structure relevant to their domain.
4. **More Interpretable Features:** Automated and human evaluations confirm that the features learned by domain-confined SAEs align more closely with clinically meaningful concepts (e.g. "infectious mononucleosis", "prescribed antihyperglycaemics", "pleuritic chest pain") rather than generic linguistic patterns.

This empirical superiority has a straightforward theoretical explanation: domain confinement reallocates the SAE's fixed latent capacity to domain-relevant features.

In a broad-domain setting, the SAE must distribute its capacity across a vast conceptual space, capturing only the most frequent patterns. By restricting the input domain, we effectively concentrate the same capacity on a more constrained set of concepts, allowing the SAE to learn more fine-grained, domain-specific features.

Implications

The Local-Global Tension in Scientific Understanding

There's a persistent tension in scientific understanding between local, specific knowledge and global, general theories. In physics, for example, general relativity provides a sweeping, elegant account of gravity at cosmic scales, but fails to integrate with quantum mechanics at microscopic scales. Complete understanding often requires both global theories and local, domain-specific ones.

Similarly, in AI interpretability, we may need to accept that understanding isn't monolithic. There may not be a single, unified account of how an LLM "thinks" across all domains. Instead, we might need domain-specific lenses that reveal different aspects of the model's internal mechanisms. Both human and artificial intelligence appear to rely on specialised circuits and modules for different domains, despite sharing underlying neural mechanisms.

The foundation model paradigm has been remarkably successful for building capable AI systems, but it may be fundamentally misaligned with our interpretability goals. By training models on diverse data and pursuing scale above all, we create systems whose internal representations are inherently difficult to disentangle.

This suggests a provocative possibility: the most interpretable AI systems might not be the most capable ones. Systems trained on narrower domains might be inherently more interpretable, even if less generally capable.

Interpretability as Localised Translation

Perhaps we should think of interpretability not as “understanding the model” in some global sense, but as developing domain-specific translations between the model's internal representations and human concepts. Just as human languages often have specialised vocabularies for different domains (legal terminology, medical jargon, technical nomenclature), our interpretability tools might need domain-specific vocabularies to accurately translate model representations.

In this view, domain-confined SAEs are more faithful translators of the model's internal language in specific domains. They capture the nuances and specialised vocabulary that broad-domain approaches necessarily miss.

Research Frontiers and Unknowns

While our results provide strong evidence for the value of domain confinement, numerous open questions and research directions remain.

Optimal Domain Granularity

What constitutes an optimal domain granularity remains unclear. Is “medicine” sufficiently confined, or should we pursue even narrower domains like “cardiology” or “oncology”? Our initial results suggest that even relatively broad domains like medical text yield substantial improvements, but the optimal granularity likely depends on the specific interpretability goals.

Cross-Domain Feature Transfer

To what extent do features learned in one domain transfer to others? While our results show that domain-confined SAEs learn more interpretable features within their domain, we have limited understanding of how these features might map to or compose with features from other domains.

Scaling Laws for Domain-Confined SAEs

How do domain-confined SAEs scale with dictionary size, model size, and data volume? Our initial results show substantial improvements across different model scales, but more systematic study of scaling relationships could inform optimal resource allocation for interpretability efforts.

Conclusion

The paradigm inversion we propose (from broad-domain scaling to domain confinement) represents a rethinking of how we approach mechanistic interpretability. Rather than

mimicking the scaling paradigm, we advocate for a more focused, domain-specific approach that yields more faithful and useful decompositions of model behaviour.

This is a shift in how we conceptualise the goal of interpretability. Perhaps understanding an AI system doesn't mean developing a single, unified account of its operation across all domains, but rather constructing domain-specific lenses that reveal different aspects of its internal mechanisms.

In healthcare and other high-stakes domains, this approach offers particular promise. By focusing our interpretability efforts on specific domains where transparency and reliability are paramount, we can develop tools that more faithfully capture the causal mechanisms underlying model behaviour in those domains. We think this may take us one step closer to ensuring the safe deployment of LLMs in the domains where they matter most.

¹ [Engels et al. \(2024\)](#).


² [Templeton et al. \(2024\)](#).


³ [O'Neill et al.](#)

⁴ Or consider a set data distribution to train an SAE on. As we increase the number of features in the SAE, we see more and more specific features ("feature splitting"). In an analogous way, when you reduce the overall number of features to learn, the features also become more specific because the SAE has the "feature budget" to represent them, from an optimisation perspective.

⁵ [Circuit tracing](#)

Other research





RESEARCH

Still: Amortized KV Cache Compaction in a Single Forward Pass

You can shrink a language model's KV cache by 200×, in a single forward pass, and it still answers correctly.



CHARLES O'NEILL • 4 others

RESEARCH

Post-training frontier legal agents with Baseten Research

Explore Baseten today

START DEPLOYING

TALK TO AN ENGINEER >

Продукт

Специализированное логическое устройство

API-интерфейсы моделей

Обучение

Frontier Gateway

Платформа логического вывода Baseten

Исполняемые среды моделей

Инфраструктура

Мультиоблако

Варианты развертывания

Облачное

Собственное

Гибридное

Встраиваемая инженерия

Инженеры , развернутые на переднем крае

Модальности

Транскрипция

Генерация изображений

Преобразование текста в речь

Большие языковые модели

Комплексный ИИ

Эмbedding

ОТРАСЛИ

Предприятие

Здравоохранение

Разработчик

Библиотека моделей

Документация

Список изменений

Ресурсы

Исследования

Клиенты

Блог

Руководства

Мероприятия

Партнеры

Калькулятор сбережений

Центр доверия

О нас

Стартапы

Вакансии

Контакты

Популярные модели

GLM 5.2

Kimi K2.7 Code

DeepSeek V4

GPT OSS 120B

Whisper Large V3

NVIDIA Nemotron 3 Ultra

Посмотреть все

Юридическая информация

Правила и условия

Политика конфиденциальности

Соглашение об уровне обслуживания

