



★ 1196 прочтений


Выявление 98,9 % дипфейков: что нужно, чтобы возглавить рейтинг Hugging Face

Автор: Модулировать

16 апреля 2026 года

TLDR >

Переводы 



Хакернун

Write



пании, пострадавшие от голосовых дипфейков.

Для сравнения: общие потери в 2023 году составили **голосовые дипфейки обошлись в 600 миллионов долларов (12,5 миллиарда долларов в 2024 году)**. За пять лет этот показатель вырос на 6566 %.

Разумеется, больше всего пострадали финансовые услуги. **23% организаций финансового сектора сообщили об убытках на сумму более миллиона** Контактные центры также пострадали сильнее всего. Сообщается, что в этих центрах наблюдается **Голосовая дипфейковая атака каждые 46 секунд**.

Компаниям **нужен API** для обнаружения дипфейков, чтобы точно и надежно выявлять голосовое мошенничество и тем самым сокращать убытки.

Оценка эффективности такого решения зависит от надежных показателей, таких как **Рейтинг дипфейков Hugging Face (HF)** По состоянию на март 2026 года Modulate занимает первое место (со средним показателем EER 1,104 %). Это означает, что Modulate распознает 98,9 % всех дипфейковых голосов, сгенерированных искусственным интеллектом, в различных аудиозаписях, использованных в 14 тестах Hugging Face. Показатель EER также отражает частоту ложных срабатываний, которая составляет всего 1,1 %.

Почему все обращают внимание на рейтинг дипфейков Hugging Face

Рейтинг дипфейков Hugging Face — это набор общедоступных, постоянно обновляемых рейтингов, которые показывают, насколько хорошо системы искусственного интеллекта распознают синтетические или поддельные медиафайлы, особенно дипфейки с речью.





ния каждой из моделей.

Потому что Арена HF Deepfake открыт для посещения и любой может воспроизвести (или опубликовать) результаты, чтобы проверить это утверждение. Это самый наглядный критерий для оценки точности моделей автоматического распознавания речи при обнаружении манипуляций со звуком.

Несмотря на то, что пользователи могут присылать свои результаты, таблица лидеров была разработана и постоянно обновляется исследователями из Научно-исследовательского института Idiap (Швейцария), Национального центра научных исследований (Франция), Университета искусственного интеллекта имени Мохаммеда ибн Заида (ОАЭ), Таллиннского технического университета (Эстония) и компании Validsoft Ltd. (Великобритания).

Это означает, что HF является одним из самых надежных и строгих общедоступных эталонов для оценки систем обнаружения.

Таблица лидеров: Modulate #1, Hiya #2, Resemble AI #3

Два самых важных показателя в таблице лидеров — это средний результат и совокупный результат.

При подсчете среднего результата результаты по всем четырнадцати наборам данных имеют одинаковый вес.

Совокупный результат объединяет вычислительную ценность всех оценочных выборок.





Современный мониторинг API для ваших приложений

Resemble-Detect-3B-Omni	14/10/2025	3000.000	2.099	2.570	1.347	2.531
Hiya-Authenticity-Verific	13/02/2026	1000.000	2.324	2.113	0.667	0.301
DLMSL-SpeakSure-v0.1	27/10/2025	658.630	6.142	3.954	1.278	0.042
Whisper	20/08/2025	98.900	8.060	3.049	1.268	0.394
DF-Raptor	19/02/2026	100.000	8.350	8.390	3.191	7.695
DF_Arena_1B_V_1 NEW	27/10/2025	1000.000	9.524	5.919	0.906	1.139
Momenta	04/12/2025	350.000	9.763	7.057	4.629	1.208
Syntra_Detector	16/08/2025	584.000	10.764	6.109	3.978	1.482
DF_Arena_500M_V_1 NEW	04/11/2025	500.000	10.880	5.780	1.760	1.090
MoLEx	18/09/2025	376.440	12.405	9.519	0.034	0.284
Resemble_Detect	11/04/2025	2112.000	12.747	10.830	3.946	1.321

В таблице лидеров Modulate (velma-2) занимает первое место как по среднему баллу, так и по общему баллу с показателями 1,104 и 1,586 соответственно. Это соответствует средней точности 98,9%. Из каждых 100 аудио-файлов Modulate правильно распознает 98,9%. Только 1,1% файлов ошибочно помечаются как дипфейки. Это самый близкий к стопроцентной точности результат среди всех моделей для обнаружения дипфейков.

Продолжая рассказ о результатах,Напоминать искусственный интеллект (resemble-detect-3b) занимает второе место со средним показателем 2,570 (средняя точность 97,9 %) и общим показателем 2,099. Привет (проверка подлинности) занимает третье место со средним показателем 2113 (средняя точность 97,4 %) и общим показателем 2,324.





Эти три лучших результата просто невероятны, особенно если учесть, насколько точнее каждая из моделей по сравнению с четвертой — DLMSL-Speaksure.

Чтобы лучше понять, почему эти достижения так важны, давайте рассмотрим двух наших главных конкурентов по отдельности:

Resemble AI — это в первую очередь компания, занимающаяся генерацией голоса (синтезом речи и клонированием голоса), что может поставить ее на противоположную сторону в вопросе обнаружения подделок. Однако их продукт для обнаружения подделок (resemble-detect-3b) представляет собой модель с 3B-параметрами. Таким образом, несмотря на то, что обнаружение подделок не является их основной задачей, компания демонстрирует при-





параметров), и она работает в 8 раз быстрее в режиме потоковой передачи. Большая часть их бизнеса сосредоточена на брендированных идентификаторах вызывающего абонента и голосовых агентах, хотя часть ресурсов они направляют на выявление и предотвращение спама и мошенничества.

Modulate — это совсем другая история. Мы с самого начала ориентировались на голосовые технологии, и распознавание — это основа нашего бизнеса. Мы работаем на основе архитектуры ELM, и наши дополнительные предложения основаны на этой архитектуре (интеллектуальный анализ диалогов, преобразование речи в текст и распознавание дипфейков).

Такой подход оправдал себя и позволил нам добиться значительных успехов в точности распознавания дипфейков.

Что на самом деле тестируют 14 наборов данных Hugging Face

В 14 наборах данных Hugging Face для распознавания дипфейков содержится около 2 миллионов аудиофайлов. Все они собраны для того, чтобы представить реальные сценарии атак в различных условиях, с разными акцентами/языками, в разных отраслях и с использованием технического жаргона.

Давайте посмотрим, насколько разнообразны эти аудиофайлы и что они позволяют протестировать.

Серия ASVspoof (2019, 2021 LA, 2021 DF, 2024)

Из всех наборов данных в коллекции HF серия ASVspoof наиболее близка к отраслевому стандарту оценки моделей в контролируемых, но реалистичных условиях.





- LA (Logical Access): TTS and voice conversion attacks injected directly into the system (no channel noise).
- PA (Physical Access): Playback attacks in real rooms with microphones, reverberation, and environmental noise.
- DF (Deepfake): Modern neural TTS/VC systems, including diffusion-based models.

With each new edition, you get new attack types, codecs, and channel conditions. For instance, 2024 expands into VoIP, telephony, compression artifacts, and more realistic channel distortions.

ADD Challenges (2022 Track 1/3, 2023 R1/R2)

The Audio Deepfake Detection (ADD) challenge series was designed with the knowledge that most models are tested on clean audio, with those unchallenged benchmarks flouted as sales signals.

This dataset focuses on noisy, degraded, and real-world audio as a way to punish those models.

It measures:

- Track 1: In-the-wild deepfake detection.
- Track 3: Robustness to channel effects, background noise, and environmental distortions.
- 2023 R1/R2: Introduces more diverse languages, codecs, and unseen synthesis methods.

In-The-Wild (YouTube, social media, uncontrolled noise)

In-The-Wild is not a dataset. It's an entire category that's typically curated from video based social media like TikTok, livestreams, and YouTube, as well as other audio mediums like podcasts and other uncontrolled environments. Essentially,





It measures:

- Real-world noise
- Room acoustics
- Microphone variability
- Editing artifacts
- Background music, cross-talk, overlapping speech

CodecFake (Neural codec processing)

Neural codecs are now embedded into communication and social apps like WhatsApp, Instagram, TikTok, and Zoom. This increasingly makes real human audio look synthetic to older detectors.

Obviously, this decreases the accuracy rates of deepfake detection models and has negative implications in real-world scenarios.

The CodecFake aims to identify the models that are able to discern true human audio from deepfakes by focusing the benchmark on neural codecs (EnCodec, DAC, SoundStream, etc.) and codec-induced artifacts.

It measures:

- Whether a detector can handle audio that has been encoded → decoded → re-encoded
- Robustness to neural codec artifacts that resemble TTS artifacts
- Sensitivity to bitrate changes

Academic benchmarks (Fake-or-Real, DFADD, SONAR)





by **Modulate**
@modulate



5



DFADD (Deepfake Audio Detection Dataset) includes multiple languages and synthesis methods and was designed to test generalization to unseen attacks.

SONAR dataset places heavy focus on neural vocoder artifacts by including challenging borderline-realistic samples and high-quality TTS systems.

LibriSeVOC (neural vocoder synthesis)

If you're trying to detect high-quality synthetic speech in commercial TTS systems, then the LibriSeVOC dataset is critical.

While built on LibriSpeech, which is generally too clean to give a complete picture on WER accuracy in a text-to-speech application, it was re-synthesized using neural vocoders (HiFi-GAN, WaveGlow, WaveRNN, etc.), which is an essential part of detection today.

Modern TTS pipelines often use diffusion models for acoustic modeling and neural vocoders for waveform generation, so vocoder detection is a core capability.

This dataset measures:

- Ability to detect vocoder-generated speech
- Sensitivity to subtle phase and spectral artifacts
- Generalization across vocoder families

How voice-native architecture beats repurposed models

When systems repurpose a model, they're typically layering non-voice-specific, generalized ML models to handle new tasks.





inefficient.

- Accuracy gaps: **Voice-native** AI tools are purpose-built to take into account tone, cadence, and other complexities of speech-based communication. This makes them incredibly accurate. Repurposed, generalized models may misinterpret conversational nuances.
- Missed context: The ability to detect tone and intent, as voice-native AI models do, are pertinent to ceasing harmful behaviors. Repurposed models may even enforce those behaviors and alienate users.
- Limited scalability: Non-specified systems struggle to keep up with the growing volume of voice interactions, causing delayed responses (at minimum) while also increasing user harm.

You can see how this plays out in the architecture of the top three models in the HF Deepfake Leaderboard.

Hiya is telephony-focused, which means it's strong on phone call conditions. But their architecture is optimized for a specific channel.

Resemble AI comes from the generation side, which means they understand synthesis because, well, they build synthesizers. While this is an essential factor in effective deepfake detection, it's not the only factor necessary.

Detection requires *architectural priorities* that repurposed models often don't have, including:

- Adversarial robustness
- Real-time processing
- False positive management at scale

That is why Modulate's ELMs take the voice-native approach, which generalizes across telephony, VoIP, clean audio, and degraded conditions. Because they're





Production performance (beyond the benchmark)

The question has never been just 'can you detect deepfakes in the lab?', it's 'can you do it at scale without drowning your fraud team in false alerts?'.

That is why we must go beyond the benchmark to look at deployment. Average metrics on the deepfake leaderboard help us do just that.

Dataset	EER (%)
Pooled	1.586
Average	1.104
In-The-Wild	1.271
ASVspoof 2019	0.299
ASVspoof 2021 LA	1.330
ASVspoof 2021 DF	0.331
ASVspoof 2024 Eval	0.384
Fake-or-Real	0.133
CodecFake	1.538
ADD 2022 Track 1	5.059
ADD 2022 Track 3	1.174
ADD 2023 R1	1.041
ADD 2023 R2	1.742
DFADD	0.000
LibriSeVoc	0.265
SONAR	0.888

Among the top-performing models, the margins for the highest rankings are extremely slim, making for a competitive field. Some models also compensate for scores with smaller models and fast processing times (Hive claims a noteworthy





across six datasets, despite how challenging each is in its own right.

In the remaining benchmarks, we remain competitive, steadfastly challenging the results of other submitted systems.

With all the success across the datasets, though, it is the 1.1% Average EER in production that demonstrates impressive generalization across all real-world applications and synthesis methods.

For those outside of the ASR industry, a 1.466% Average EER difference between Modulate and the next system might not seem like it'd make much difference in application. In reality, that difference amounts to 60% more deepfakes caught, or half as many (150,000) fewer false positives per 10 million calls. All done on a model that is 10x smaller.

For banks, insurance companies, and customer service teams, this could account for millions in losses.

Now consider that this unprecedented level of accuracy costs just \$0.25/hr. You also gain both batch and streaming modes, and a structured output offered in four confidence segments (meaning you'll get four separate scores representing levels of certainty about the predictions).

A lower-cost ASR model means continuous coverage

That \$0.25/hr is 100x more affordable than our competitors, thanks to an inherently efficient and smaller model. This isn't just nice to have while maintaining the highest level of accuracy in deepfake detection; it's absolutely essential to stopping fraudsters.

Most banks, insurance companies, and call centers *are* checking for fraud. However, they're running these checks at the beginning of calls and hitting the off switch early to avoid the high costs that come with longer run times.





voice once they're through it.

An affordable cost structure makes it possible to check the entire call, not just the opening seconds. You can run every single segment, for every speaker, continuously and even in the background.

The efficiency question: Does a smaller model really matter?

Hiya has highlighted their 1 billion parameter model as more efficient than other systems.

It's a legitimate claim, since model efficiency matters for both deployment cost and latency. However, this claim doesn't hold water when tested against other approaches to efficiency and accuracy.

Modulate is already a smaller model than most, but it gains an additional advantage with its voice-native architecture. This architecture provides an inherent efficiency advantage because it doesn't need to process the full complexity of language.

The models operate purely on acoustic features, avoiding the computational overhead associated with transformer-driven language processing.

Not to mention the avoidance of the post-processing most repurposed models typically need, which dramatically decreases their efficiency.

Voice-native architecture leads them all in accuracy, efficiency, and cost





impressive accuracy. But it is Modulate's voice-native architecture that delivers the best results, consistently.

We deliver this pivotal performance thanks to our consistent testing and training with noisy voice data. We built our models on half a billion hours of real audio, focusing on a diverse range of vocal tones, speech rhythms, and pronunciations that appear in patterns over longer audio segments.


This helps us guarantee accuracy, as seen in the HF benchmarks, at a price that allows businesses to continually run Modulate without significantly driving total costs higher.

As the scale of deepfake attacks grows, you need a solution that can scale with them. You need **Modulate**.

← **Previous**

How Deepgram and Modulate Benchmark
Against Real-World Audio





Modulate @modulate

Modulate is building the voice layer for the internet.

[Read my stories](#)

[About @modulate](#)

Comments

Share your thoughts...

More than AI Detector. Preserve **what's human**.

TOPICS

machine-learning #deepfake-detection #voice-ai

#ai-benchmarks #audio-deepfakes #fraud-prevention

#deepfake-benchmarks #huggingface #good-company

THIS ARTICLE WAS FEATURED IN



Arweave

ViewBlock

Terminal

Lite



X



Bsky



Хакернун

Write



#SPONSORED

Assure your apps with modern API Monitoring

Catchpoint

#SPEECH-TO-TEXT-AI

How Deepgram and Modulate Benchmark Against Real-World Audio

Modulate

Apr 14, 2026

#ARTIFICIAL - INTELLIGENCE

I Wired 800,000 Living Neurons Into an LLM. Here's What Actually Happened.

ARTIST

Mar 25, 2026

#ARTIFICIAL - INTELLIGENCE

Qwen3.5-9b-uncensored-hauhaucs-Aggressive Model: A Beginner's Guide to Get You Started

aimodels44

Mar 25, 2026

#MYTHOS

Is Mythos Really The Internet's Greatest Cybersecurity Risk? Or Just an Anthropic Product Launch?

Cyber Espionage

Apr 08, 2026

#LANGUAGE - MODELS

Orca 2: Enhancing Reasoning in Smaller Language Models - Abstract and Introduction


Writings, Papers and Blogs on Text Models

May 29, 2024





Современный мониторинг API для ваших приложений



THE HACKERNOON NEWSLETTER

name@company.com

Subscribe

☐ I agree to receive electronic content from HackerNoon



Available on
App Store



Available on
Google Play

ABOUT

Careers

Contact

Cookies

Emails

HackerNoon AI

HackerNoon CV

HackerNoon

Terms of Service

READ

Archive

Categories

Editors' Picks

Picks

Image Gallery

Leaderboard

Newsletters

Open Source

WRITE

Distribution

Editing Protocol

Get Published

Guidelines

Help

New Story

Submit

BUSINESS

Blogging

Contests

Book Demo Meeting

Business

Blogging

Case Studies

Company

Directorv



Хакернун

Write



What Customers Say

