

Сеть Хопфилда

Сеть Хопфилда (или **ассоциативная память**) — это разновидность **рекуррентной нейронной сети** или система **спинового стекла**, которая может служить **контентно-адресуемой памятью**. Сеть Хопфилда, названная в честь **Джона Хопфилда**, состоит из одного слоя нейронов, где каждый нейрон связан со всеми остальными нейронами, кроме самого себя. Эти связи являются двунаправленными и симметричными, то есть вес связи между нейроном i и нейроном j равен весу связи между нейроном j и нейроном i . Паттерны ассоциативно воспроизводятся при фиксации определенных входных данных и динамически изменяют сеть таким образом, чтобы минимизировать энергетическую функцию, приближаясь к локальным состояниям с минимальной энергией, которые соответствуют сохраненным паттернам. Паттерны ассоциативно усваиваются (или «сохраняются») с помощью алгоритма **обучения Хебба**.


Одной из ключевых особенностей сетей Хопфилда является их способность восстанавливать полные паттерны на основе частичных или зашумленных входных данных, что делает их устойчивыми к неполным или поврежденным данным. Благодаря связи со статистической механикой, рекуррентными сетями и когнитивной психологией человека, сети Хопфилда нашли применение в различных областях, включая **физику**, **психологию**, **нейронауку**, а также в теории и практике машинного обучения. Из-за бинарных нейронов (± 1 или $0/1$), ограниченной масштабируемости и несовместимости с обучением на основе градиента классические сети Хопфилда редко используются в современном машинном обучении.

История

Одним из источников ассоциативной памяти является человеческая **когнитивная психология**, в частности **ассоциативная память**. **Фрэнк Розенблатт** изучал «перцептроны с обратной связью», которые представляют собой трёхслойные **перцептроны**, средний слой которых содержит рекуррентные связи, изменяющиеся по правилу **обучения Хебба**.

[1]: 73–75 [2]: Глава 19, 21

Другая модель ассоциативной памяти заключается в том, что выходные данные не возвращаются к входным. У. К. Тейлор предложил такую модель, разработанную Hebbian learning в 1956 году.^[3] **Карл Штайнбух**, который хотел понять процесс обучения и был вдохновлен наблюдением за обучением своих детей,^[4] опубликовал **Lernmatrix** в 1961 году.^{[5][6]} Он был переведен на английский в 1963 году.^[7] Аналогичное исследование было проведено с **коррелограмма** Д. Дж. Уилшоу и др. в 1969 году.^[8] **Теуво Кохонен** тренировал ассоциативную память методом градиентного спуска в 1974 году.^[9]



Сеть перцептронов с обратной связью и перекрестными связями. [2]: 403, рис. 47

Другим источником ассоциативной памяти стала [статистическая механика](#). Модель Изинга была опубликована в 1920-х годах как модель магнетизма, однако в ней изучалось тепловое равновесие, которое не меняется с течением времени. [Рой Дж. Глаубер](#) в 1963 году исследовал эволюцию модели Изинга во времени как процесс, ведущий к тепловому равновесию ([динамика Глаубера](#)), добавив в модель компонент времени. [10][11]

Вторым добавленным компонентом стала адаптация к раздражителю. Этот компонент был добавлен независимо друг от друга разными исследователями, в том числе Розенблаттом (1960), [1]: 73–75 Каору Накано (1971), [12][13] и [Шунъити Амари](#) (1972). [14] Они предложили изменять весовые коэффициенты модели Изинга по правилу [хеббовского обучения](#) в качестве модели ассоциативной памяти. Та же идея была опубликована [Уильямом А. Литтлом](#) в 1974 году, [15] и Хопфилд упомянул его в своей статье 1982 года.


Техническое описание некоторых из этих ранних работ по ассоциативной памяти можно найти у Карпентера (1989) [16] и Коуэна (1990) [17].

[Модель Шеррингтона — Киркпатрика](#) спинового стекла, опубликованная в 1975 году, [18] представляет собой сеть Хопфилда со случайной инициализацией. Шеррингтон и Киркпатрик обнаружили, что функция энергии в модели Шеррингтона — Киркпатрика с большой вероятностью может иметь множество локальных минимумов. В статье 1982 года Хопфилд применил эту недавно разработанную теорию для изучения сети Хопфилда с бинарными функциями активации. [19] В статье 1984 года он распространил этот подход на непрерывные функции активации. [20] Она стала стандартной моделью для изучения нейронных сетей с помощью статистической механики. [21][22]

В 2016 году Дмитрий Кротов и Хопфилд добились значительного увеличения объема памяти [23] за счет изменения сетевой динамики и энергетической функции. В 2017 году Демирджигил и его коллеги развили эту идею. [24] В серии статей, опубликованных в период с 2016 по 2020 год, была описана непрерывная динамика моделей с большой ёмкостью памяти. [23][25][26] Сети Хопфилда с большой ёмкостью памяти теперь называются плотными ассоциативными сетями или [современными сетями Хопфилда](#).

In 2024, John J. Hopfield and [Geoffrey E. Hinton](#) were awarded the [Nobel Prize in Physics](#) for their foundational contributions to machine learning, such as the Hopfield network.

Структура



Сеть Хопфилда с четырьмя узлами

Узлы в сетях Хопфилда являются бинарными пороговыми элементами, то есть могут принимать только два разных значения в зависимости от того, превышает ли входной сигнал узла пороговое значение. U_i Дискретные сети Хопфилда описывают взаимосвязи между бинарными (возбужденными или невозбужденными) нейронами.

$1, 2, \dots, i, j, \dots, N$.^[19] В определенный момент состояние нейронной сети описывается вектором V , который записывает, какие нейроны активируются, в двоичном коде N биты.

Взаимодействия w_{ij} Между нейронами существуют связи, которые обычно имеют значения 1 или -1 , и в этой статье мы будем придерживаться этого соглашения. Однако в других источниках могут использоваться значения 0 и 1. Эти связи «выучиваются» с помощью [закона ассоциаций Хебба](#), согласно которому для определенного состояния V^s и отдельные узлы i, j

$$w_{ij} = V_i^s V_j^s$$

но $w_{ii} = 0$.

(Обратите внимание, что правило обучения Хебба имеет следующий вид:

$$w_{ij} = (2V_i^s - 1)(2V_j^s - 1) \text{ когда единицы измерения принимают значения в } \{0, 1\}.)$$

После обучения нейросети w_{ij} больше не эволюционируют. Если новое состояние нейронов $V^{s'}$ При введении в нейронную сеть она воздействует на нейроны таким образом, что

- $V_i^{s'} \rightarrow 1$ если $\sum_j w_{ij} V_j^{s'} \geq U_i$
- $V_i^{s'} \rightarrow -1$ если $\sum_j w_{ij} V_j^{s'} < U_i$

где U_i — пороговое значение i -го нейрона (часто принимается равным 0).^[27] Таким образом, сети Хопфилда способны «запоминать» состояния, хранящиеся в матрице взаимодействия, поскольку при появлении нового состояния $V^{s'}$ Под воздействием матрицы взаимодействия каждый нейрон будет меняться до тех пор, пока не достигнет исходного состояния. V^s (см. раздел «Обновления» ниже).

Связи в сети Хопфилда обычно имеют следующие ограничения:

- $w_{ii} = 0, \forall i$ (ни одно устройство не связано само с собой)
- $w_{ij} = w_{ji}, \forall i, j$ (соединения симметричны)

Ограничение на симметричность весов гарантирует, что функция энергии будет монотонно уменьшаться в соответствии с правилами активации.^[28] Сеть с асимметричными весами может демонстрировать периодическое или хаотическое поведение, однако Хопфилд обнаружил, что такое поведение характерно лишь для относительно небольших участков фазового пространства и не влияет на способность сети функционировать как ассоциативная память с адресацией по содержимому.

Хопфилд также смоделировал нейронные сети для работы с непрерывными значениями, в которых электрический выход каждого нейрона представляет собой не бинарное значение, а величину в диапазоне от 0 до 1.^[20] Он обнаружил, что такой тип сети также способен сохранять и воспроизводить запомненные состояния.

Notice that every pair of units i and j in a Hopfield network has a connection that is described by the connectivity weight w_{ij} . In this sense, the Hopfield network can be formally described as a complete undirected graph $G = \langle V, f \rangle$, where V is a set of [McCulloch–Pitts neurons](#) and $f : V^2 \rightarrow \mathbb{R}$ is a function that links pairs of units to a real value, the connectivity weight.

Обновление

Обновление одного элемента (узла в графе, моделирующем искусственный нейрон) в сети Хопфилда выполняется по следующему правилу:

$$s_i \leftarrow \begin{cases} +1 & \text{if } \sum_j w_{ij} s_j \geq \theta_i, \\ -1 & \text{otherwise.} \end{cases}$$

где:

- w_{ij} — сила, с которой груз перемещается из точки j в точку i (вес груза).

- s_i — состояние элемента i .
- θ_i — порог срабатывания устройства i .

Обновления в сети Хопфилда можно выполнять двумя способами:

- **Асинхронный:** за раз обновляется только один элемент. Этот элемент может выбираться случайным образом, либо с самого начала может быть задан определенный порядок.
- **Синхронный:** все элементы обновляются одновременно. Для поддержания синхронизации в системе должны быть центральные часы. Некоторые считают этот метод менее реалистичным, поскольку в аналогичных биологических или физических системах, представляющих интерес, нет глобальных часов.

Нейроны «притягиваются» или «отталкиваются» друг от друга в пространстве состояний

Вес связи между двумя нейронами сильно влияет на их значения. Рассмотрим вес связи w_{ij} между двумя нейронами i и j . Если $w_{ij} > 0$ Правило обновления подразумевает, что:

- когда $s_j = 1$ Вклад j в взвешенную сумму положителен. Таким образом, s_i притягивается j к своему значению $s_i = 1$
- когда $s_j = -1$ Вклад j в взвешенную сумму отрицателен. С другой стороны, s_i подталкивается j к своему значению $s_i = -1$

Таким образом, значения нейронов i и j будут сближаться, если вес связи между ними положительный. И, наоборот, они будут отдаляться, если вес связи отрицательный.

Свойства сходимости дискретных и непрерывных сетей Хопфилда

Брук (<https://www.paradise.caltech.edu/bruck.html>) в своей статье 1990 года^[29] исследовал дискретные сети Хопфилда и доказал обобщенную теорему о сходимости, основанную на связи между динамикой сети и [разрезами в соответствующем графе](#). Это обобщение охватывало как асинхронную, так и синхронную динамику и включало в себя элементарные доказательства, основанные на жадных алгоритмах для [максимального разреза в графах](#). В последующей статье^[30] было дополнительно исследовано поведение любого нейрона как в сетях Хопфилда с дискретным, так и с непрерывным временем, когда соответствующая энергетическая функция минимизируется в процессе оптимизации. Брук показал^[29], что нейрон j меняет свое состояние *тогда и только тогда*, когда он еще больше уменьшает следующий смещенный псевдоразрыв. Дискретная сеть Хопфилда минимизирует следующий смещенный псевдоразрыв^[30] для матрицы синаптических весов сети Хопфилда.

$$J_{pseudo-cut}(k) = \sum_{i \in C_1(k)} \sum_{j \in C_2(k)} w_{ij} + \sum_{j \in C_1(k)} \theta_j$$

где $C_1(k)$ и $C_2(k)$ представляет собой набор нейронов, значения которых равны -1 и $+1$ соответственно в момент времени k . Более подробную информацию можно найти в недавней статье.^[30]

Сеть Хопфилда с дискретным временем всегда минимизирует в точности следующий псевдоразрез^{[29][30]}

$$U(k) = \sum_{i=1}^N \sum_{j=1}^N w_{ij} (s_i(k) - s_j(k))^2 + 2 \sum_{j=1}^N \theta_j s_j(k)$$


Сеть Хопфилда с непрерывным временем всегда минимизирует верхнюю границу следующего взвешенного разреза^[30]

$$V(t) = \sum_{i=1}^N \sum_{j=1}^N w_{ij} (f(s_i(t)) - f(s_j(t)))^2 + 2 \sum_{j=1}^N \theta_j f(s_j(t))$$

где $f(\cdot)$ Это сигмоидальная функция с нулевым центром.

С другой стороны, комплексная сеть Хопфилда, как правило, стремится минимизировать так называемую теневую часть комплексной весовой матрицы сети.^[31]

Энергия



Энергетический ландшафт сети Хопфилда, на котором показано текущее состояние сети (в верхней части), состояние аттрактора, к которому она в конечном итоге сведется, минимальный уровень энергии и область притяжения, заштрихованная зеленым. Обратите внимание, что при обновлении сети Хопфилда энергия всегда уменьшается.

Сети Хопфилда имеют скалярное значение, связанное с каждым состоянием сети, которое называется «энергией» E сети, где:

$$E = -\frac{1}{2} \sum_{i,j} w_{ij} s_i s_j + \sum_i \theta_i s_i$$

Эта величина называется «энергией», потому что при обновлении сетевых блоков она либо уменьшается, либо остается неизменной. Кроме того, при многократном обновлении сеть в конечном итоге придет в состояние, которое является [локальным минимумом](#) функции энергии (которая считается [функцией Ляпунова](#)). ^[19] Таким образом, если состояние является локальным минимумом функции энергии, то оно является стабильным состоянием сети. Обратите внимание, что эта энергетическая функция относится к общему классу моделей в [физике](#) под названием [модели Изинга](#); они, в свою очередь, являются частным случаем [марковских сетей](#), поскольку соответствующая [вероятностная мера](#), [мера Гиббса](#), обладает [свойством марковости](#).

Сеть Хопфилда в оптимизации

[Хопфилд](#) и [Танк](#) представили применение сети Хопфилда для решения классической задачи коммивояжера в 1985 году. ^[32] С тех пор сеть Хопфилда широко используется для оптимизации. Идея использования сети Хопфилда для решения задач оптимизации проста: если ограниченную или неограниченную целевую функцию можно представить в виде энергетической функции Хопфилда E , то существует сеть Хопфилда, точки равновесия которой представляют собой решения задачи ограниченной или неограниченной оптимизации. Минимизация энергетической функции Хопфилда позволяет минимизировать целевую функцию и соблюсти ограничения, поскольку ограничения «встроены» в синаптические веса сети. Несмотря на то, что включение ограничений оптимизации в синаптические веса является непростой задачей, многие сложные задачи оптимизации с ограничениями в различных дисциплинах были преобразованы в энергетическую функцию Хопфилда: системы ассоциативной памяти, аналого-цифровое преобразование, задача планирования в многозадачном производстве, квадратичное распределение и другие связанные с ними NP-полные задачи, задача распределения каналов в беспроводных сетях, задача маршрутизации в мобильных одноранговых сетях, восстановление изображений, системная идентификация, комбинаторная оптимизация и многое другое. Однако, хотя сложные задачи оптимизации можно преобразовать в энергетические функции Хопфилда, это не гарантирует сходимость к решению (даже за экспоненциальное время). ^[33]

Инициализация и запуск

Инициализация сетей Хопфилда осуществляется путем присвоения ячейкам значений, соответствующих желаемому начальному шаблону. Затем выполняются повторные обновления до тех пор, пока сеть не сойдется к шаблону-аттрактору. Сходимость, как правило, гарантирована, поскольку Хопфилд доказал, что аттракторы этой [нелинейной динамической системы](#) стабильны, а не периодичны или хаотичны, как в некоторых других системах. Таким образом, в контексте сетей Хопфилда шаблон-аттрактор — это

конечное стабильное состояние, шаблон, значения элементов которого не могут измениться в процессе обновления.

Обучение

Обучение сети Хопфилда заключается в снижении энергии состояний, которые сеть должна «запоминать». Это позволяет использовать сеть в качестве системы памяти с адресацией по содержимому, то есть сеть будет возвращаться к «запомненному» состоянию, если ей предоставить только часть этого состояния. Сеть можно использовать для восстановления состояния, наиболее близкого к исходному, на основе искаженных входных данных. Это называется ассоциативной памятью, поскольку она восстанавливает воспоминания на основе сходства. Например, если мы обучим сеть Хопфилда с пятью узлами таким образом, чтобы состояние $(1, -1, 1, -1, 1)$ было энергетическим минимумом, и дадим сети состояние $(1, -1, -1, -1, 1)$, она сойдётся к состоянию $(1, -1, 1, -1, 1)$. Таким образом, сеть обучена правильно, если энергия состояний, которые она должна запоминать, является локальным минимумом. Обратите внимание, что в отличие от обучения [перцептрона](#), пороговые значения нейронов никогда не обновляются.

Правила обучения

Для хранения информации в памяти сети Хопфилда можно использовать различные [правила обучения](#). Желательно, чтобы правило обучения обладало двумя следующими свойствами:

- *Локальное*: правило обучения является *локальным*, если каждый весовой коэффициент обновляется с использованием информации, доступной нейронам по обе стороны связи, связанной с этим весовым коэффициентом.
- *Инкрементальное*: новые паттерны можно изучать, не используя информацию о старых паттернах, которые также использовались для обучения. То есть при использовании нового паттерна для обучения новые значения весовых коэффициентов зависят только от старых значений и нового паттерна.^[34]

Эти свойства желательны, поскольку правило обучения, обладающее ими, более правдоподобно с биологической точки зрения. Например, поскольку человеческий мозг постоянно усваивает новые понятия, можно предположить, что процесс обучения у человека инкрементальный. Система обучения, не обладающая инкрементальностью, как правило, обучается только один раз на большом массиве обучающих данных.

Правило обучения Хебба для сетей Хопфилда

[Теория Хебба](#) была предложена Дональдом Хеббом в 1949 году для объяснения «ассоциативного обучения», при котором одновременная активация нейронных клеток

приводит к значительному увеличению синаптической силы между этими клетками. ^[35]
 Ее часто формулируют так: «Нейроны, которые возбуждаются одновременно, связываются друг с другом. Нейроны, которые возбуждаются не одновременно, не связываются».

Правило Хебба является локальным и инкрементальным. В сетях Хопфилда оно реализуется следующим образом: n бинарные паттерны:

$$w_{ij} = \frac{1}{n} \sum_{\mu=1}^n \epsilon_i^{\mu} \epsilon_j^{\mu}$$

where ϵ_i^{μ} represents bit i from pattern μ .

If the bits corresponding to neurons i and j are equal in pattern μ , then the product $\epsilon_i^{\mu} \epsilon_j^{\mu}$ will be positive. This would, in turn, have a positive effect on the weight w_{ij} and the values of i and j will tend to become equal. The opposite happens if the bits corresponding to neurons i and j are different.

Storkey learning rule


This rule was introduced by [Amos Storkey](#) in 1997 and is both local and incremental. Storkey also showed that a Hopfield network trained using this rule has a greater capacity than a corresponding network trained using the Hebbian rule. ^[36] The weight matrix of an attractor neural network is said to follow the Storkey learning rule if it obeys:

$$w_{ij}^{\nu} = w_{ij}^{\nu-1} + \frac{1}{n} \epsilon_i^{\nu} \epsilon_j^{\nu} - \frac{1}{n} \epsilon_i^{\nu} h_{ji}^{\nu} - \frac{1}{n} \epsilon_j^{\nu} h_{ij}^{\nu}$$

where $h_{ij}^{\nu} = \sum_{k=1: i \neq k \neq j}^n w_{ik}^{\nu-1} \epsilon_k^{\nu}$ is a form of *local field* ^[34] at neuron i .

This learning rule is local, since the synapses take into account only neurons at their sides. The rule makes use of more information from the patterns and weights than the generalized Hebbian rule, due to the effect of the local field.

Ложные закономерности



10 случайных битов изначально
были перевернуты

15 случайных битов изначально
были инвертированы (что
привело к появлению ложного
шаблона)

Динамика Хопфилда в сети из $5 \times 5 = 25$ нейронов, обученных запоминать один паттерн «Е» черного цвета

Шаблоны, которые сеть использует для обучения (так называемые *состояния извлечения*), становятся аттракторами системы. Повторные обновления в конечном итоге приводят к сходимости к одному из состояний извлечения. Однако иногда сеть сходится к ложным шаблонам (отличным от шаблонов, используемых для обучения).^[37] На самом деле количество ложных шаблонов может быть экспоненциально большим по сравнению с количеством сохраненных шаблонов, даже если они ортогональны друг другу.^[38] Энергия этих ложных шаблонов также является локальным минимумом. Для каждого сохраненного шаблона x отрицание $-x$ также является ложным шаблоном.

Ложное состояние также может быть *линейной комбинацией* нечетного числа состояний поиска. Например, при использовании 3 шаблонов μ_1, μ_2, μ_3 Таким образом можно получить следующее ложное утверждение:

$$\epsilon_i^{\text{mix}} = \pm \text{sgn}(\pm \epsilon_i^{\mu_1} \pm \epsilon_i^{\mu_2} \pm \epsilon_i^{\mu_3})$$

Ложные паттерны с четным числом состояний существовать не могут, поскольку их сумма может равняться нулю.^[37]

Вместимость

Пропускная способность нейронной сети Хопфилда определяется количеством нейронов и связей в ней. Таким образом, количество запоминаемых данных зависит от нейронов и связей. Кроме того, было показано, что точность воспроизведения векторов и узлов составляет 0,138 (из хранилища можно извлечь примерно 138 векторов на каждые 1000 узлов) (Hertz et al., 1991). Таким образом, очевидно, что при попытке сохранить большое количество векторов будет возникать множество ошибок. Если модель Хопфилда не воспроизводит нужный паттерн, это может свидетельствовать о вторжении, поскольку семантически связанные элементы могут сбивать человека с толку, и он воспроизводит неправильный паттерн. Таким образом, модель сети Хопфилда может перепутать один

сохраненный элемент с другим при извлечении. Идеальные отзывы и высокая емкость, > 0,14, могут быть загружены в сеть методом обучения Storkey; ETAM,^{[39][40]} ETAM также экспериментирует в.^[41] Позже были разработаны дополнительные модели, вдохновленные сетью Хопфилда, для увеличения лимита памяти и снижения частоты ошибок при поиске, причем некоторые из них способны к [однократному обучению](#).^[42]

Объем памяти можно рассчитать по правилу Хебба. $C \cong \frac{n}{2 \ln n}$ где n — количество нейронов в сети.^[36]

Объем памяти, рассчитанный по правилу Стокей, может быть равен $C \cong \frac{n}{\sqrt{2 \ln n}}$ где n — количество нейронов в сети.^[36]

Человеческая память

Сеть Хопфилда — это модель ассоциативного обучения и запоминания человека.^{[43][44]} Она учитывает [ассоциативную память](#) за счет использования векторов памяти. Векторы памяти можно использовать в ограниченном объеме, и это приведет к извлечению наиболее похожего вектора из сети. Однако мы увидим, что из-за этого процесса могут возникать сбои. В ассоциативной памяти сети Хопфилда есть два типа операций: автоассоциация и гетероассоциация. В первом случае вектор связан сам с собой, а во втором — два разных вектора связаны в памяти. Кроме того, оба типа операций можно сохранить в одной матрице памяти, но только в том случае, если данная матрица представляет собой не одну из этих операций, а их комбинацию (автоассоциативную и гетероассоциативную).

В сетевой модели Хопфилда используется то же правило обучения, что и в [правиле обучения Хебба \(1949\)](#), согласно которому обучение происходит за счет усиления весовых коэффициентов в случае активности нейронов.

Риццуто и Кахана (2001) смогли показать, что модель нейронной сети может учитывать влияние повторения на точность воспроизведения, если в нее включен алгоритм вероятностного обучения. В процессе извлечения информации обучение не происходит. В результате весовые коэффициенты сети остаются неизменными, что свидетельствует о способности модели переключаться с этапа обучения на этап воспроизведения. Добавив контекстуальный дрейф, они смогли продемонстрировать быстрое забывание, которое происходит в модели Хопфилда при выполнении задания на воспроизведение по подсказке. Вся сеть влияет на изменение активности любого отдельного узла.

Динамическое правило Маккалока и Питтса (1943), описывающее поведение нейронов, показывает, как активация нескольких нейронов влияет на частоту импульсов нового

нейрона и как веса нейронов усиливают синаптические связи между новым активированным нейроном (и теми, которые его активировали). Хопфилд использовал динамическое правило Маккалока — Питтса, чтобы показать, как в его сети возможно извлечение информации. Однако Хопфилд делал это циклически. Вместо линейной функции он использовал нелинейную функцию активации. Так появилось динамическое правило Хопфилда, с помощью которого он смог показать, что при использовании нелинейной функции активации динамическое правило всегда будет изменять значения вектора состояния в направлении одного из сохраненных шаблонов.

Плотная ассоциативная память или современная сеть Хопфилда

Сети Хопфилда^{[19][20]} — это рекуррентные нейронные сети с динамическими траекториями, сходящимися к состояниям аттрактора с фиксированной точкой и описываемыми функцией энергии. Состояние каждого модельного нейрона i определяется зависимой от времени переменной V_i , которое может быть как дискретным, так и непрерывным. Полная модель описывает математически, как будущая активность каждого нейрона зависит от известной текущей или предыдущей активности всех нейронов.

В оригинальной модели ассоциативной памяти Хопфилда^[19] переменные были бинарными, а динамика описывалась последовательным обновлением состояния нейронов. Функция энергии была квадратичной. V_i была определена, а динамика заключалась в изменении активности каждого отдельного нейрона i только в том случае, если это снизит общую энергию системы. Эта же идея была распространена на случай V_i является непрерывной переменной, представляющей выходной сигнал нейрона i , и V_i является монотонной функцией входного тока. Динамика выражается в виде системы дифференциальных уравнений первого порядка, в которой «энергия» системы всегда уменьшается.^[20] В непрерывном случае энергия имеет один член, квадратичный по отношению к V_i (как в бинарной модели) и второй член, зависящий от функции усиления (функции активации нейрона). Несмотря на множество полезных свойств ассоциативной памяти, обе эти классические системы имеют небольшой объем памяти, который линейно зависит от количества входных признаков.^[19] Напротив, увеличив количество параметров в модели, чтобы между нейронами возникали не только попарные, но и более сложные взаимодействия, можно увеличить объем памяти.^{[45][46]}

Плотные ассоциативные сети^[23] (также известные как современные сети Хопфилда^[25]) — это обобщение классических сетей Хопфилда, в которых нарушается линейная зависимость между количеством входных признаков и количеством сохраненных воспоминаний. Это достигается за счет усиления нелинейных зависимостей (либо в

энергетической функции, либо в функциях активации нейронов), что приводит к сверхлинейной^[23] (и даже экспоненциальной^[24]) емкости памяти в зависимости от количества нейронных элементов, то есть к увеличению порядка взаимодействия между нейронами.^{[45][46]} При этом сети по-прежнему требуется достаточное количество скрытых нейронов.^[26]

The key theoretical idea behind dense associative memory networks is to use an energy function and an update rule that is more sharply peaked around the stored memories in the space of neuron's configurations compared to the classical model,^[23] as demonstrated when the higher-order interactions and subsequent energy landscapes are explicitly modelled.^[46]

Discrete variables

A simple example^[23] of the modern Hopfield network can be written in terms of **binary variables** V_i that represent the active $V_i = +1$ and inactive $V_i = -1$ state of the model neuron i .

$$E = - \sum_{\mu=1}^{N_{\text{mem}}} F\left(\sum_{i=1}^{N_f} \xi_{\mu i} V_i\right)$$

In this formula the weights $\xi_{\mu i}$ represent the matrix of memory vectors (index $\mu = 1 \dots N_{\text{mem}}$ enumerates different memories, and index $i = 1 \dots N_f$ enumerates the content of each memory corresponding to the i -th feature neuron), and the function $F(x)$ is a rapidly growing non-linear function. The update rule for individual neurons (in the asynchronous case) can be written in the following form

$$V_i^{(t+1)} = \text{Sign} \left[\sum_{\mu=1}^{N_{\text{mem}}} \left(F\left(\xi_{\mu i} + \sum_{j \neq i} \xi_{\mu j} V_j^{(t)}\right) - F\left(-\xi_{\mu i} + \sum_{j \neq i} \xi_{\mu j} V_j^{(t)}\right) \right) \right]$$

which states that in order to calculate the updated state of the i -th neuron the network compares two energies: the energy of the network with the i -th neuron in the ON state and the energy of the network with the i -th neuron in the OFF state, given the states of the remaining neuron. The updated state of the i -th neuron selects the state that has the lowest of the two energies.^[23]

In the limiting case when the non-linear energy function is quadratic $F(x) = x^2$ these equations reduce to the familiar energy function and the update rule for the classical binary Hopfield Network.^[19]

The memory storage capacity of these networks can be calculated for random binary patterns. For the power energy function $F(x) = x^n$ the maximal number of memories that can be stored and retrieved from this network without errors is given by^[23]

$$N_{\text{mem}}^{\text{max}} \approx \frac{1}{2(2n-3)!!} \frac{N_f^{n-1}}{\ln(N_f)}$$

For an exponential energy function $F(x) = e^x$ the memory storage capacity is exponential in the number of feature neurons^[24]

$$N_{\text{mem}}^{\text{max}} \approx 2^{N_f/2}$$




Fig. 1: An example of a continuous modern Hopfield network with $N_f = 5$ feature neurons and $N_{\text{mem}} = 11$ memory (hidden) neurons with symmetric synaptic connections between them.

Continuous variables

Modern Hopfield networks or dense associative memories can be best understood in continuous variables and continuous time.^{[25][26]} Consider the network architecture, shown in Fig.1, and the equations for neuron's states evolution^[26]

(1)

where the currents of the feature neurons are denoted by x_i , and the currents of the memory neurons are denoted by h_μ (h stands for hidden neurons). There are no synaptic connections among the feature neurons or the memory neurons. A matrix $\xi_{\mu i}$ denotes the strength of synapses from a feature neuron i to the memory neuron μ . The synapses are assumed to be symmetric, so that the same value characterizes a different physical synapse from the memory neuron μ to the feature neuron i . The outputs of the memory neurons and the feature neurons are denoted by f_μ and g_i , which are non-linear functions of the corresponding currents. In general these outputs can depend on the currents of all the neurons in that layer so that $f_\mu = f(\{h_\mu\})$ and $g_i = g(\{x_i\})$. It is convenient to define these activation functions as derivatives of the Lagrangian functions for the two groups of neurons

(2)

This way the specific form of the equations for neuron's states is completely defined once the Lagrangian functions are specified. Finally, the time constants for the two groups of neurons are

denoted by τ_f and τ_h , I_i is the input current to the network that can be driven by the presented data.

	Model A	Model B	Model C
Lagrangian functions	$L_h = \sum_{\mu=1}^{N_h} F(h_\mu)$ $L_x = \sum_{i=1}^{N_f} x_i $	$L_h = \log \left(\sum_{\mu=1}^{N_h} e^{h_\mu} \right)$ $L_x = \frac{1}{2} \sum_{i=1}^{N_f} x_i^2$	$L_h = \sum_{\mu=1}^{N_h} F(h_\mu)$ $L_x = \sqrt{\sum_{i=1}^{N_f} x_i^2}$
energy	$E = - \sum_{\mu=1}^{N_h} F \left(\sum_{i=1}^{N_f} \xi_{\mu i} V_i \right)$	$E = \frac{1}{2} \sum_{i=1}^{N_f} x_i^2 - \log \left(\sum_{\mu=1}^{N_h} \exp \left(\sum_{i=1}^{N_f} \xi_{\mu i} x_i \right) \right)$	$E = - \sum_{\mu=1}^{N_h} F \left(\sum_{i=1}^{N_f} \xi_{\mu i} \frac{x_i}{\sqrt{\sum_j x_j^2}} \right)$
effective update rule	$\tau \frac{dx_i}{dt} = \sum_{\mu=1}^{N_h} \xi_{i\mu} f \left(\sum_{j=1}^{N_f} \xi_{\mu j} V_j \right) - x_i$	$\tau \frac{dx_i}{dt} = \sum_{\mu=1}^{N_h} \xi_{i\mu} \text{softmax} \left(\sum_{j=1}^{N_f} \xi_{\mu j} x_j \right) - x_i$	$\tau \frac{dx_i}{dt} = \sum_{\mu=1}^{N_h} \xi_{i\mu} f \left[\sum_{j=1}^{N_f} \xi_{\mu j} \frac{x_j}{\sqrt{\sum_k x_k^2}} \right] - x_i$

Fig. 2: Effective theory on the feature neurons for various common choices of the Lagrangian functions. Model A reduces to the models studied in [23][24] depending on the choice of the activation function, model B reduces to the model studied in [25] model C reduces to the model of [26] F is a "smooth enough" function. [23]

General systems of non-linear differential equations can have many complicated behaviors that can depend on the choice of the non-linearities and the initial conditions. For Hopfield Networks, however, this is not the case - the dynamical trajectories always converge to a fixed point attractor state. This property is achieved because these equations are specifically engineered so that they have an underlying energy function [26]

(3)

The terms grouped into square brackets represent a Legendre transform of the Lagrangian function with respect to the states of the neurons. If the Hessian matrices of the Lagrangian functions are positive semi-definite, the energy function is guaranteed to decrease on the dynamical trajectory [26]

(4)

This property makes it possible to prove that the system of dynamical equations describing temporal evolution of neurons' activities will eventually reach a fixed point attractor state.

In certain situations one can assume that the dynamics of hidden neurons equilibrates at a much faster time scale compared to the feature neurons, $\tau_h \ll \tau_f$. In this case the steady state solution of the second equation in the system (1) can be used to express the currents of the hidden units through the outputs of the feature neurons. This makes it possible to reduce the general theory (1) to an effective theory for feature neurons only. The resulting effective update rules and the energies for various common choices of the Lagrangian functions are shown in

Fig.2. In the case of log-sum-exponential Lagrangian function the update rule (if applied once) for the states of the feature neurons is the attention mechanism^[25] commonly used in many modern AI systems (see Ref.^[26] for the derivation of this result from the continuous time formulation).

Relationship to classical Hopfield network with continuous variables

Classical formulation of continuous Hopfield Networks^[20] can be understood^[26] as a special limiting case of the modern Hopfield networks with one hidden layer. Continuous Hopfield Networks for neurons with graded response are typically described^[20] by the dynamical equations

(5)

and the energy function

(6)

where $V_i = g(x_i)$, and $g^{-1}(z)$ is the inverse of the activation function $g(x)$. This model is a special limit of the class of models that is called models A,^[26] with the following choice of the Lagrangian functions

(7)

that, according to the definition (2), leads to the activation functions

(8)

If we integrate out the hidden neurons the system of equations (1) reduces to the equations on

the feature neurons (5) with $T_{ij} = \sum_{\mu=1}^{N_h} \xi_{\mu i} \xi_{\mu j}$, and the general expression for the energy (3)

reduces to the effective energy

(9)

While the first two terms in equation (6) are the same as those in equation (9), the third terms look superficially different. In equation (9) it is a Legendre transform of the Lagrangian for the feature neurons, while in (6) the third term is an integral of the inverse activation function.

Nevertheless, these two expressions are in fact equivalent, since the derivatives of a function and its Legendre transform are inverse functions of each other. The easiest way to see that these two terms are equal explicitly is to differentiate each one with respect to $\mathbf{x}_i$. The results of these differentiations for both expressions are equal to $\mathbf{x}_i g(\mathbf{x}_i)'$. Thus, the two expressions are equal up to an additive constant. This completes the proof^[26] that the classical Hopfield Network with continuous states^[20] is a special limiting case of the modern Hopfield network (1) with energy (3).

General formulation of the modern Hopfield network




Fig. 3: The connectivity diagram of the fully-connected modern Hopfield network consisting of five neurons. The synaptic weights are described by a symmetric matrix $\mathbf{W}_{IJ}$.

Biological neural networks have a large degree of heterogeneity in terms of different cell types. This section describes a mathematical model of a fully connected modern Hopfield network assuming the extreme degree of heterogeneity: every single neuron is different.^[47] Specifically, an energy function and the corresponding dynamical equations are described assuming that each neuron has its own activation function and kinetic time scale. The network is assumed to be fully connected, so that every neuron is connected to every other neuron using a symmetric matrix of weights $\mathbf{W}_{IJ}$, indices I and J enumerate different neurons in the network, see Fig.3. The easiest way to mathematically formulate this problem is to define the architecture through a Lagrangian function $L(\{\mathbf{x}_I\})$ that depends on the activities of all the neurons in the network. The activation function for each neuron is defined as a partial derivative of the Lagrangian with respect to that neuron's activity

(10)

From the biological perspective one can think about $\mathbf{g}_I$ as an axonal output of the neuron I . In the simplest case, when the Lagrangian is additive for different neurons, this definition results in the activation that is a non-linear function of that neuron's activity. For non-additive Lagrangians this activation function can depend on the activities of a group of neurons. For instance, it can contain contrastive (softmax) or divisive normalization. The dynamical equations describing temporal evolution of a given neuron are given by^[47]

(11)

This equation belongs to the class of models called firing rate models in neuroscience. Each neuron I collects the axonal outputs $\mathbf{g}_J$ from all the neurons, weights them with the synaptic coefficients $\mathbf{W}_{IJ}$ and produces its own time-dependent activity $\mathbf{x}_I$. The temporal evolution has a time constant τ_I , which in general can be different for every neuron. This network has a global energy function^[47]

(12)

where the first two terms represent the Legendre transform of the Lagrangian function with respect to the neurons' currents $\mathbf{x}_I$. The temporal derivative of this energy function can be computed on the dynamical trajectories leading to (see ^[47] for details)

(13)

The last inequality sign holds provided that the matrix $\mathbf{M}_{IK}$ (or its symmetric part) is positive semi-definite. If, in addition to this, the energy function is bounded from below the non-linear dynamical equations are guaranteed to converge to a fixed point attractor state. The advantage of formulating this network in terms of the Lagrangian functions is that it makes it possible to easily experiment with different choices of the activation functions and different architectural arrangements of neurons. For all those flexible choices the conditions of convergence are determined by the properties of the matrix $\mathbf{M}_{IJ}$ and the existence of the lower bound on the energy function.




Fig. 4: The connectivity diagram of the layered Hierarchical Associative Memory network.^[47] Each layer can have different number of neurons, different activation function, and different time scales. The feedforward weights and feedback weights are equal.

Hierarchical associative memory network

The neurons can be organized in layers so that every neuron in a given layer has the same activation function and the same dynamic time scale. If we assume that there are no horizontal connections between the neurons within the layer (lateral connections) and there are no skip-layer connections, the general fully connected network (11), (12) reduces to the architecture shown in Fig.4. It has N_{layer} layers of recurrently connected neurons with the states described by continuous variables x_i^A and the activation functions g_i^A , index A enumerates the layers of the network, and index i enumerates individual neurons in that layer. The activation functions can depend on the activities of all the neurons in the layer. Every layer can have a different number of neurons N_A . These neurons are recurrently connected with the neurons in the preceding and the subsequent layers. The matrices of weights that connect neurons in layers A and B are denoted by $\xi_{ij}^{(A,B)}$ (the order of the upper indices for weights is the same as the order of the lower indices, in the example above this means that the index i enumerates neurons in the layer A , and index j enumerates neurons in the layer B). The feedforward weights and the feedback weights are equal. The dynamical equations for the neurons' states can be written as^[47]

(14)

with boundary conditions

(15)

The main difference between these equations and those from the conventional feedforward networks is the presence of the second term, which is responsible for the feedback from higher layers. These top-down signals help neurons in lower layers to decide on their response to the presented stimuli. Following the general recipe it is convenient to introduce a Lagrangian function $L^A(\{x_i^A\})$ for the A -th hidden layer, which depends on the activities of all the neurons in that layer.^[47] The activation functions in that layer can be defined as partial derivatives of the Lagrangian

(16)

With these definitions the energy (Lyapunov) function is given by^[47]

(17)

If the Lagrangian functions, or equivalently the activation functions, are chosen in such a way that the Hessians for each layer are positive semi-definite and the overall energy is bounded from below, this system is guaranteed to converge to a fixed point attractor state. The temporal derivative of this energy function is given by^[47]

(18)

Thus, the hierarchical layered network is indeed an attractor network with the global energy function. This network is described by a hierarchical set of synaptic weights that can be learned for each specific problem.

См. также

-
- [Ассоциативная память \(значения\)](#)
 - [Автоассоциативная память](#)
 - [Машина Больцмана](#) — похожа на сеть Хопфилда, но использует отжиг [сэмплирование Гиббса](#) вместо [градиентного спуска](#)
 - [Модель познания на основе динамических систем](#)

- [Модель Изинга](#)
- [Теория Хебба](#)

ССЫЛКИ

1. Ф. Розенблатт, "[Обобщение восприятия в группах преобразований](#)", стр. 63–100 в «*Самоорганизующиеся системы: материалы междисциплинарной конференции, 5 и 6 мая 1959 года*». Под редакцией Маршалла К. Йовица и Скотта Кэмерона. Лондон, Нью-Йорк, [и др.], Pergamon Press, 1960. ix, 322 с.
2. Розенблатт, Фрэнк (15 марта 1961 г.). [DTIC AD0256582: ПРИНЦИПЫ НЕЙРОДИНАМИКИ. ПЕРЦЕПТРЫ И ТЕОРИЯ МЕХАНИЗМОВ МОЗГА](#) (https://archive.org/details/DTIC_AD0256582/page/n3/mode/2up) . Центр технической информации Министерства обороны США.
3. У. К. Тейлор, 1956. *Электрическое моделирование некоторых функциональных процессов нервной системы*. Теория информации 3, Э. К. Черри (ред.), стр. 314-328. Лондон: Баттервортс.
4. [Надгробная речь: 1917 Карл Штайнбух, 2005](#) (https://www.itiv.kit.edu/downloads/euology_1_.pdf) . Бернард Уидроу, Райнер Хартенштейн, Роберт Хехт-Нильсен, IEEE Computational Intelligence Society. страница 5. Август 2005 года.
5. Штейнбух, К. (1961-01-01). "[Матрица обучения](#)" (<https://link.springer.com/article/10.1007/BF00293853>) . *Kybernetik* (на немецком языке). **1** (1): 36–45. doi:10.1007/BF00293853 (<https://doi.org/10.1007%2FBF00293853>) . ISSN 1432-0770 (<https://search.worldcat.org/issn/1432-0770>) .
6. Штейнбух, Карл (1961). *Автомат и человек: о человеческом и машинном интеллекте*. Берлин: Springer. ISBN 978-3-642-53168-2. OL 27019478M (<https://openlibrary.org/books/OL27019478M>) .
7. Штейнбух К., Писке У. А. В. (декабрь 1963 г.). «Обучающие матрицы и их применение». *IEEE Transactions on Electronic Computers*. EC-12 (6): 846–862. Bibcode:1963ITECm..12..846S (<https://ui.adsabs.harvard.edu/abs/1963ITECm..12..846S>) . doi:10.1109/PGEC.1963.263588 (<https://doi.org/10.1109%2FPGEC.1963.263588>) . ISSN 0367-7508 (<https://search.worldcat.org/issn/0367-7508>) .
8. Уилшоу Д. Дж., Бунеман О. П., Лонге-Хиггинс Х. К. (июнь 1969 г.). «[Неголографическая ассоциативная память](#)» (<https://www.nature.com/articles/222960a0>) . *Nature*. **222** (5197): 960–962. Bibcode:1969Natur.222..960W (<https://ui.adsabs.harvard.edu/abs/1969Natur.222..960W>) . doi:10.1038/222960a0 (<https://doi.org/10.1038%2F222960a0>) . ISSN 0028-0836 (<https://search.worldcat.org/issn/0028-0836>) . PMID 5789326 (<https://pubmed.ncbi.nlm.nih.gov/5789326>) .

9. Kohonen, T. (April 1974). "An Adaptive Associative Memory Principle". *IEEE Transactions on Computers*. **C-23** (4): 444–445. Bibcode:1974ITCmp.100..444K (<https://ui.adsabs.harvard.edu/abs/1974ITCmp.100..444K>) . doi:10.1109/T-C.1974.223960 (<https://doi.org/10.1109%2FT-C.1974.223960>) . ISSN 0018-9340 (<https://search.worldcat.org/issn/0018-9340>) .
10. Glauber, Roy J. (February 1963). "Roy J. Glauber "Time-Dependent Statistics of the Ising Model" " (<https://aip.scitation.org/doi/abs/10.1063/1.1703954>) . *Journal of Mathematical Physics*. **4** (2): 294–307. doi:10.1063/1.1703954 (<https://doi.org/10.1063%2F1.1703954>) . Retrieved 2021-03-21.
11. Süzen, Mehmet (29 September 2014). "Effective ergodicity in single-spin-flip dynamics" (<http://journals.aps.org/pre/abstract/10.1103/PhysRevE.90.032141>) . *Physical Review E*. **90** (3) 032141. arXiv:1405.4497 (<https://arxiv.org/abs/1405.4497>) . Bibcode:2014PhRvE..90c2141S (<https://ui.adsabs.harvard.edu/abs/2014PhRvE..90c2141S>) . doi:10.1103/PhysRevE.90.032141 (<https://doi.org/10.1103%2FPhysRevE.90.032141>) . PMID 25314429 (<https://pubmed.ncbi.nlm.nih.gov/25314429>) . S2CID 118355454 (<https://api.semanticscholar.org/CorpusID:118355454>) . Retrieved 2022-08-09.
12. Nakano, Kaoru (1971). "Learning Process in a Model of Associative Memory". *Pattern Recognition and Machine Learning*. pp. 172–186. doi:10.1007/978-1-4615-7566-5_15 (https://doi.org/10.1007%2F978-1-4615-7566-5_15) . ISBN 978-1-4615-7568-9.
13. Nakano, Kaoru (1972). "Associatron-A Model of Associative Memory". *IEEE Transactions on Systems, Man, and Cybernetics*. SMC-2 (3): 380–388. Bibcode:1972ITSMC...2..380N (<https://ui.adsabs.harvard.edu/abs/1972ITSMC...2..380N>) . doi:10.1109/TSMC.1972.4309133 (<https://doi.org/10.1109%2FTSMC.1972.4309133>) .
14. Amari, Shun-ichi (1972). "Learning patterns and pattern sequences by self-organizing nets of threshold elements". *IEEE Transactions*. **C** (21): 1197–1206.
15. Little, W. A. (1974). "The Existence of Persistent States in the Brain". *Mathematical Biosciences*. **19** (1–2): 101–120. doi:10.1016/0025-5564(74)90031-5 (<https://doi.org/10.1016%2F0025-5564%2874%2990031-5>) .
16. Carpenter, Gail A (1989-01-01). "Neural network models for pattern recognition and associative memory" (<https://www.sciencedirect.com/science/article/abs/pii/089360808990035X>) . *Neural Networks*. **2** (4): 243–257. Bibcode:1989NN.....2..243C (<https://ui.adsabs.harvard.edu/abs/1989NN.....2..243C>) . doi:10.1016/0893-6080(89)90035-X (<https://doi.org/10.1016%2F0893-6080%2889%2990035-X>) . ISSN 0893-6080 (<https://search.worldcat.org/issn/0893-6080>) .

17. Cowan, Jack D. (January 1990). "Discussion: McCulloch-Pitts and related neural nets from 1943 to 1989" (<http://link.springer.com/10.1007/BF02459569>) . *Bulletin of Mathematical Biology*. **52** (1–2): 73–97. doi:10.1007/BF02459569 (<https://doi.org/10.1007%2FBF02459569>) . ISSN 0092-8240 (<https://search.worldcat.org/issn/0092-8240>) .
18. Sherrington, David; Kirkpatrick, Scott (1975-12-29). "Solvable Model of a Spin-Glass" (<http://link.aps.org/doi/10.1103/PhysRevLett.35.1792>) . *Physical Review Letters*. **35** (26): 1792–1796. Bibcode:1975PhRvL..35.1792S (<https://ui.adsabs.harvard.edu/abs/1975PhRvL..35.1792S>) . doi:10.1103/PhysRevLett.35.1792 (<https://doi.org/10.1103%2FPhysRevLett.35.1792>) . ISSN 0031-9007 (<https://search.worldcat.org/issn/0031-9007>) .
19. Hopfield, J. J. (1982). "Neural networks and physical systems with emergent collective computational abilities" (<https://www.ncbi.nlm.nih.gov/pmc/articles/PMC346238>) . *Proceedings of the National Academy of Sciences*. **79** (8): 2554–2558. Bibcode:1982PNAS...79.2554H (<https://ui.adsabs.harvard.edu/abs/1982PNAS...79.2554H>) . doi:10.1073/pnas.79.8.2554 (<https://doi.org/10.1073%2Fpnas.79.8.2554>) . PMC 346238 (<https://www.ncbi.nlm.nih.gov/pmc/articles/PMC346238>) . PMID 6953413 (<https://pubmed.ncbi.nlm.nih.gov/6953413>) .
20. Hopfield, J. J. (1984). "Neurons with graded response have collective computational properties like those of two-state neurons" (<https://www.ncbi.nlm.nih.gov/pmc/articles/PMC345226>) . *Proceedings of the National Academy of Sciences*. **81** (10): 3088–3092. Bibcode:1984PNAS...81.3088H (<https://ui.adsabs.harvard.edu/abs/1984PNAS...81.3088H>) . doi:10.1073/pnas.81.10.3088 (<https://doi.org/10.1073%2Fpnas.81.10.3088>) . PMC 345226 (<https://www.ncbi.nlm.nih.gov/pmc/articles/PMC345226>) . PMID 6587342 (<https://pubmed.ncbi.nlm.nih.gov/6587342>) .
21. Engel, A.; Broeck, C. van den (2001). *Statistical mechanics of learning*. Cambridge, UK; New York, NY: Cambridge University Press. ISBN 978-0-521-77307-2.
22. Seung, H. S.; Sompolinsky, H.; Tishby, N. (1992-04-01). "Statistical mechanics of learning from examples" (<https://journals.aps.org/pr/abstract/10.1103/PhysRevA.45.6056>) . *Physical Review A*. **45** (8): 6056–6091. Bibcode:1992PhRvA..45.6056S (<https://ui.adsabs.harvard.edu/abs/1992PhRvA..45.6056S>) . doi:10.1103/PhysRevA.45.6056 (<https://doi.org/10.1103%2FPhysRevA.45.6056>) . PMID 9907706 (<https://pubmed.ncbi.nlm.nih.gov/9907706>) .
23. Krotov, Dmitry; Hopfield, John (2016). "Dense Associative Memory for Pattern Recognition". *Neural Information Processing Systems*. **29**: 1172–1180. arXiv:1606.01164 (<https://arxiv.org/abs/1606.01164>) .

24. Mete, Demircigil; et al. (2017). "On a model of associative memory with huge storage capacity" (<https://link.springer.com/article/10.1007/s10955-017-1806-y>) . *Journal of Statistical Physics*. **168** (2): 288–299. arXiv:1702.01929 (<https://arxiv.org/abs/1702.01929>) . Bibcode:2017JSP...168..288D (<https://ui.adsabs.harvard.edu/abs/2017JSP...168..288D>) . doi:10.1007/s10955-017-1806-y (<https://doi.org/10.1007/s10955-017-1806-y>) . S2CID 119317128 (<https://api.semanticscholar.org/CorpusID:119317128>) .
25. Ramsauer, Hubert; et al. (2021). "Hopfield Networks is All You Need". *International Conference on Learning Representations*. arXiv:2008.02217 (<https://arxiv.org/abs/2008.02217>) .
26. Krotov, Dmitry; Hopfield, John (2021). "Large associative memory problem in neurobiology and machine learning". *International Conference on Learning Representations*. arXiv:2008.06996 (<https://arxiv.org/abs/2008.06996>) .
27. Hopfield, J. J. (1982). "Neural networks and physical systems with emergent collective computational abilities" (<https://www.ncbi.nlm.nih.gov/pmc/articles/PMC346238>) . *Proceedings of the National Academy of Sciences*. **79** (8): 2554–2558. Bibcode:1982PNAS...79.2554H (<https://ui.adsabs.harvard.edu/abs/1982PNAS...79.2554H>) . doi:10.1073/pnas.79.8.2554 (<https://doi.org/10.1073/pnas.79.8.2554>) . PMC 346238 (<https://www.ncbi.nlm.nih.gov/pmc/articles/PMC346238>) . PMID 6953413 (<https://pubmed.ncbi.nlm.nih.gov/6953413>) .
28. MacKay, David J. C. (2003). "42. Hopfield Networks". *Information Theory, Inference and Learning Algorithms* (https://archive.org/details/informationtheor00mack_607) . Cambridge University Press. p. 508 (https://archive.org/details/informationtheor00mack_607/page/n519) . ISBN 978-0521642989. "This convergence proof depends crucially on the fact that the Hopfield network's connections are *symmetric*. It also depends on the updates being made asynchronously."
29. Bruck, J. (October 1990). "On the convergence properties of the Hopfield model" (<https://resolver.caltech.edu/CaltechAUTHORS:20120426-132042598>) . *Proc. IEEE*. **78** (10): 1579–85. Bibcode:1990IEEEP..78.1579B (<https://ui.adsabs.harvard.edu/abs/1990IEEEP..78.1579B>) . doi:10.1109/5.58341 (<https://doi.org/10.1109/5.58341>) .
30. Uykan, Z. (September 2020). "On the Working Principle of the Hopfield Neural Networks and its Equivalence to the GADIA in Optimization". *IEEE Transactions on Neural Networks and Learning Systems*. **31** (9): 3294–3304. Bibcode:2020ITNNL..31.3294U (<https://ui.adsabs.harvard.edu/abs/2020ITNNL..31.3294U>) . doi:10.1109/TNNLS.2019.2940920 (<https://doi.org/10.1109/TNNLS.2019.2940920>) . PMID 31603804 (<https://pubmed.ncbi.nlm.nih.gov/31603804>) . S2CID 204331533 (<https://api.semanticscholar.org/CorpusID:204331533>) .

31. Uykan, Z. (March 2021). "Shadow-Cuts Minimization/Maximization and Complex Hopfield Neural Networks" (<https://doi.org/10.1109%2FTNNLS.2020.2980237>) . *IEEE Transactions on Neural Networks and Learning Systems*. **32** (3): 1096–1109.
Bibcode:2021ITNNL..32.1096U (<https://ui.adsabs.harvard.edu/abs/2021ITNNL..32.1096U>) . doi:10.1109/TNNLS.2020.2980237 (<https://doi.org/10.1109%2FTNNLS.2020.2980237>) . PMID 32310787 (<https://pubmed.ncbi.nlm.nih.gov/32310787>) . S2CID 216047831 (<https://api.semanticscholar.org/CorpusID:216047831>) .
32. Hopfield, J.J.; Tank, D.W. (1985). "Neural computation of decisions in optimization problems". *Biological Cybernetics*. **52** (3): 141–6. doi:10.1007/BF00339943 (<https://doi.org/10.1007%2BF00339943>) . PMID 4027280 (<https://pubmed.ncbi.nlm.nih.gov/4027280>) . S2CID 36483354 (<https://api.semanticscholar.org/CorpusID:36483354>) .
33. Bruck, Jehoshua; Goodman, Joseph W (1990-06-01). "On the power of neural networks for solving hard problems" (<https://linkinghub.elsevier.com/retrieve/pii/0885064X9090001T>) . *Journal of Complexity*. **6** (2): 129–135. doi:10.1016/0885-064X(90)90001-T (<https://doi.org/10.1016%2F0885-064X%2890%2990001-T>) . ISSN 0885-064X (<https://search.worldcat.org/issn/0885-064X>) .
34. Storkey, A.J.; Valabregue, R. (1999). "The basins of attraction of a new Hopfield learning rule". *Neural Networks*. **12** (6): 869–876. CiteSeerX 10.1.1.19.4681 (<https://citeseerx.ist.psu.edu/viewdoc/summary?doi=10.1.1.19.4681>) . doi:10.1016/S0893-6080(99)00038-6 (<https://doi.org/10.1016%2FS0893-6080%2899%2900038-6>) . PMID 12662662 (<https://pubmed.ncbi.nlm.nih.gov/12662662>) .
35. Hebb 1949
36. Storkey, Amos (1997). "Increasing the capacity of a Hopfield network without sacrificing functionality". *Artificial Neural Networks – ICANN'97*. Lecture Notes in Computer Science. Vol. 1327. Springer. pp. 451–6. CiteSeerX 10.1.1.33.103 (<https://citeseerx.ist.psu.edu/viewdoc/summary?doi=10.1.1.33.103>) . doi:10.1007/BFb0020196 (<https://doi.org/10.1007%2BFb0020196>) . ISBN 978-3-540-69620-9.
37. Hertz 1991
38. Bruck, J.; Roychowdhury, V.P. (1990). "On the number of spurious memories in the Hopfield model (neural network)" (<https://resolver.caltech.edu/CaltechAUTHORS:BRUieeetit90a>) . *IEEE Transactions on Information Theory*. **36** (2): 393–397. Bibcode:1990ITIT...36..393B (<https://ui.adsabs.harvard.edu/abs/1990ITIT...36..393B>) . doi:10.1109/18.52486 (<https://doi.org/10.1109%2F18.52486>) .

39. Liou, C.-Y.; Lin, S.-L. (2006). "Finite memory loading in hairy neurons" (<http://ntur.lib.ntu.edu.tw/bitstream/246246/155192/1/19.pdf>) (PDF). *Natural Computing*. **5** (1): 15–42. doi:10.1007/s11047-004-5490-x (<https://doi.org/10.1007%2Fs11047-004-5490-x>) . S2CID 35025761 (<https://api.semanticscholar.org/CorpusID:35025761>) .
40. Liou, C.-Y.; Yuan, S.-K. (1999). "Error Tolerant Associative Memory". *Biological Cybernetics*. **81** (4): 331–342. doi:10.1007/s004220050566 (<https://doi.org/10.1007%2Fs004220050566>) . PMID 10541936 (<https://pubmed.ncbi.nlm.nih.gov/10541936>) . S2CID 6168346 (<https://api.semanticscholar.org/CorpusID:6168346>) .
41. Yuan, S.-K. (June 1997). *Expanding basins of attraction of the associative memory* (https://ntu.primo.exlibrisgroup.com/discovery/fulldisplay?vid=886NTU_INST:886NTU_INST&search_scope=MyInstitution&tab=LibraryCatalog&docid=alma991010725609704786&lang=en&context=L&adaptor=Local%20Search%20Engine&query=any,contains,%E5%8A%89%E9%95%B7%E9%81%A0&facet=rtype,include,manuscripts&facet=searchcreationdate,include,1977%7C,%7C2019&facet=searchcreationdate,include,1992%7C,%7C2010&offset=0) (Master thesis). National Taiwan University. 991010725609704786.
42. ABOUDIB, Ala; GRIPON, Vincent; JIANG, Xiaoran (2014). "A study of retrieval algorithms of sparse messages in networks of neural cliques" (<https://hal.archives-ouvertes.fr/hal-01058303/>) . *COGNITIVE 2014 : The 6th International Conference on Advanced Cognitive Technologies and Applications*. pp. 140–6. arXiv:1308.4506 (<https://arxiv.org/abs/1308.4506>) . Bibcode:2013arXiv1308.4506A (<https://ui.adsabs.harvard.edu/abs/2013arXiv1308.4506A>) .
43. Amit, D.J. (1992). *Modeling Brain Function: The World of Attractor Neural Networks* (<https://books.google.com/books?id=fvLYch1yQncC>) . Cambridge University Press. ISBN 978-0-521-42124-9.
44. Rolls, Edmund T. (2016). *Cerebral Cortex: Principles of Operation* (https://books.google.com/books?id=on_ADAAAQBAJ) . Oxford University Press. ISBN 978-0-19-878485-2.
45. Horn, D; Usher, M (1988). "Capacities of multiconnected memory models" (<https://doi.org/10.1051/jphys:01988004903038900>) . *Journal de Physique*. **49** (3): 389–395. doi:10.1051/jphys:01988004903038900 (<https://doi.org/10.1051%2Fjphys%3A01988004903038900>) .
46. Burns, Thomas; Fukai, Tomoki (2023). "Simplicial Hopfield networks" (https://openreview.net/forum?id=_QLsH8gatwx) . *International Conference on Learning Representations*. **11**. arXiv:2305.05179 (<https://arxiv.org/abs/2305.05179>) .
47. Krotov, Dmitry (2021). "Hierarchical Associative Memory". arXiv:2107.06446 (<https://arxiv.org/abs/2107.06446>) [cs.NE (<https://arxiv.org/archive/cs/NE>)] .

- Hebb, D.O. (2005) [1949]. *The Organization of Behavior: A Neuropsychological Theory* (<https://books.google.com/books?id=ddB4AgAAQBAJ>) . Psychology Press. ISBN 978-1-135-63190-1.
- Hertz, John A. (2018) [1991]. *Introduction To The Theory Of Neural Computation* (<https://books.google.com/books?id=aEIPEAAAQBAJ&pg=PP5>) . CRC Press. ISBN 978-0-429-96821-1.
- McCulloch, W.S.; Pitts, W.H. (1943). "A logical calculus of the ideas immanent in nervous activity". *Bulletin of Mathematical Biophysics*. **5** (4): 115–133. Bibcode:1943BMaB....5..115M (<https://ui.adsabs.harvard.edu/abs/1943BMaB....5..115M>) . doi:10.1007/BF02478259 (<https://doi.org/10.1007%2FBF02478259>) .
- Polyn, S.M.; Kahana, M.J. (2008). "Memory search and the neural representation of context" (<https://www.ncbi.nlm.nih.gov/pmc/articles/PMC2839453>) . *Trends in Cognitive Sciences*. **12** (1): 24–30. doi:10.1016/j.tics.2007.10.010 (<https://doi.org/10.1016%2Fj.tics.2007.10.010>) . PMC 2839453 (<https://www.ncbi.nlm.nih.gov/pmc/articles/PMC2839453>) . PMID 18069046 (<https://pubmed.ncbi.nlm.nih.gov/18069046>) .
- Rizzuto, D.S.; Kahana, M.J. (2001). "An autoassociative neural network model of paired-associate learning". *Neural Computation*. **13** (9): 2075–2092. CiteSeerX 10.1.1.45.7929 (<http://citeseerx.ist.psu.edu/viewdoc/summary?doi=10.1.1.45.7929>) . doi:10.1162/089976601750399317 (<https://doi.org/10.1162%2F089976601750399317>) . PMID 11516358 (<https://pubmed.ncbi.nlm.nih.gov/11516358>) . S2CID 7675117 (<https://api.semanticscholar.org/CorpusID:7675117>) .
- Kruse, Rudolf; Borgelt, Christian; Klawonn, Frank; Moewes, Christian; Steinbrecher, Matthias; Held, Pascal (2013). *Computational Intelligence: A Methodological Introduction* (<https://books.google.com/books?id=yQVGAAAAQBAJ>) . Springer. ISBN 978-1-4471-5013-8.

ВНЕШНИЕ ССЫЛКИ

- Рохас, Рауль (12 июля 1996 г.). "13. Модель Хопфилда" (<http://page.mi.fu-berlin.de/rojas/neural/chapter/K13.pdf>) (PDF). «Нейронные сети — систематическое введение» (<http://page.mi.fu-berlin.de/rojas/neural/index.html.html>) . Springer. ISBN 978-3-540-60505-8.
- Сеть Хопфилда на Javascript (<http://www.heatonresearch.com/aifh/vol3/hopfield.html>)
- Архивировано (<http://to-campos.planetaclix.pt/neural/hope.html>) Задача коммивояжёра (<https://web.archive.org/web/20150530022419/http://to-campos.planetaclix.pt/neural/hope.html>) 30 мая 2015 года в Wayback Machine — апплет с нейронной сетью Хопфилда на JAVA
- Хопфилд, Джон (2007). "Сеть Хопфилда" (<https://doi.org/10.4249%2Fscholarpedia.1977>) . *Scholarpedia*. **2** (5): 1977. Bibcode:2007SchpJ...2.1977H (<https://ui.adsabs.harvard.edu/abs/2007SchpJ...2.1977H>) . doi:10.4249/scholarpedia.1977 (<https://doi.org/10.4249%2Fscholarpedia.1977>) .

- «Не забывайте об ассоциативных воспоминаниях» (<https://thegradient.pub/dont-forget-about-associative-memories/>) . *The Gradient*. 7 ноября 2020. Получено 27 сентября 2024.