

Критические уязвимости в системах голосового искусственного интеллекта, выявленные с помощью AudioHijack

Неизвестный источник • 17 мая 2026 года

Ключевые моменты

- AudioHijack успешно применяется в 79–96 % случаев, выявляя критические уязвимости в системах защиты голосового искусственного интеллекта.
- Атаки на открытые модели распространяются на коммерческие системы, что указывает на общие архитектурные недостатки.
- Ограниченные средства защиты снижают вероятность успеха атаки всего на 7 %, что подчеркивает необходимость надежных мер безопасности.

Краткие сведения

Недавнее исследование выявило серьезную уязвимость голосовых систем на базе искусственного интеллекта: незаметные аудиосигналы могут перехватывать управление этими технологиями, что приводит к несанкционированному выполнению команд с высокой вероятностью успеха. Это исследование, представленное на симпозиуме IEEE по безопасности и конфиденциальности, демонстрирует риски, с которыми сталкиваются компании, использующие голосовой искусственный интеллект, а также потенциальные угрозы безопасности данных и проблемы с операционной надежностью. По мере того как компании все активнее внедряют эти системы, понимание и устранение этих уязвимостей становится критически важным для защиты конфиденциальных операций.

Упомянутые Субъекты

Компании

- Майкрософт
- Мистраль
- Открытый доступ
- Антропный

Технологии

- Большие аудиолингвистические модели (Large Audio–Language Models, LALMs)
- Аудиомагнитофон
- примеры состязательных аудиозаписей

Люди

- Мэн Чен
- Евгений Багдасарян
- Эдд Гент

Организации

- IEEE

Ключевые понятия

- голосовые системы искусственного интеллекта
- скрытые звуковые атаки
- состязательный звук
- порождающие модели
- устойчивость модели
- вредоносные инструкции
- алгоритм оптимизации
- механизмы внимания

Определения

- Большие аудиолингвистические модели (Large Audio–Language Models, LALMs)**
Модели, способные анализировать и генерировать аудио, позволяют управлять устройствами с помощью голосовых команд и автоматически расшифровывать их.
- Аудиомагнитофон**
Метод, который использует недостатки безопасности в LALMs путем встраивания вредоносных инструкций в аудиоклипы.
- примеры состязательных аудиозаписей**
Аудиофайлы, обработанные таким образом, чтобы обмануть модели машинного обучения и заставить их выдавать неверные результаты.
- токены**
Числовые значения, присваиваемые фрагментам аудио в генеративных моделях.
- механизмы внимания**

Компоненты моделей, которые помогают выделить важные фрагменты аудио для выполнения задачи.

Варианты использования

- управление устройствами с помощью голосовых команд
- автоматическая расшифровка совещаний
- поиск конфиденциальной информации в интернете
- скачивание файлов из источников, контролируемых злоумышленниками
- отправка электронных писем с пользовательскими данными
- внедрение вредоносного аудио в голосовые чаты в реальном времени

Frequently Asked Questions

What are hidden audio attacks?

Hidden audio attacks involve embedding imperceptible sounds in audio that can manipulate AI voice systems to execute unauthorized commands. These attacks can be executed without the user's knowledge.

How does AudioHijack work?

AudioHijack exploits vulnerabilities in generative AI models by embedding malicious instructions in audio clips. It allows attackers to manipulate the model's behavior without needing control over the user's input.

What challenges do audio attacks face in real-world applications?

Real-world audio attacks may encounter challenges such as audio compression and post-processing, which can degrade the effectiveness of the malicious signals. Additionally, the complexity of audio data makes detection difficult.

What is the significance of the research presented at the IEEE Symposium?

The research highlights vulnerabilities in AI voice systems and emphasizes the need for improved model resilience against adversarial audio attacks. It aims to inform developers about potential security flaws in their applications.

How can companies protect their AI models from such attacks?

Companies can enhance the resilience of their AI models by implementing additional layers of protection, monitoring internal attention mechanisms, and providing developers with tools and guidance to safeguard against adversarial inputs.

Source

Critical Vulnerabilities in Voice AI Systems Exposed by AudioHijack

<https://spectrum.ieee.org/voice-ai-audio-attacks>

Related Stories IT

AI Task Surge Demands New Leadership Strategies for Managers

The integration of artificial intelligence into workplace operations is dramatically altering productivity landscapes, posing significant challenges for managers. As AI tools accelerate output, managers struggle to keep pace with increased work volume while simultaneously ensuring team...

 May 25, 2026

AI's Impact on Bug Bounty Programs and Cybersecurity Strategies

The rise of advanced AI is dramatically altering the cybersecurity landscape, particularly in software vulnerability detection and bug bounty programs. Companies now face a surge in reported vulnerabilities due to autonomous AI tools, prompting a reassessment of security...

 May 25, 2026

AI-Driven Virtual Sensors Enhance Battery Management System Efficiency

The webinar 'AI with Model-Based Design: Virtual Sensor Modeling' highlights the transformative role of AI-driven virtual sensors in Battery Management Systems, focusing on their ability to estimate critical signals like the state of charge (SOC). This integration not only enhances...

 May 25, 2026

Related Case Studies

Commerzbank Cuts Advisory Call Documentation

Time by Two-Thirds with Google Cloud AI

Commerzbank deployed Google Cloud AI to automate advisory call documentation, cutting the process from over 60 minutes to just minutes. The solution uses speech-to-text and generative AI to produce structured summaries, improving compliance and freeing advisors to focus on client...

 Invalid Date

PepsiCo Achieves 20% Manufacturing Throughput Increase with AI Digital Twins

PepsiCo deployed AI-powered digital twins built on NVIDIA Omniverse to virtually simulate and optimize manufacturing and distribution facilities. The technology identified 90% of potential issues before implementation, compressed facility design cycles from months to days, and...

 Invalid Date

Siemens Energy Cuts Proposal Time 90% with Amazon Bedrock AI

Siemens Energy reduced proposal generation time by 90% using Amazon Bedrock.

 Invalid Date

Related Research

Millimeter-Wave Radar Enhances Pollinator Monitoring with High Accuracy

A novel radar system is changing the game for pollinator monitoring by accurately identifying different insect species without harm. This innovation promises to enhance agricultural practices and ecological studies, paving the way for more sustainable approaches.

 May 23, 2026

DCI's Direct Corpus Interaction Enhances AI Agent Precision and Cost Efficiency

Direct Corpus Interaction empowers AI agents to bypass traditional retrieval limitations, unlocking real-time access to raw data. This innovative approach enables more dynamic and accurate information retrieval, essential for fast-paced business environments.

📅 May 23, 2026

Manufacturers Face Workforce Skepticism Amid AI Integration Challenges

A recent study highlights a critical gap between executive optimism and worker skepticism regarding AI in manufacturing, with over 75% of frontline workers feeling inadequately trained and uncertain about their future roles.

📅 May 22, 2026

Interesting Companies

Podium

AI-powered lead generation and management platform that helps you convert more leads and make more money.

Bubble Lab

Open-source, Typescript-native agentic workflow builder

Reka

Invention. Intelligence. Impact. At Reka, we make the complex simple. Our multimodal, modular intelligence disassembles, understands, and delivers complete solutions in new configurations.

Vapi

Build Advanced Voice AI Agents

Theta Software

Specialized AI for Every Job

Ai2

Transform your business with powerful Ai2 Applications for seamless Sales Order Management. Automate B2B Sales Process. Boost efficiency and sales today!

Button

MarkUpgrade: We help visionary entrepreneurs secure extraordinary domain names to power their brands to success.

Promptless

Promptless keeps your technical docs up to date by automatically drafting docs updates from Github PRs, improving customer satisfaction and free user conversions while reducing implementation time ...

Eloquent AI

The Mission Control Engine For Reliable AI Agents

Welcome.AI

The definitive source for AI intelligence, research, and solutions.

CONTENT

[Latest News](#)

[Research](#)

[Case Studies](#)

[Use Cases](#)

[SEO to GEO](#)

[llms.txt](#)

[SOLUTIONS](#)

[For Companies](#)

[Search](#)

[Companies](#)

[Solutions](#)

[Categories](#)

[Newsletter](#)

[NETWORK](#)

[GStars.dev](#)

[Whoo.is](#)

[BookAuthor.AI](#)

[Word.Chat](#)

[Aice.AI](#)

[COMPANY](#)

[About](#)

[Advertise](#)

[Partners](#)

[Contact](#)

[Privacy](#)

[Terms](#)