

ТИХОЕ МЕСТО

Хакеры обнаружили, что неслышные звуки, спрятанные в подкастах или случайных видео, могут взломать ваш голосовой чат- бот с искусственным интеллектом

Будь осторожен.



Автор Джон Кристиан

Опубликовано 24 мая 2026 года в 7:30 по восточному поясному времени

 Добавьте Futurism 



Гетти / Футуризм

Зарегистрируйтесь, чтобы
увидеть будущее уже сегодня

Введите свой адрес электронной почты

ЗАРЕГИСТРИРОВАТЬСЯ

Представьте себе такую ситуацию: ваш алгоритм подбирает фоновое видео на YouTube или, может быть, подкаст. Вы не подозреваете, что хакеры встроили в него неслышимые звуки, предназначенные для взлома вашего голосового помощника на умном устройстве или в телефоне. Таким образом, киберпреступники получают доступ к вашим личным фотографиям, банковским счетам и любой другой личной информации, которую вы подключили к системе искусственного интеллекта.

Звучит как неудачный эпизод из «Чёрного зеркала», но именно это, как показали исследователи, возможно в рамках нового исследования, представленного на этой неделе на Симпозиуме IEEE по безопасности и конфиденциальности.

По сути, группа исследователей из Китая и Сингапура обнаружила, что можно создавать «конфронтационные аудиозаписи», совершенно незаметные для человеческого уха, которые заставляют голосовые ИИ-модели делать то, чего они делать не должны. Затем их можно легко замаскировать под безобидные аудиозаписи — песни, фильмы или что-то еще, что ничего не подозревающие пользователи могут слушать в фоновом режиме, — и поджидать, пока пользователи случайно поставят под угрозу свою цифровую безопасность.

«Обучение этого сигнала занимает всего полчаса, а затем, поскольку этот сигнал не зависит от контекста, его можно использовать для атаки на целевую модель в любой момент, независимо от того, что говорит пользователь, — рассказал в интервью *IEEE Spectrum* о своей работе ведущий автор исследования Мэн Чен, аспирант Чжэцзянского университета в Китае. — Эти точечные средства защиты не справляются с нашей атакой, потому что, как мы выяснили, этим моделям очень сложно отличить обычные намерения пользователя от атаки злоумышленника».

Одна загвоздка, по крайней мере на данный момент: для применения этого метода хакерам требовался доступ ко всем весовым коэффициентам модели ИИ, на которую они нацелились, то есть они могли атаковать только модели с открытым исходным кодом. Но поскольку многие коммерческие системы искусственного интеллекта основаны на моделях с открытым исходным кодом, их метод сработал против основных продуктов Microsoft и Mistral.

Компания Mistral не ответила на запрос *IEEE* о комментарии, но Microsoft выступила с заявлением, которое, вероятно, заставит задуматься любого, прежде чем передавать какую-либо важную информацию одной из голосовых моделей искусственного интеллекта компании.

«Мы высоко ценим работу исследователей, направленную на углубление понимания этого метода, — говорилось в письме. — В этом исследовании устойчивость модели оценивается с помощью контролируемого прямого взаимодействия с самой моделью, что помогает нам в разработке подходов к повышению устойчивости моделей. На практике модели ИИ часто интегрируются в пользовательские приложения, и мы предлагаем разработчикам инструменты и рекомендации, которые помогут им внедрить дополнительные уровни защиты для обеспечения безопасности пользователей».

More on AI: *Researchers Alarmed by AI That Can Self-Replicate Into Another Machine*



Jon Christian
Executive Editor

I'm the executive editor at Futurism, assigning, editing, and reporting on everything from artificial intelligence and space exploration to the personalities shaping the tech sector.

TAGS IN THIS STORY

COMPUTING

DEVICES

FINANCE

FUTURE SOCIETY

INTERNET OF THINGS

PRIVACY

ROBOTS AND MACHINES

MOST POPULAR

ANTHROPIC

Top AI Models Showing Disturbing Behavior as They Become More Advanced

By **Krystle Vermes**

FUTURE SOCIETY

Chaos Reigns as Fox News Guest Appears to Be Wearing Human-Like Mask

By **Joe Wilkins**

MARS

SpaceX Announces Plans to Put Billionaire on First Rocket to Mars

By **Joe Wilkins**

ARTIFICIAL INTELLIGENCE

Fury Explodes at Short Films Using AI to Make Erotica of Women From the 1970s

By **Frank Landymore**

CLIMATE CHANGE

Research Paper Warns That There's a Massive Experiment at Work to Geoengineer the Earth's Climate

By **Frank Landymore**

[READ MORE](#)

More in Machine Learning



MACHINE LEARNING

Democrats' 2024 Election Autopsy Shows Signs of Sloppy AI Generation

By **Joe Wilkins**



ETHICS

Being a Crappy Boss to AI Chatbots Pushes Them Toward Spouting Marxist Rhetoric and Organizing With Their Compatriots, Researchers Find

By **Joe Wilkins**



BRAIN

These Smart Glasses That Show Captions of What Everyone's Saying Without a Creepy Spy Camera Actually Seem Pretty Awesome


By **Jon Christian**



MACHINE LEARNING

Amazon Employees Forced to Hit Quotas on AI Use, Immediately Start Using it for Everything Except Work


By **Joe Wilkins**



ETHICS

The AI Industry Is Secretly Powered by Homeless People

By **Krystle Vermes**



ETHICS

AI Appears to Be Trapping Certain Job Applicants in a Limbo Where They Never Get an Interview for “Reasons” That Are Completely Unfair

By **Joe Wilkins**



MACHINE LEARNING

ChatGPT Is Saying Weird Things in Chinese

By Joe Wilkins



MACHINE LEARNING

America Trembles as Transportation Secretary Announces Plans for Air Traffic Controllers to Lean on AI Tools

By Joe Wilkins

SEE MORE

More in Artificial Intelligence



ETHICS

Paper Finds That Leading AI Chatbots Like ChatGPT and Claude Remain Incredibly Sycophantic, Resulting in Twisted Effects on Users

By **Maggie Harrison Dupré**



ANTHROPIC

Researchers Find It's Shockingly Easy to Cause AI to Lose Its Mind by Posting Poisoned Documents Online

By **Victor Tangermann**



FUTURE SOCIETY

Google Adds Button to Generate Error-Laden AI Podcast About Your Search Results Instead of Just Reading Them Like a Functioning Member of Society

By **Victor Tangermann**



ARTIFICIAL INTELLIGENCE

Using an AI Browser Lets Hackers Drain Your Bank Account Just by Showing You a Public Reddit Post

By **Victor Tangermann**



OPENAI

People Are Making Sora 2 Videos of Stephen Hawking Being Horribly Brutalized


By **Jon Christian, Victor Tangermann**



FUTURE SOCIETY

OpenAI's Sora 2 Generates Realistic Videos of People Shoplifting

By **Victor Tangermann**



ARTIFICIAL INTELLIGENCE

Mega-Hyped Chinese AI App DeepSeek Says It's Been Hit by "Large-Scale Malicious Attacks"

By **Victor Tangermann**



OPENAI

ChatGPT Went Rogue, Spoke In People's Voices Without Their Permission

By **Victor Tangermann**

SEE MORE

Futurism

Sign up to see the future, today

Can't-miss innovations from the bleeding edge of science and tech

SIGN UP

ADVANCED TRANSPORT

ARTIFICIAL INTELLIGENCE

FUTURE SOCIETY

HEALTH & MEDICINE

ROBOTS AND MACHINES

SCIENCE & ENERGY

SPACE

NEWSLETTER

ABOUT US

EDITORIAL STANDARDS

CONTACTS

PRIVACY POLICY

TERMS & CONDITIONS

DMCA POLICY

SITEMAP

FOLLOW US

IG

BS

FB

DISCLAIMER(S)

ARTICLES MAY CONTAIN AFFILIATE LINKS WHICH ENABLE US TO SHARE IN THE REVENUE OF ANY PURCHASES MADE. REGISTRATION ON OR USE OF THIS SITE CONSTITUTES ACCEPTANCE OF OUR TERMS OF SERVICE.

© 2026 RECURRENT. ALL RIGHTS RESERVED.