



Влияние пространственных корреляций на нейронную сеть Хопфилда и плотные ассоциативные воспоминания

d c b a Де Марцо Джордано Ссылки на авторов открывают панель с оверлеем  ,
Джулио Яннелли ^{a e 1} 

[Показать больше](#) 

 Поделиться  процитировать

<https://doi.org/10.1016/j.physa.2023.128487> 

[Получить права и контент](#) 

Абстрактный

Модель Хопфилда — одна из немногих нейронных сетей, для которых можно получить аналитические результаты. Однако большинство из них получены в предположении о наличии случайных некоррелированных паттернов, в то время как в реальных приложениях данные, которые нужно хранить, демонстрируют нетривиальные корреляции. В этой статье мы изучаем, как пространственные корреляции в подаваемых данных влияют на способность сети Хопфилда к извлечению информации при нулевой температуре. В частности, в качестве шаблонов для хранения мы используем конфигурации линейной модели Изинга при обратной температуре β Ассоциативная память, тем самым ограничивая наш анализ экспоненциально затухающими пространственными корреляциями. Используя метод соотношения сигнал/шум, мы получаем фазовую диаграмму в зависимости от нагрузки сети Хопфилда и температуры Изинга, на которой можно выделить нечеткую фазу и область извлечения данных. Примечательно, что с увеличением

пространственной корреляции внутри шаблонов критическая нагрузка сети Хопфилда снижается, что также подтверждается результатами численного моделирования. Затем анализ был распространен на Dense с произвольными взаимодействиями между нечетными телами, для которых мы получили аналогичные результаты.

Введение

Нейронная сеть Хопфилда (НСХ) [1] стала краеугольным камнем в истории искусственных нейронных сетей (ИНС) и научных попыток смоделировать функции мозга [2], [3]. В частности, НСХ представляет собой рекуррентную нейронную сеть (РНС), состоящую из N нейронов или спинов, которые взаимодействуют попарно и работают как ассоциативная память (АП), то есть могут *хранить* и *воспроизводить* информацию.

Важнейшим аспектом HNN является понимание максимального объема данных, которые эта система может успешно запомнить [4]. Было показано, что HNN с N нейронами может хранить $K = \mathcal{O}(N)$ независимых и одинаково распределенных случайных паттернов, каждый из которых состоит из N независимых и одинаково распределенных переменных Радемахера, при условии, что допускаются некоторые ошибки [5]. Таким образом, емкость памяти $\alpha = K/N$ HNN может быть порядка единицы, и при этом нейронная сеть продолжает работать. Эвристически это можно объяснить тем, что матрица взаимодействия состоит из $\mathcal{O}(N^2)$ независимых компонентов, поэтому максимальное количество битов, которое может быть сохранено, должно быть того же порядка. Точнее, было показано [5], что осмысленный поиск возможен при использовании до $\alpha \leq \alpha_c$ с $\alpha_c \approx 0.14$.

Для увеличения объема памяти такой системы были предложены различные модификации HNN (например, [6], [7], [8], [9]). В последние годы [10], [11] большое внимание уделялось обобщенным HNN с p -корпускулярными взаимодействиями. Такие нейронные сети называются плотными ассоциативными памятью (Dense Associative Memory, DAM). Матрица взаимодействия DAM с p -частичными взаимодействиями содержит $\mathcal{O}(N^p)$ компонентов, так что в принципе такая сеть может хранить до N^{p-1} независимых и одинаково распределённых паттернов Радемахера (длиной N) [12], [13]. Доказано, что такие архитектуры не только обладают большей ёмкостью, но и очень устойчивы к шумам, сбоям и вредоносным примерам [14], [15], [16].

Однако паттерны со случайными некоррелированными компонентами, несмотря на то, что они являются привлекательным стандартом для аналитических исследований, не отражают должным образом *реалистичные* воспоминания. Этот момент очень важен, поскольку, как было показано [17], [18], [19], [20], [21], HNN и DAM формально эквивалентны машине Больцмана (Boltzmann Machine, BM) [22], [23], которая используется в ряде приложений машинного обучения, где данные определенно не являются независимыми и одинаково распределенными. Действительно, в большинстве ситуаций из реальной жизни паттерны могут быть взаимосвязаны или структурированы, например, если они демонстрируют нетривиальные пространственные корреляции [24], [25], [26]. Такая ситуация возникает, например, когда паттерны, которые нужно сохранить, представляют собой тексты, которые можно представить в виде одномерных двоичных последовательностей, элементы которых коррелируют друг с другом в соответствии с грамматическими и семантическими правилами. Аналогичным образом черно-белые изображения представляют собой двоичные матрицы с пространственными корреляциями, поскольку черный (или белый) пиксель с большей вероятностью будет окружен пикселями того же цвета. Однако, несмотря на важность закономерностей с такого рода пространственными корреляциями, лишь в немногих исследованиях рассматривалось поведение нейронной сети с горками в такой ситуации. В работе [24] было показано, что если пространственные корреляции возникают из-за простой цепи Маркова с двумя состояниями, то нейронная сеть с горками все равно демонстрирует критическую пропускную способность порядка единицы. Также были изучены эффекты корреляции между пикселями, которые одинаковы для всех пар пикселей и равны λ/N [27]. Выяснилось, что извлечение возможно даже при $\alpha \approx \alpha_c$ и $\lambda > 0$, но при этом происходит новый ферромагнитный переход. Более реалистичные корреляции, возникающие в двумерной модели Изинга, были изучены в работе [28], но только в случае точного воспроизведения узоров, что дает лишь нижнюю границу реальной емкости памяти. Влияние корреляций на динамические ассоциативные воспоминания недавно рассматривалось [29] на примере паттернов, сгенерированных моделью Кюри — Вейса, но опять же только при условии идеального распознавания паттернов.

In the present work we considered how the HNN behaves in presence of patterns generated by a one dimensional Ising model (or *Ising linear chain*) at inverse temperature β . The spin configurations of this model can be regarded as prototypes of textual data. Note that by varying the temperature of the Ising model we can control the level of internal correlation of the patterns, while we set the temperature of the Hopfield model

to zero, thus neglecting the effects of fast noise. In the rest of the work we refer to β as the temperature parameter relative to the Ising model.

By using a Signal-to-Noise Analysis (SNA)[2] we assess the maximal storage capacity of the HNN as function of β , finding that for $\beta > 0$ the neural network can still store a number of patterns which grows linearly with the number of neurons N , even though the storage capacity is lower than in the case of i.i.d. Rademacher patterns. This result is non trivial since naively one would expect the storage capacity to increase due to the fact that internal correlations diminish the amount of information to be stored. Moreover, differently from previous studies, we obtain the true maximal storage capacity and not a lower bound. This allows to draw a phase diagrams in the space defined by the parameters (α, β) , where a retrieval region and a fuzzy phase can be identified. The analysis is then generalized to the DAM version of the HNN with odd p -bodies interaction. We show that the maximal storage capacity decreases as β increases, but again the network can memorize $O(N^{p-1})$ patterns as in the uncorrelated case, provided that $\beta > 0$.

The paper is structured as follows:

- In Section2 we introduce the signal to noise technique and we apply it to the HNN and to the DAM with i.i.d. Rademacher patterns.
- In Section3 we apply the SNA to the HNN feed with patterns generated by a one dimensional Ising model and we compare the analytical results with numerical simulations.
- In Section4 we generalize the results of the previous section to the case of a DAM with p -bodies interaction.
- Finally Section5 is devoted to our conclusions and remarks.

Access through your organization

Check access to the full text by signing in through your organization.

Access through your organization

Section snippets

Signal to noise technique for uncorrelated patterns

The Hopfield Neural Network is made of N neurons associated with binary state variables, i.e. $\sigma_i = \pm 1$ for $i = 1 \dots N$, and interacting pairwise on a complete graph with coupling matrix J_{ij} . Denoting by ξ^μ with $\xi_i^\mu = \pm 1$ the K binary patterns we want to store in the neural network, the coupling matrix is defined by the so called Hebbian rule, which reads $\forall i \neq j \quad J_{ij} = \frac{1}{N} \sum_{\mu=1}^K \xi_i^\mu \xi_j^\mu$ and $J_{ii} = 0$ for all the diagonal elements, avoiding self interactions. The Hamiltonian of the system thus satisfies

$$H[\sigma] = - \sum_{ij}^N J_{ij} \sigma_i \sigma_j = -\frac{1}{2} \dots$$

Hopfield neural network with correlated patterns

In the previous section we shown how HNN behaves when fed with uncorrelated Rademacher patterns, but as aforementioned real data are structured and characterized by non trivial spatial correlations. Examples are text and images, both playing a central role in a huge number of machine learning applications.

It is then very natural to assess what happens to the HNN, and so also to the formally equivalent Boltzmann machine, when the patterns have internal correlations (but different patterns are ...

Dense associative memories with correlated patterns

We now move to the case of Dense Associative Memories storing correlated patterns generated by the 1D Ising model at temperature β . The procedure is analogous to that followed in Section2, but as done in Section3 we now have to consider correlations among the different components of the patterns. We only consider an Hamiltonian with interactions involving an odd number of neurons since in this way both computations and numerical simulations are easier to perform. As shown inAppendixB in the ...

Conclusions

ANN are nowadays used in uncountable applications, but despite the great interest they gathered we are still lacking a general theory describing how and why they work. Understanding the mechanism behind their ability in handling complex problems is thus a central issue and many scientists are working in this direction. HNN is one of the few examples where analytical results can be obtained and great effort has been devoted to draw phase diagrams for this particular system. Indeed, despite it ...

Declaration of Competing Interest

The authors declare that they have no known competing financial interests or personal relationships that could have appeared to influence the work reported in this paper. ...

Acknowledgments

We are grateful to Elena Agliari, Adriano Barra and Francesco Alemanno for their useful comments and discussion.

We also thank two anonymous referee that provided us several suggestions for improving the paper.

We acknowledge Enrico Fermi Research Center for financial support. ...

[Recommended articles](#)

References (35)

HopfieldJ.J.

Proc. Natl. Acad. Sci. (1982)

AmitD.J. *et al.*

Modeling Brain Function: The World of Attractor Neural Networks
(1992)

CoolenA.C. *et al.*

Theory of Neural Information Processing Systems
(2005)

AmitD.J. *et al.*

Ann. Phys. (1987)

AmitD.J. *et al.*

Phys. Rev. Lett. (1985)

FolliV. *et al.*

Front. Comput. Neurosci. (2017)

StorkeyA.

DotsenkoV. *et al.*

J. Phys. A: Math. Gen. (1991)

FachechiA. *et al.*

Neural Netw. (2019)

Krotov D. *et al.*

Adv. Neural Inf. Process. Syst. (2016)



View more references

Cited by (6)

[Hopfield model with planted patterns: A teacher-student self-supervised learning model](#)

2023, Applied Mathematics and Computation

Citation Excerpt :

...In this work the negative effects of the correlation structure on the system's capacity emerge and different non-Hebb rules are proposed to mitigate it, restoring the possibility of pattern retrieval. Other works on the effect of patterns correlation on the critical capacity are [25–27]. From this perspective it appears as a collective endeavour in favour of an artificial intelligence (AI) that works exclusively by machine memorization, in contrast to modern AI that is being dominated by machine learning....

[Show abstract](#) ✓

[Dense associative memory in a nonlinear-optical Hopfield neural network ↗](#)

2026, Physical Review Applied

[Accuracy and capacity of modern Hopfield networks with synaptic noise ↗](#)

2025, Physical Review E

[Grid-symmetric multi-scroll attractors and its circuit implementation in magnetized Hopfield neural network ↗](#)

2025, Physica Scripta

[Hopf bifurcations in a fractional-order neural network introducing delays into neutral terms ↗](#)

2024, European Physical Journal Plus

[Semantically-correlated memories in a dense associative model ↗](#)

2024, Proceedings of Machine Learning Research

1 Authors equally contributed.

[Просмотреть полный текст](#)

© 2023 Elsevier B.V. All rights reserved.



All content on this site: Copyright © 2026 Elsevier B.V., its licensors, and contributors. All rights are reserved, including those for text and data mining, AI training, and similar technologies. For all open access content, the relevant licensing terms apply.

