


Объявления

Обнаружение и предотвращение атак с использованием дистилляции

23 февраля 2026 г.



Мы выявили кампании промышленного масштаба, организованные тремя лабораториями искусственного интеллекта — DeepSeek, Moonshot и MiniMax, — с целью незаконного использования возможностей Claude для

AI



ограничения доступа.

В этих лабораториях использовался метод под названием «дистилляция», который заключается в обучении менее мощной модели на основе результатов более мощной модели. Дистилляция — широко распространенный и законный метод обучения. Например, передовые лаборатории в области искусственного интеллекта регулярно

«дистиллируют» свои собственные модели, чтобы создавать более компактные и дешевые версии для своих клиентов. Но дистилляция может использоваться и в незаконных целях: с ее помощью конкуренты могут получить доступ к мощным возможностям других лабораторий за гораздо меньшее время и с меньшими затратами, чем потребовалось бы на их самостоятельную разработку.

Эти кампании становятся все более масштабными и изощренными. Времени на принятие мер остается все меньше, а угроза распространяется не только на отдельные компании или регионы. Для ее устранения потребуются быстрые и скоординированные действия со стороны представителей отрасли, политиков и мирового сообщества в области искусственного интеллекта.

Почему дистилляция так важна

Незаконно дистиллированные модели не имеют необходимых защитных механизмов, что создает значительные риски для национальной безопасности. Anthropic и другие американские компании создают системы, которые не позволяют государственным и негосударственным субъектам использовать ИИ, например, для разработки биологического оружия или вредоносных действий в киберпространстве. Модели, созданные в результате незаконной дистилляции, вряд ли будут иметь такие защитные механизмы, а значит, опасные возможности могут распространяться без какой-либо защиты.

Иностранные лаборатории, использующие американские модели, могут внедрять эти незащищенные возможности в военные, разведывательные и наблюдательные системы, что позволит авторитарным правительствам использовать передовой искусственный интеллект для наступательных киберопераций, кампаний по дезинформации и массовой слежки. Если исходные коды моделей открыты, этот риск многократно возрастает, поскольку такие возможности свободно распространяются за пределы контроля какого-либо одного правительства.

Атаки с использованием дистилляции и экспортный контроль

Компания Anthropic последовательно поддерживает экспортный контроль, чтобы сохранить лидерство Америки в области искусственного интеллекта. Атаки с использованием дистилляции подрывают этот контроль, позволяя иностранным лабораториям, в том числе

подконтрольным Коммунистической партии Китая, лишать США конкурентного преимущества, которое призван сохранять экспортный контроль.

Из-за того, что мы не видим, как происходят эти атаки, стремительный прогресс, которого якобы добиваются эти лаборатории, ошибочно воспринимается как доказательство того, что экспортный контроль неэффективен и его можно обойти с помощью инноваций. На самом деле этот прогресс во многом зависит от возможностей, полученных в результате извлечения данных из американских моделей, а для масштабного извлечения данных требуется доступ к современным чипам. Таким образом, атаки с использованием «дистилляции» подтверждают необходимость экспортного контроля: ограниченный доступ к чипам ограничивает как непосредственное обучение моделей, так и масштабы незаконной «дистилляции».

What we found

The three distillation campaigns detailed below followed a similar playbook, using fraudulent accounts and proxy services to access Claude at scale while evading detection. The volume, structure, and focus of the prompts were distinct from normal usage patterns, reflecting deliberate capability extraction rather than legitimate use.

We attributed each campaign to a specific lab with high confidence through IP address correlation, request metadata, infrastructure indicators, and in some cases corroboration from industry partners who observed the same actors and behaviors on their platforms. Each campaign targeted Claude's most differentiated capabilities: agentic reasoning, tool use, and coding.

DeepSeek

Scale: Over 150,000 exchanges

The operation targeted:

- Reasoning capabilities across diverse tasks
- Rubric-based grading tasks that made Claude function as a reward model for reinforcement learning
- Creating censorship-safe alternatives to policy sensitive queries

DeepSeek generated synchronized traffic across accounts. Identical patterns, shared payment methods, and coordinated timing suggested “load balancing” to increase throughput, improve reliability, and avoid detection.

In one notable technique, their prompts asked Claude to imagine and articulate the internal reasoning behind a completed response and write it out step by step—effectively generating chain-of-thought training data at scale. We also observed tasks in which Claude was used to generate censorship-safe alternatives to politically sensitive queries like questions about dissidents, party leaders, or authoritarianism, likely in order to train DeepSeek’s own models to steer conversations away from censored topics. By examining request metadata, we were able to trace these accounts to specific researchers at the lab.

Moonshot AI

Scale: Over 3.4 million exchanges

The operation targeted:

- Agentic reasoning and tool use
- Coding and data analysis
- Computer-use agent development
- Computer vision

Moonshot (Kimi models) employed hundreds of fraudulent accounts spanning multiple access pathways. Varied account types made the campaign harder to detect as a coordinated operation. We attributed the campaign through request metadata, which matched the public profiles of senior Moonshot staff. In a later phase, Moonshot used a more targeted approach, attempting to extract and reconstruct Claude’s reasoning traces.

MiniMax

Scale: Over 13 million exchanges

The operation targeted:

- Agentic coding
- Tool use and orchestration

We attributed the campaign to MiniMax through request metadata and infrastructure indicators, and confirmed timings against their public product

roadmap. We detected this campaign while it was still active—before MiniMax released the model it was training—giving us unprecedented visibility into the life cycle of distillation attacks, from data generation through to model launch. When we released a new model during MiniMax’s active campaign, they pivoted within 24 hours, redirecting nearly half their traffic to capture capabilities from our latest system.

How distillers access frontier models

For national security reasons, Anthropic does not currently offer commercial access to Claude in China, or to subsidiaries of their companies located outside of the country.

To circumvent this, labs use commercial proxy services which resell access to Claude and other frontier AI models at scale. These services run what we call “hydra cluster” architectures: sprawling networks of fraudulent accounts that distribute traffic across our API as well as third-party cloud platforms. The breadth of these networks means that there are no single points of failure. When one account is banned, a new one takes its place. In one case, a single proxy network managed more than 20,000 fraudulent accounts simultaneously, mixing distillation traffic with unrelated customer requests to make detection harder.

Once access is secured, the labs generate large volumes of carefully crafted prompts designed to extract specific capabilities from the model. The goal is either to collect high-quality responses for direct model training, or to generate tens of thousands of unique tasks needed to run reinforcement learning. What distinguishes a distillation attack from normal usage is the pattern. A prompt like the following (which approximates similar prompts we have seen used repetitively and at scale) may seem benign on its own:

You are an expert data analyst combining statistical rigor with deep domain knowledge. Your goal is to deliver data-driven insights — not summaries or visualizations — grounded in real data and supported by complete and transparent reasoning.

But when variations of that prompt arrive tens of thousands of times across hundreds of coordinated accounts, all targeting the same narrow capability, the pattern becomes clear. Massive volume concentrated in a few areas, highly repetitive structures, and content that maps directly onto what is most valuable for training an AI model are the hallmarks of a distillation attack.

How we're responding

We continue to invest heavily in defenses that make such distillation attacks harder to execute and easier to identify. These include:

- **Detection.** We have built several classifiers and behavioral fingerprinting systems designed to identify distillation attack patterns in API traffic. This includes detection of chain-of-thought elicitation used to construct reasoning training data. We have also built detection tools for identifying coordinated activity across large numbers of accounts.
- **Intelligence sharing.** We are sharing technical indicators with other AI labs, cloud providers, and relevant authorities. This provides a more holistic picture into the distillation landscape.
- **Access controls.** We've strengthened verification for educational accounts, security research programs, and startup organizations—the pathways most commonly exploited for setting up fraudulent accounts.
- **Countermeasures.** We are developing Product, API and model-level safeguards designed to reduce the efficacy of model outputs for illicit distillation, without degrading the experience for legitimate customers.

But no company can solve this alone. As we noted above, distillation attacks at this scale require a coordinated response across the AI industry, cloud providers, and policymakers. We are publishing this to make the evidence available to everyone with a stake in the outcome.



Related content

Introducing Claude Tag

Claude Tag is a new way for teams to work with Claude.

[Read more](#) →

Anthropic opens Seoul office and announces new partnerships across the Korean AI ecosystem

[Read more](#) →

Statement on the US government directive to suspend access to Fable 5 and Mythos 5

The US government has issued an export control directive to suspend all access to Fable 5 and Mythos 5.

[Read more](#) →



Products

[Claude](#)

[Claude Code](#)

[Claude Code Enterprise](#)

[Claude Cowork](#)

[@Claude](#)

[Claude Design](#)

[Claude Security](#)

[Claude for Chrome](#)

[Claude for Microsoft 365](#)

[Skills](#)

[Download app](#)

[Pricing](#)

[Log in to Claude](#)

Models

[Mythos](#)

[Fable](#)

[Opus](#)

[Sonnet](#)

[Haiku](#)

Solutions

[AI agents](#)

[Code modernization](#)

[Coding](#)

[Customer support](#)

[Education](#)

[Enterprise](#)

[Financial services](#)

[Government](#)

[Healthcare](#)

[Legal](#)

[Life sciences](#)

[Nonprofits](#)

[Security](#)

[Small business](#)

[Startups](#)

Claude Platform

[Overview](#)

[Developer docs](#)

[Pricing](#)

[Ecosystem](#)

[Marketplace](#)

[Regional compliance](#)

[Claude on AWS](#)

[Google Cloud's Vertex AI](#)

[Microsoft Foundry](#)

[Console login](#)

Resources

[Blog](#)

[Claude partner network](#)

[Community](#)

[Connectors](#)

Courses

Customer stories

Engineering at Anthropic

Events

Inside Claude Code

Inside Claude Cowork

Inside Claude Enterprise

Plugins

Powered by Claude

Service partners

Tutorials

Use cases

Help and security

Availability

Status

Support center

Company

Anthropic

Careers

Policy

Economic Futures

Research

News

Claude's Constitution

Claude Corps

Policy on the AI Exponential

Responsible Scaling Policy

Security and compliance

Transparency

Terms and policies

[Privacy choices](#)

[Privacy policy](#)

[Consumer health data privacy policy](#)

[Responsible disclosure policy](#)

[Terms of service: Commercial](#)

[Terms of service: Consumer](#)

[Usage policy](#)

© 2026 Anthropic PBC

