

TTS-2 в режиме реального времени. Создан для общения в режиме реального времени, максимально приближенного к человеческому. Подробнее



☰ Возможности > Временные метки

Возможности

Временные метки

📄 Copy page



Выравнивание по меткам времени позволяет получать информацию о синхронизации, соответствующую сгенерированному аудио, что полезно для таких функций, как выделение слов, субтитры в стиле караоке и синхронизация губ. Примеры и особенности работы, описанные на этой странице, применимы к моделям TTS 1.5 и TTS-2 (`inworld-tts-1.5-mini` , `inworld-tts-1.5-max` , `inworld-tts-2`).

⚠ Информацию о языках, поддерживающих выравнивание временных меток, см. в [таблице поддержки языков](#).

препинания

- ❗ Включение выравнивания временных меток может увеличить задержку (особенно для конечных точек, не поддерживающих потоковую передачу).

Если эта функция включена, в ответе будут отображаться массивы с временными метками:

- **WORD** : `timestampInfo.wordAlignment` с `words` , `wordStartTimeSeconds` , `wordEndTimeSeconds` , и `phoneticDetails` . Массив `words` охватывает все токены исходного ввода по порядку, поэтому выравнивание соответствует полному тексту без пропусков.
- **CHARACTER** : `timestampInfo.characterAlignment` с `characters` , `characterStartTimeSeconds` , `characterEndTimeSeconds`

Подробную информацию см. в [справочнике по API](#).

Поведение при потоковой передаче

Вы можете управлять тем, как данные с метками времени передаются вместе со звуком, с помощью [timestampTransportStrategy](#) .

Синхронизация (по умолчанию)

Аудио и выравнивание поступают одновременно в каждом фрагменте. Каждый фрагмент содержит аудиоданные и соответствующие временные метки.

```
Chunk 1: audio + timestamps for chunk 1
Chunk 2: audio + timestamps for chunk 2
Chunk 3: audio + timestamps for chunk 3
```

TTS-2 в режиме реального времени. Создан для общения в режиме реального времени, максимально приближенного к человеческому. Подробнее

10

>

только данные о временной метке. Это сокращает время до начала воспроизведения аудио, поскольку серверу не нужно ждать завершения выравнивания, чтобы отправить аудио.

```
Chunk 1: audio only
Chunk 2: audio only
Chunk 3: audio only
Chunk 4: timestamps only (alignment for chunks 1-3)
Chunk 5: timestamps only
...
```

Используйте асинхронную передачу, если для вас важна скорость воспроизведения и вы можете обрабатывать временные метки, поступающие после соответствующего аудио. Используйте синхронную передачу, если вам нужны аудио и временные метки в каждом фрагменте (например, для синхронизации губ в реальном времени или выделения слов во время воспроизведения).

Задайте `timestampTransportStrategy` в качестве `SYNC` или `ASYNC` в своем запросе. Подробнее см. в [справочнике по API](#).

Структура ответа

Возвращает данные о выравнивании с указанием времени на уровне фонов и визуальных символов для анимации синхронизации губ.

>

```
{
  "wordIndex": 0,
  "phones": [
    {"phoneSymbol": "[silence]", "startTimeSeconds": 0, "durationSeconds": 0.59}
  ]
},
{
  "wordIndex": 1,
  "phones": [
    {"phoneSymbol": "h", "startTimeSeconds": 0.24, "durationSeconds": 0.08},
    {"phoneSymbol": "ɛ", "startTimeSeconds": 0.38, "durationSeconds": 0.08},
    {"phoneSymbol": "l", "startTimeSeconds": 0.42, "durationSeconds": 0.08},
    {"phoneSymbol": "ə", "startTimeSeconds": 0.47, "durationSeconds": 0.08},
    {"phoneSymbol": "ʊ", "startTimeSeconds": 0.54, "durationSeconds": 0.08}
  ]
},
{
  "wordIndex": 2,
  "phones": [
    {"phoneSymbol": "[silence]", "startTimeSeconds": 0.59, "durationSeconds": 0.59}
  ]
},
{
  "wordIndex": 3,
  "phones": [
    {"phoneSymbol": "w", "startTimeSeconds": 0.59, "durationSeconds": 0.08},
    {"phoneSymbol": "ʒ", "startTimeSeconds": 0.69, "durationSeconds": 0.08},
    {"phoneSymbol": "t", "startTimeSeconds": 0.72, "durationSeconds": 0.08},
    {"phoneSymbol": "d", "startTimeSeconds": 0.95, "durationSeconds": 0.08}
  ]
},
{
  "wordIndex": 4,
  "phones": [
    {"phoneSymbol": "[silence]", "startTimeSeconds": 1.09, "durationSeconds": 0.59}
  ]
}
```

>

```
]
},
{
  "wordIndex": 6,
  "phones": [
    {"phoneSymbol": "[silence]", "startTimeSeconds": 1.52, "durationSec
  ]
},
{
  "wordIndex": 7,
  "phones": [
    {"phoneSymbol": "w", "startTimeSeconds": 1.52, "durationSeconds": 0
    {"phoneSymbol": "ə", "startTimeSeconds": 1.55, "durationSeconds": 0
    {"phoneSymbol": "t", "startTimeSeconds": 1.58, "durationSeconds": 0
  ]
},
{
  "wordIndex": 8,
  "phones": [
    {"phoneSymbol": "[silence]", "startTimeSeconds": 1.62, "durationSec
  ]
},
{
  "wordIndex": 9,
  "phones": [
    {"phoneSymbol": "b", "startTimeSeconds": 1.62, "durationSeconds": 0
    {"phoneSymbol": "i", "startTimeSeconds": 1.67, "durationSeconds": 0
  ]
},
{
  "wordIndex": 10,
  "phones": [
    {"phoneSymbol": "[silence]", "startTimeSeconds": 1.73, "durationSec
  ]
},
{
```

>

```
    ],
  },
  {
    "wordIndex": 12,
    "phones": [
      {"phoneSymbol": "[silence]", "startTimeSeconds": 2.34, "durationSec
```

Phonetic details structure

Each entry in `phoneticDetails` contains:

Field	Description
<code>wordIndex</code>	0-based index into the <code>words</code> array. Speech tokens have full phoneme breakdowns; non-speech tokens have a single <code>[silence]</code> phone (may be zero-length).
<code>phones</code>	Array of phonemes for this token.
<code>isPartial</code>	Deprecated. This field may still appear in responses for backward compatibility, but it is always <code>false</code> .

Каждая запись по телефону содержит:

Field	Description
<code>phoneSymbol</code>	The phone symbol: IPA for speech phones, or <code>[silence]</code> for non-speech tokens.
<code>startTimeSeconds</code>	Start time of the phoneme in seconds.



>

The following viseme symbols are used for lip-sync animation:

Viseme	Description
aei	Open mouth vowels (a, e, i, ə, ʌ, æ, ɑ, etc.)
o	Rounded vowels (o, u, əʊ, ou, etc.)
ee	Front vowels (i, ɪ, eɪ, etc.)
bmp	Bilabial consonants (b, m, p)
fv	Labiodental consonants (f, v)
l	Lateral consonant (l)
r	Rhotic sounds (r, ɜ, ə)
th	Dental fricatives (θ, ð)
qw	Rounded consonants (w, ʌ)
chjsh	Postalveolar/palatal consonants (tʃ, dʒ, ʃ, ʒ)
cdgknstxyz	Alveolar/velar consonants (c, d, g, k, n, s, t, x, y, z)

Was this page helpful?



Yes



No

TTS-2 в режиме реального времени. Создан для общения в режиме реального времени,
максимально приближенного к человеческому. Подробнее

10

>
