


CRAM: новая аппаратная архитектура снижает энергопотребление ИИ в 1000 раз

30 июля 2024 State-of-the-art



Исследователи из Университета Миннесоты Твин-Ситис представили архитектуру аппаратного обеспечения **Computational Random-Access Memory (CRAM)**, которая призвана трансформировать вычисления в области ИИ, резко сократив энергопотребление. CRAM способен сократить использование энергии ИИ в 1000 раз, решая одну из главных проблем в этой области: потребление энергоресурсов. Международное энергетическое агентство (IEA) прогнозирует, что потребление энергии ИИ увеличится более чем в два раза, с 460 тераватт-часов (ТВт·ч) в 2022 году до 1000 ТВт·ч к 2026 году, что эквивалентно общему потреблению электроэнергии в Японии. Традиционные методы вычислений ИИ включают энергоемкие передачи данных между логическими блоками и памятью. CRAM устраняет это, обрабатывая

данные полностью в массиве памяти. Статья опубликована в [*npj Unconventional Computing*](#).



Подробнее о CRAM

CRAM, или Computational Random-Access Memory, разработан специально для снижения энергопотребления. В отличие от традиционных архитектур, CRAM обрабатывает данные непосредственно в ячейках памяти, устраняя необходимость в энергоемких передачах данных между логическими блоками и памятью. Эта инновация значительно повышает энергоэффективность, предлагая потенциальную экономию энергии до 1000 раз по сравнению с традиционными методами. Уникальная конструкция CRAM позволяет выполнять вычисления в памяти, обеспечивая случайный доступ, реконфигурируемость и параллельные операции, что делает его идеальным для ресурсоемких вычислений, используемых, например, для обучения нейронных сетей или обработки изображений.

Переход от традиционной архитектуры

CRAM представляет собой фундаментальное отступление от традиционной [архитектуры фон Неймана](#), которая является основой современных компьютеров. Обеспечивая вычисления непосредственно в ячейках памяти, CRAM устраняет узкое место передачи данных между вычислительными блоками и памятью. Улья Карпузку, доцент кафедры электротехники и вычислительной техники и соавтор статьи, подчеркнула гибкость CRAM в реконфигурации для соответствия требованиям производительности различных алгоритмов ИИ.

CRAM обрабатывает данные полностью в массиве памяти, в основе подхода лежит технология [спинтронных](#) устройств,

использующая спин электронов для хранения данных. Экономия энергии составляет до 2500 раз по сравнению с традиционными методами. Этот прорыв стал результатом более чем 20 лет исследований под руководством Джиан-Пинга Ванга, Заслуженного профессора Макнайта и обладателя кафедры Роберта Ф. Хартманна на кафедре электротехники и вычислительной техники.

Эволюция технологии CRAM

Ванг вспомнил о первоначальной концепции использования ячеек памяти непосредственно для вычислений, которая считалась «сумасшедшей» два десятилетия назад. Междисциплинарные усилия, включающие студентов и преподавателей из различных областей, таких как физика, материаловедение, инженерия, компьютерные науки и создание аппаратного обеспечения, привели к разработке этой технологии.

Архитектура CRAM базируется на предыдущих работах команды с магнитными туннельными переходами (MTJ) и наноструктурированными устройствами. Эти компоненты, уже используемые в жестких дисках и датчиках, составляют основу магнитной оперативной памяти (MRAM), внедренной в микроконтроллеры и смарт-часы.

Экспериментальные результаты и перспективы

Команда провела обширные эксперименты, демонстрирующие возможности CRAM. Они достигли надежных операций записи в память с средним коэффициентом ошибок записи менее 1.5×10^{-4} . Устройство продемонстрировало высокую точность в логических операциях, с точностью около 99.4% для двухвходового NAND.

С несколькими уже полученными патентами исследовательская команда стремится сотрудничать с лидерами полупроводниковой промышленности для расширения демонстраций и производства аппаратного обеспечения, способного улучшить функциональность ИИ. Детали исследования команды опубликованы в рецензируемом журнале *npj Unconventional Computing*.

Эта инновация не только обещает сделать ИИ более энергоэффективным, но и переосмысливает будущее вычислений ИИ с гибкой, эффективной и устойчивой архитектурой.

Автор: [Konstantine Mozgovoy](#) 

Источник: <https://www.nature.com/articles/s44335-024-00003-3>

 Подписаться ▼

Оставьте первый комментарий!



Читайте также

Google представила Gemini 2.5 Flash Image aka Nano Banana — новую модель генерации изображений

Mistral Agents API: фреймворк для создания AI-агентов с веб-поиском, генерирующих код и изображения

Токенизатор TA-TiTok от Bydedance обновил бенчмарки в генерации изображений при обучении на открытых данных

VBVR: открытый датасет на 2 миллиона видео для обучения видеомоделей рассуждению

**GLM-5: топ-1 открытая модель для генерации кода и текста,
конкурирующая с Claude и GPT на агентных задачах**

Multiplex Thinking: семплинг 3 токенов вместо 1 повышает точность решения олимпиадных задач с 40% до 55%

Актуальное

MinerU-Diffusion: новый подход к OCR через диффузионное декодирование ускоряет парсинг PDF в 3 раза без потери точности

daVinci-MagiHuman: открытая 15B-модель генерирует 5-секундное видео с липсинком за 2 секунды на одном H100

OpenClaw: лобстер, который захватил мир. ИИ-агент работает локально и управляется через мессенджеры

OpenClaw-RL: ИИ-агент учится на собственных ошибках через реакции пользователя и среды, обновляя веса на ходу

Helios: 14B-модель генерирует видео длиной больше 60 секунд со скоростью 19,5 FPS на одной H100

VBVR: открытый датасет на 2 миллиона видео для обучения видеомоделей рассуждению

GLM-5: топ-1 открытая модель для генерации кода и текста, конкурирующая с Claude и GPT на агентных задачах

Рассказываем о последних исследованиях в области искусственного интеллекта: нейронные сети, computer vision, nlp, обработка фотографий, потокового видео и звука, дополненная и виртуальная реальность.

